29 settembre 2026

Da dove vengono i dati e quanto in fretta servono: quattro casi di modelli predittivi, cinque fonti, batch contro streaming

Foundation in Big Data — Lesson 2: Industry Examples across Sectors, Big Data Sources, Batch vs Streaming Data, Introduction to Databricks + Team Work 2

Martedì · Rizzi, Campana · Completa

Due registrazioni PLAUD: parte 1 (Rizzi, 10:03, 91 min): quattro casi aziendali (demenza, grandine e alluvioni per le assicurazioni, arte di Refik Anadol, previsione dei trend nella moda) fino al minuto 55 circa, poi Team Work 2 sul centro fitness con lavoro a gruppi (conversazioni private saltate) e alcune presentazioni finali. Parte 2 (Campana, 12:03, 62 min): la registrazione parte a lezione già iniziata (manca l'introduzione, si sente solo la fine della metafora del maiale della slide 3), poi le fonti dei big data, il gioco sulle fonti da combinare, batch contro streaming con la sfida in classe, e si interrompe proprio mentre comincia l'introduzione a Databricks. Slide Canvas 'BigDataBsnsRizzi2026Lesson2' (45 pagine, caricata la mattina della lezione): pp. 2–11 fonti, pp. 12–19 batch/streaming (Campana); pp. 20–29 Databricks (registrata solo l'apertura: la sezione su Databricks è un'integrazione ricostruita dalle slide 20–29, viste anche come immagine, più fonti ufficiali Databricks); pp. 30–43 casi (Rizzi); pp. 44–45 consegna del Team Work 2. Nessun'altra registrazione del giorno sui PLAUD salvati (le due trascrizioni 'pulita' di settembre sono copie delle stesse due registrazioni). Canvas non accessibile in questo giro. Le slide-immagine 4–11, 25–27, 13–19, 32–34, 36–37, 39, 42–43 sono state guardate come immagine.

In breve

Rizzi mostra quattro casi in cui i big data cambiano una decisione: prevedere chi rischia la demenza, prezzare il rischio grandine per le assicurazioni, creare un'opera d'arte da dati ecologici, anticipare il trend della prossima collezione di moda. Il filo comune è unire fonti molto diverse e saper misurare quanto un modello è affidabile. Campana spiega da dove arrivano i dati (transazioni,

ERP/CRM, sensori, social, API), che cosa vede e che cosa perde ciascuna fonte, e come scegliere tra elaborazione batch (a lotti, programmata) e streaming (continua, in tempo reale) in base alla finestra di decisione.

- Un modello predittivo combina molti fattori insieme: lo studio NACC (9.606 persone) trova età, bassa istruzione, depressione e BMI come segnali principali, con due metodi diversi che arrivano alle stesse conclusioni.
- Un modello si giudica con metriche precise: sensibilità = quota dei malati veri che trova; specificità = quota dei sani che riconosce; AUC = quanto bene ordina i rischi. Accuratezza da sola inganna quando i casi sono rari.
- Associazione non è causa: nello studio il BMI più alto sembra 'proteggere', ma è probabile causalità inversa (si dimagrisce prima della diagnosi). Non è un consiglio di salute.
- Il rischio diventa un prezzo quando unisci pericolo (meteo), esposizione (beni assicurati) e vulnerabilità: perdita attesa = somma di probabilità × gravità.
- Ogni fonte cattura un pezzo di realtà: transazioni = cosa è successo; ERP/CRM = chi e come; sensori = condizioni fisiche; social = contesto pubblico; API = contesto esterno. Nessuna basta da sola.
- Ogni fonte ha il suo difetto tipico: definizioni incoerenti e silos (ERP/CRM), rumore e guasti (sensori), distorsioni e fake (social), dipendenza da un fornitore (API).
- La finestra di decisione decide la velocità: buste paga e bilanci in batch; frodi con carta e monitoraggio dei pazienti in streaming. Si sceglie la latenza che la decisione richiede, non la più bassa possibile.
- Quasi tutte le aziende usano entrambi: streaming per agire subito, batch per riconciliare, fare report e riaddestrare i modelli.

Un modello predittivo vede i rischi che nessuno

vede guardando un fattore alla volta

Rizzi apre con una domanda medica: si può capire in anticipo chi rischia la demenza? La demenza è in crescita perché la popolazione invecchia, e farmaceutica e sanità cercano due cose: **prevedere** chi è a rischio e **prevenire** dove possibile.

Il punto di partenza è un elenco famoso. Nel 2024 la *Lancet Commission* (un gruppo di esperti pubblicato sulla rivista medica The Lancet) ha indicato **14 fattori di rischio modificabili**: tra gli altri inattività fisica, fumo, alcol, inquinamento, traumi alla testa, poca vita sociale, bassa istruzione, obesità, ipertensione, diabete, depressione, perdita dell'udito, colesterolo LDL alto e perdita della vista non curata. La Commissione stima che agire su questi fattori potrebbe prevenire o ritardare circa il 45% dei casi. Alcuni sono ovvi; altri, come l'istruzione o la vista, sorprendono.

L'idea in una frase

Un rischio complesso non si capisce guardando un fattore alla volta: il modello li valuta tutti insieme, perché le persone hanno più condizioni nello stesso momento.

Caso reale · Lo studio NACC: due metodi, le stesse risposte (2025)

Un gruppo di ricercatori (Arnold e colleghi, rivista *Alzheimer's & Dementia*, 2025) ha usato i dati del National Alzheimer's Coordinating Center americano: **9.606 persone** seguite in 46 centri tra il 2005 e il 2023, per una media di circa 6 anni. Di queste, **877 (il 9%)** hanno sviluppato demenza. Hanno analizzato 13 fattori di rischio con due "lenti":

1. **Data-driven** (guidata dai dati): un modello di *machine learning* chiamato *XGBoost*, una catena di piccoli alberi decisionali in cui ogni albero corregge gli errori del precedente. È bravo a trovare combinazioni non lineari, ma da solo non spiega il perché.
2. **Hypothesis-driven** (guidata da ipotesi): la classica analisi di sopravvivenza dei medici, con le curve di *Kaplan-Meier* (quanti restano senza demenza nel tempo) e la regressione di *Cox* (quanto ogni fattore aumenta il rischio).

Rizzi sottolinea che il modello ha macinato i dati per ore e settimane, e alla fine ne sono usciti fattori che un'analisi a mano non avrebbe trovato. Le due lenti hanno indicato gli stessi segnali principali: **età, bassa istruzione, depressione e BMI**. Quando metodi diversi convergono, la conclusione è più solida. Limiti dichiarati: nessuna validazione esterna, volontari di centri di ricerca, popolazione in prevalenza bianca.

Rizzi insiste su un problema: se chiedi qualcosa al tuo chatbot preferito, ottieni una risposta ma non sai **come** ci è arrivato. Un ragionamento deterministico è trasparente: "Andrea è padre di Filippo, Filippo è padre di Marco, quindi Andrea è nonno di Marco". Un modello statistico non funziona così: produce probabilità. Per aprire la scatola nera i ricercatori usano *SHAP*, un metodo che a posteriori stima quanto ogni variabile ha spinto la previsione. Nella slide la barra dell'età è lunghissima, quelle di istruzione e depressione più corte. Attenzione: SHAP spiega **il modello**, non dimostra cause.

E qui arriva il paradosso. Nello studio, chi ha un **BMI più alto** (indice di massa corporea: peso diviso altezza al quadrato; 25–30 sovrappeso, oltre 30 obesità)

ha un rischio osservato **più basso**. Rizzi a lezione scherza che "mangiare un po' di più non è sempre male". Le slide stesse dicono il contrario: è probabile *causalità inversa*. Negli anni prima della diagnosi molte persone dimagriscono, quindi il peso basso è un sintomo precoce, non una causa. La Lancet Commission considera l'obesità in mezza età un fattore di rischio.

Sensibilità e specificità, spiegate dagli statistici di Padova · apri su YouTube

:::

Come si misura se il modello è buono? Le slide danno quattro numeri. Ecco che cosa vogliono dire:

- **Sensibilità 0,70**: su 100 persone che svilupperanno davvero la demenza, il modello ne segnala 70.
- **Specificità 0,64**: su 100 persone che non la svilupperanno, il modello ne riconosce 64 come a basso rischio; le altre 36 ricevono un falso allarme.
- **ROC AUC 0,73**: se prendi a caso un malato e un sano, nel 73% dei casi il modello dà al malato un rischio più alto. 0,5 è il lancio di una moneta, 1 è perfetto.
- **Accuratezza 0,64**: quota totale di risposte giuste. Da sola inganna quando i casi sono rari.

Esempio svolto · **Che cosa succede su 1.000 persone**

1. Con il 9% di casi, su 1.000 persone 90 svilupperanno demenza e 910 no.
2. Sensibilità 0,70: il modello trova 63 dei 90 casi veri e ne perde 27.
3. Specificità 0,64: dei 910 sani ne riconosce 580; gli altri 330 sono falsi allarmi.
4. Allarmi totali: 63 + 330 = 393. Solo 63 su 393, cioè il 16%, sono casi veri.
5. Accuratezza: (63 + 580) / 1.000 = 64,3%, proprio il numero della slide.

Conclusione: il modello è utile per decidere a chi offrire prima controlli e prevenzione, non per dire a una persona "avrai la demenza".

Laboratorio · **Sposta la soglia del modello: più casi trovati o meno falsi allarmi?**

Soglia di rischio per dare l'allarme:

50

Su 1.000 persone (90 casi veri): casi trovati **63** · casi persi **27** · falsi allarmi **328**

Sensibilità **0.70** · Specificità **0.64**

Zona di compromesso: è qui che si decide, in base al costo di un caso perso e di un falso allarme.

Numeri illustrativi costruiti intorno ai valori dello studio NACC (a soglia 50: sensibilità 0,70, specificità 0,64). Non è il modello vero, serve a vedere il compromesso.

Prova tu **Un amico ha ricevuto da un'app "rischio demenza alto" basata su un modello con specificità 0,64. Deve preoccuparsi?**

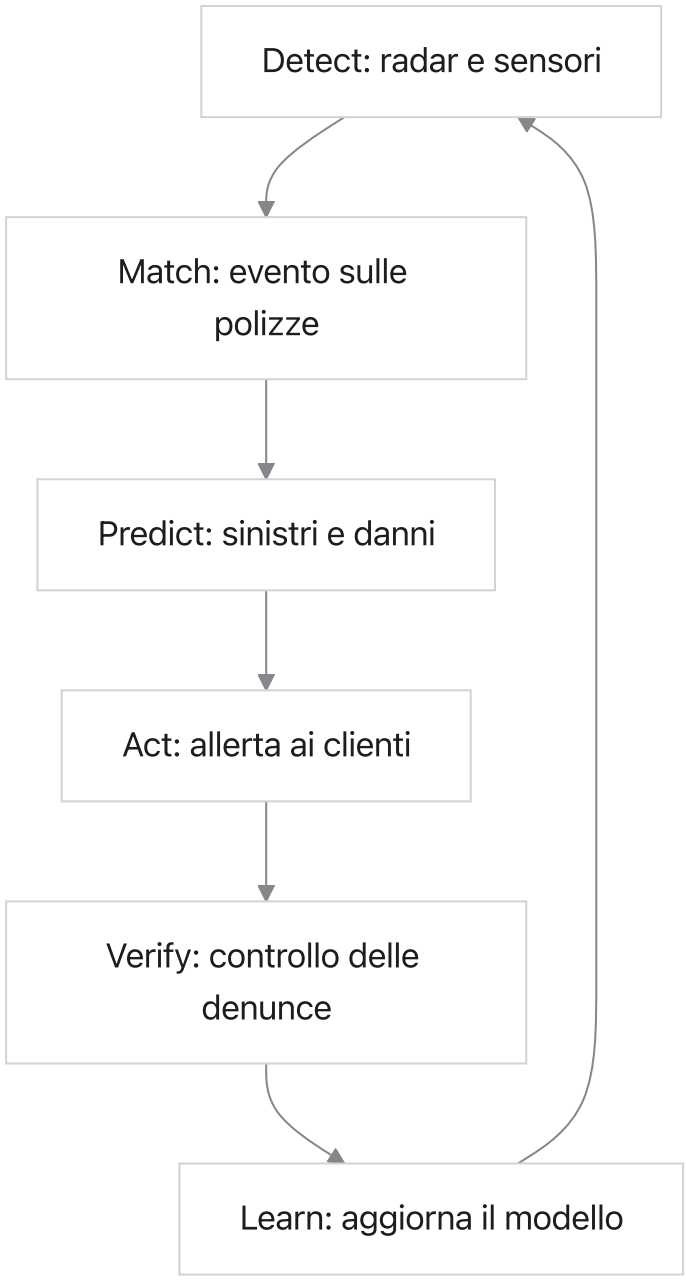
Il rischio diventa un prezzo quando unisci meteo, luoghi e sinistri

Il secondo caso viene dall'esperienza di Rizzi. Una ventina di anni fa ha lavorato con l'ANIA, l'associazione delle compagnie assicurative italiane, su un modello per i danni da **grandine e alluvioni** in agricoltura. L'assicurazione è statistica: l'agricoltore paga un *premio* (il prezzo della polizza) e, se la grandine distrugge il raccolto, la compagnia gli rimborsa quello che avrebbe guadagnato. Il premio giusto dipende dalla probabilità dell'evento.

Prima dei dati, chi scriveva le polizze (l'*underwriter*) decideva a sensazione: "a Bergamo grandina più che a Catanzaro", o si affidava ai vecchi contadini che "sentono" la stagione. Per un settore così grande non basta: secondo i dati ANIA, nel 2024 i premi assicurativi in Italia valevano circa il 6,9% del PIL.

Il problema tecnico era mettere insieme fonti molto diverse: email delle denunce di sinistro ("sono in provincia di Catanzaro e la grandine ha distrutto il mio campo"), immagini satellitari, storico dei sinistri di tutte le compagnie, e poi collegare tutto alla **geografia**. Il risultato: per un punto preciso sulla mappa, la probabilità di grandine o alluvione nei prossimi 12 mesi, trasformabile in premio. Rizzi racconta che il modello è ancora in uso, migliorato nel tempo.

Le slide 36–37 mostrano la versione moderna in sei passi:



Il modello unisce tre cose: il **pericolo** (*hazard*: dimensione della grandine, vento, pioggia), l'**esposizione** (*exposure*: che cosa è assicurato e dove) e la **vulnerabilità** (quanto si danneggia un tetto, un'auto, un vigneto). La fase "verify" serve anche contro le frodi: chi denuncia una grandinata che non c'è stata viene smentito dai dati meteo.

Formula · Perdita attesa

Perdita attesa = Σ [P(sinistro) × gravità attesa], corretta per franchigie, limiti, coperture e riassicurazione.

- P(sinistro): probabilità che la polizza abbia un danno nel periodo (numero tra 0 e 1).
- Gravità attesa: danno medio in euro se il sinistro avviene.
- Esempio ipotetico: 1.000 vigneti, ognuno con P = 0,03 e danno medio 20.000 €. Perdita attesa = 1.000 × 0,03 × 20.000 = 600.000 €, cioè 600 € per polizza prima di costi e margine. Se il modello scopre che in una valle P sale a 0,08, lì il premio puro diventa 1.600 €.

Caso reale · Il chicco di 19 centimetri (Friuli, luglio 2023)

La sera del 24 luglio 2023 ad Azzano Decimo (Pordenone) cadde un chicco di grandine di circa **19 cm** di diametro, confermato dall'European Severe Weather Laboratory (ESSL) come record europeo. Il record precedente, 16 cm a Carmignano di Brenta (Padova), era di appena cinque giorni prima. È stato il secondo grande episodio di temporali violenti nel nord Italia in una settimana. Per un assicuratore significa che il passato non basta più: se gli eventi estremi cambiano, i modelli vanno riaddestrati con dati nuovi, ed è il passo "learn" dello schema.

Prova tu **Perché un modello del rischio grandine addestrato solo sui sinistri 2000–2015 potrebbe sbagliare i prezzi nel 2026?**

I dati possono anche creare: un'opera d'arte e la prossima collezione

Il terzo caso cambia settore: l'arte. Refik Anadol, artista nato a Istanbul, ha aperto a Los Angeles **DATALAND** con l'opera *Machine Dreams: Rainforest*. Lo stes-

so schema dei casi precedenti: raccogliere dati diversissimi (immagini, suoni della foresta, dati ecologici), analizzarli e poi **generare** cose nuove.

Caso reale · Machine Dreams: Rainforest (DATALAND, Los Angeles)

Secondo il museo, l'opera usa il *Large Nature Model*, un modello di AI addestrato su archivi di istituzioni di ricerca e organizzazioni ambientali, più lavoro sul campo: oltre **1,2 miliardi di dati ecologici** e un flusso continuo di dati ambientali dalle foreste pluviali. Il risultato sono immagini e suoni che non si ripetono mai, proiettati da 84 proiettori, con un paesaggio sonoro composto dal vivo. In più, sensori indossabili leggono in forma anonima battito, movimento e posizione dei visitatori, e queste misure entrano nell'esperienza. Rizzi la cita perché unisce tre mondi: dati scientifici, natura e persone.

Il quarto caso è la **moda**. Ogni collezione è una scommessa: si produce sei mesi prima, e se al pubblico non piace si perdono milioni. I big data servono a ridurre l'azzardo leggendo i segnali deboli prima che il trend esploda. Le slide 42–43 seguono la traccia digitale dal buzz all'acquisto:

1. **Attenzione**: che cosa la gente nota (sfilate, influencer, foto per strada).
2. **Ricerca**: che cosa cerca davvero ("ballerine argento").
3. **Esplorazione**: quali prodotti guarda, per quanto tempo.
4. **Intenzione**: wishlist e carrello.
5. **Acquisto**: che cosa compra davvero.
6. **Tenere o restituire**: che cosa dà valore duraturo.

Leggere insieme i passi dà diagnosi diverse: tanto buzz e poche ricerche = solo attenzione culturale; tante ricerche e poca disponibilità = buco nell'assortimento; tante vendite e tanti resi = problema di vestibilità o qualità; tante vendite e pochi resi = domanda vera.

Il concetto chiave è il *trend momentum*: **crescita × persistenza × conversione commerciale**. Se una celebrità indossa scarpe argento, le ricerche fanno un

picco per tre giorni e poi crollano: è un picco virale, non una base per la collezione estiva. Serve una crescita che duri e che diventi acquisti. Il modello produce una previsione ("calzature metalliche, primavera-estate, clienti urbani 18–35, prezzo accessibile premium, fiducia medio-alta"), ma la decisione creativa resta allo stilista.

Caso reale · Zara: vince chi cambia rotta in poche settimane

Il primo negozio Zara aprì nel 1975 ad A Coruña, in Galizia. Oggi Inditex, il gruppo di Zara, è il più grande distributore di moda al mondo. Rizzi lo cita come chi ha capito per primo che indovinare la collezione non basta: bisogna poter **correggere** durante la stagione. Il segreto documentato è la produzione di prossimità: una parte importante dei capi viene prodotta vicino alla sede, in Spagna, Portogallo, Marocco e Turchia, così se un'estate è più calda del previsto o un capo non vende, si cambia produzione in settimane e non in mesi. A Coruña viene ancora usata come città-test per le nuove collezioni.

Dentro il mondo di Zara (Bloomberg Originals) · apri su YouTube

:::

Prova tu **Le ricerche di un modello di giacca crescono da quattro mesi, le vendite anche, ma i resi sono al 45%. Che cosa concludi?**

Ogni fonte di dati vede solo un pezzo di realtà

Campana parte da una metafora: *"tout est bon dans le cochon"*, del maiale non si butta niente. La slide 3 dice che l'AI "non butta mai via nessun dato". Il senso è che un dato che oggi sembra spazzatura può diventare informazione se trova il sistema giusto per leggerlo, e che un modello che deve parlare con le persone ha bisogno anche di dati "sporchi" come post e conversazioni, perché contengono contesto, modi di dire e cultura.

Collegamento · Lo slogan e il GDPR

Come regola aziendale va presa con le pinze. Per i dati personali il GDPR (art. 5) impone la **minimizzazione**: raccogli solo ciò che serve per uno scopo dichiarato e conservalo solo per il tempo necessario. "Tenere tutto, non si sa mai" è un rischio legale, non una strategia. Il data lake della lezione del 6 ottobre è il posto dove i dati si tengono, ma con etichette, permessi e scadenze.

Il punto di Campana: prima di analizzare, chiediti **quale parte di realtà cattura ogni fonte**. La slide 4 distingue quattro origini:

- **Generati dalle persone**: messaggi, post, recensioni, click.
- **Generati dai processi**: la traccia lasciata dai flussi aziendali (ordini, fatture, spedizioni).
- **Generati dalle macchine**: sensori, telemetria, robot industriali.
- **Esterni**: meteo, geografia, mercati, dati pubblici.

Guardare una sola fonte porta a conclusioni sbagliate. L'esempio di Campana: un'azienda di trasporti vede i costi di consegna salire e pensa di aver sbagliato qualcosa. Ma se guardi anche i dati esterni scopri che è salito il prezzo del petrolio.

Poi passa alle fonti concrete. Le **transazioni** (acquisti, pagamenti, prenotazioni, resi, richieste di rimborso) registrano **che cosa è successo**, con data e ora. Sono strutturate, continue, verificabili: "non puoi mentire", sono pronte per una revisione contabile. Servono per analisi delle vendite, rilevazione delle frodi e previsione della domanda. Ma perdono il **contesto**: lo scontrino dice che hai comprato un prodotto, non che ne avevi guardati tre, che non trovavi quello che volevi o che il sito del concorrente era fuori servizio.

Per questo le aziende usano due grandi sistemi:

- **ERP** (*Enterprise Resource Planning*): finanza, magazzino, acquisti, produzione. Risponde alla domanda "ho le risorse (soldi, persone, merci,

processi) per mantenere le promesse?". È **esecuzione**.

- **CRM** (*Customer Relationship Management*): contatti, clienti, opportunità, interazioni. In Salesforce, per esempio, chi vende registra ogni chiamata e com'è andata, così il sistema ricorda quando hai sentito un cliente l'ultima volta. È **relazione**.

Insieme raccontano una storia molto migliore: l'ERP sa che il cliente ha pagato, il CRM sa che prima aveva chiesto assistenza tre volte. Ma per unirli servono **identificativi comuni** (lo stesso cliente deve avere lo stesso codice) e **definizioni comuni**.

Esempio svolto · Il consiglio di amministrazione con due numeri (ipotetico, raccontato da Campana)

1. Il marketing presenta al consiglio: "abbiamo 2.000 clienti". Per lui cliente = chiunque abbia lasciato i dati scaricando un documento.
2. Il responsabile vendite risponde: "no, sono 1.000". Per lui cliente = chi ha pagato un abbonamento negli ultimi 90 giorni.
3. Entrambi leggono dati corretti, da sistemi diversi con definizioni diverse.
4. Il consiglio non sa più che cosa decidere. La soluzione non è "più dati", ma un dizionario comune delle definizioni (*data governance*) e un codice cliente unico tra ERP e CRM.

Prova tu **Un e-commerce ha solo i dati delle transazioni. Che cosa non potrà mai sapere?**

Sensori e social sono veloci, ma possono mentire

I **sensori e l'IoT** misurano piccole variazioni continue: temperatura, movimento, GPS, battito cardiaco da un dispositivo indossabile, pressione. Il flusso è sempre lo stesso: **sensore → gateway** (il dispositivo che raccoglie e inoltra) **→ piattaforma di streaming → azione** (allerta o dashboard). Sono dati ad altissima

velocità, con data e ora, *semi-strutturati* (hanno una forma, ma non sempre stanno comodi in una tabella). Usi tipici: manutenzione predittiva (cambiare un pezzo quando sta per rompersi, invece che a calendario), ottimizzazione delle flotte, gestione dell'energia, monitoraggio dei pazienti in terapia intensiva.

Che cos'è l'Internet of Things (Registro .it) · apri su YouTube

:::

Il loro difetto è il **rumore**. Se un macchinario sensibile al calore segna +100 °C in due minuti, può stare per rompersi oppure il sensore ha preso un'interferenza elettromagnetica. Distinguere segnale da rumore è difficile, e con dati così veloci hai pochi secondi per decidere.

Caso reale · Lion Air 610: un sistema che si fidava di un solo sensore (2018)

Il 29 ottobre 2018 un Boeing 737 MAX della Lion Air precipitò in mare poco dopo il decollo da Giacarta: 189 morti. Il rapporto finale degli investigatori indonesiani (KNKT, ottobre 2019) indica tra i fattori il sistema automatico MCAS, che prendeva i dati da **un solo sensore** dell'angolo d'attacco. Quel sensore, riparato in precedenza, era starato di circa 21 gradi; il sistema, credendo che l'aereo stesse per stallare, spingeva il muso verso il basso. Mancava anche l'avviso di disaccordo tra i due sensori. Dopo un secondo incidente (Ethiopian Airlines, marzo 2019) il 737 MAX fu fermato in tutto il mondo, e Boeing modificò MCAS per confrontare entrambi i sensori. Lezione per i dati: un dato macchina non è automaticamente vero, e un sistema critico non deve dipendere da una sola fonte.

I **social media** sono dati non strutturati: post, commenti, reazioni, immagini, video, slang, reti di contatti. Servono per l'analisi del sentiment (che cosa pensa la gente del tuo nuovo prodotto, anche chi non è cliente), il monitoraggio del brand e la scoperta di trend, a volte più rapida ed economica di una costosa ricerca di mercato. Ma vanno interpretati con cautela: ironia e contesto, profili fal-

si, **distorsioni** (se vendi a persone anziane, i social non rappresentano i tuoi clienti) e privacy.

Caso reale · Google Flu Trends: quando le ricerche ingannano (2008–2015)

Google lanciò Flu Trends nel 2008 per stimare l'influenza dalle ricerche online, più in fretta dei dati ufficiali del CDC americano. Nel 2013 la rivista Nature segnalò che il sistema stimava più del doppio delle visite mediche per sindromi influenzali rispetto al CDC. Un articolo su Science (Lazer e colleghi, 2014) calcolò che tra agosto 2011 e settembre 2013 aveva sovrastimato l'influenza in 100 settimane su 108. Cause: le ricerche dipendono anche dalle notizie e dalla paura, e Google stesso cambiava il motore di ricerca. Il servizio fu chiuso nel 2015. Gli autori chiamano il problema *big data hubris*: credere che tanti dati sostituiscano i dati raccolti con metodo.

Big data hubris: il caso Google Flu Trends (University of Washington) · apri su YouTube

:::

Prova tu **Un'azienda di apparecchi acustici vuole capire la soddisfazione dei clienti solo da TikTok. Che cosa non va?**

Un'API ti fa risparmiare, ma ti lega a qualcun altro

Un'**API** (*Application Programming Interface*) è la porta controllata con cui un sistema chiede dati o servizi a un altro: meteo, mappe, tassi di cambio, pagamenti, dati pubblici. È un contratto: dice che cosa puoi chiedere (tutto, solo una parte filtrata, oppure aggiornare un dato) e in che formato riceverai la risposta.

Perché conviene: se fai una startup di trasporti, non ricostruisci Google Maps, lo usi tramite API. E non ti interessa come è fatto dietro: se domani il fornitore cambia tecnologia, per te non cambia nulla finché l'API resta uguale. Un'API ser-

ve anche a condividere **solo i dati necessari**: un ospedale può comunicare data e tipo di intervento senza passare l'intera cartella clinica.

Campana chiede tre domande prima di dipendere da un'API:

1. **Chi possiede il servizio?** Se il fornitore fallisce o viene comprato da un altro, il tuo prodotto si ferma.
2. **Quali sono i limiti d'uso?** Prezzi e quote cambiano: molte aziende hanno adottato servizi di AI a consumo e solo dopo si sono accorte di quanto costavano.
3. **Come vengono gestiti i cambiamenti?** Una nuova versione può rompere la tua applicazione; una versione vecchia può avere problemi di sicurezza da correggere.

Caso reale · Google Maps alza il prezzo (2018)

Nel giugno-luglio 2018 Google ha riorganizzato le API di mappe nella Google Maps Platform: la fatturazione è diventata obbligatoria per tutti, con un credito gratuito di 200 dollari al mese. Per molti piccoli siti bastava; per chi faceva molte richieste i costi sono saliti di colpo, e la sola richiesta di una carta di credito ha spinto diversi sviluppatori a valutare alternative aperte come OpenStreetMap. È l'esempio perfetto delle domande 1 e 2: il servizio è di un altro, e le condizioni le decide lui.

Poi Campana tira le fila con un gioco: scegli un'azienda e tre fonti da combinare. La tabella della slide 11 riassume:

Fonte	Struttura	Velocità	Valore	Limite
Transazioni	strutturata	alta	eventi reali	poco contesto
ERP/CRM	strutturata	media	visione azienda e cliente	silos, definizioni diverse
Sensori/IoT	semi-strutturata	altissima	monitoraggio fisico	rumore, guasti
Social	non strutturata	alta	opinioni, trend	distorsioni
API	di solito semi-strutturata	variabile	dati e servizi esterni	dipendenza dal fornitore

Esempio svolto · Le creme solari (esempio di Campana)

1. Fonti: transazioni (vendite per zona), social (si parla di un'ondata di caldo), API meteo (previsioni di temperature alte in Italia).
2. Decisione: spostare in anticipo più creme solari nei magazzini italiani.
3. Vantaggio: agisci prima, non rincorri la domanda.
4. Rischio: se l'ondata di caldo non arriva, hai merce ferma nel posto sbagliato. Più fonti riducono l'incertezza, non la eliminano.

L'idea in una frase

Nessuna fonte dà la visione completa: il valore nasce dal combinarne alcune intorno a una decisione precisa.

Prova tu **Una startup costruisce tutto su un'API gratuita di un concorrente più grande. Qual è il rischio peggiore?**

Batch o streaming: scegli la velocità che la decisione richiede

L'ultima idea di Campana è la più importante per l'esame: la **finestra di decisione**, cioè il periodo in cui un'informazione può ancora cambiare l'esito. Fuori da quella finestra il dato è inutile. Le finestre cambiano molto:

- **giorni**: redditività mensile, decisioni finanziarie di lungo periodo;
- **ore**: aggiornare le scorte di magazzino;
- **minuti**: seguire le consegne (sapere ore dopo che un camion era fermo non serve a niente);
- **millisecondi**: bloccare una frode con carta prima che il danno avvenga.

Da qui due modi di elaborare. Il **batch** (a lotti): raccogli i dati, li archivi, a un orario fisso (ogni ora, notte, settimana, mese) parte un lavoro programmato che trasforma, controlla e produce report. Pro: efficiente sui grandi volumi, semplice da testare e verificare, costa meno (il server lavora solo quando serve). Contro: latenza alta, informazioni vecchie, problemi che restano nascosti fino al ciclo successivo (se il batch gira il lunedì, l'errore di martedì lo scopri sei giorni dopo). Esempi: buste paga, saldi giornalieri dei conti, report mensili, segmentazione settimanale dei clienti.

Lo **streaming** (in flusso): gli eventi arrivano di continuo e vengono analizzati appena arrivano, per un'azione immediata (un allarme, un blocco, una raccomandazione). Pro: intervento rapido, monitoraggio continuo, automazione. Rischi: eventi **in ritardo o duplicati** (un utente impaziente clicca "paga" quattro volte: il sistema deve capire che è una sola richiesta), più complessità tecnica, e gli **errori si propagano subito** nella dashboard o nel robot, senza il tempo di correggerli che il batch concede. Esempi: frodi nei pagamenti, monitoraggio dei pazienti, tracciamento dei veicoli, anomalie delle macchine.

Tra i due estremi ci sono vie di mezzo: *real-time* (millisecondi-secondi, autorizzazione del pagamento), *near-real-time* (secondi-minuti, dashboard operative),

micro-batch (lotti piccoli ogni pochi minuti, analisi del sito web), *offline* (ore-giorni, bilanci). La slide 16 lo dice in una frase: **tempo reale significa abbastanza veloce per la decisione**.

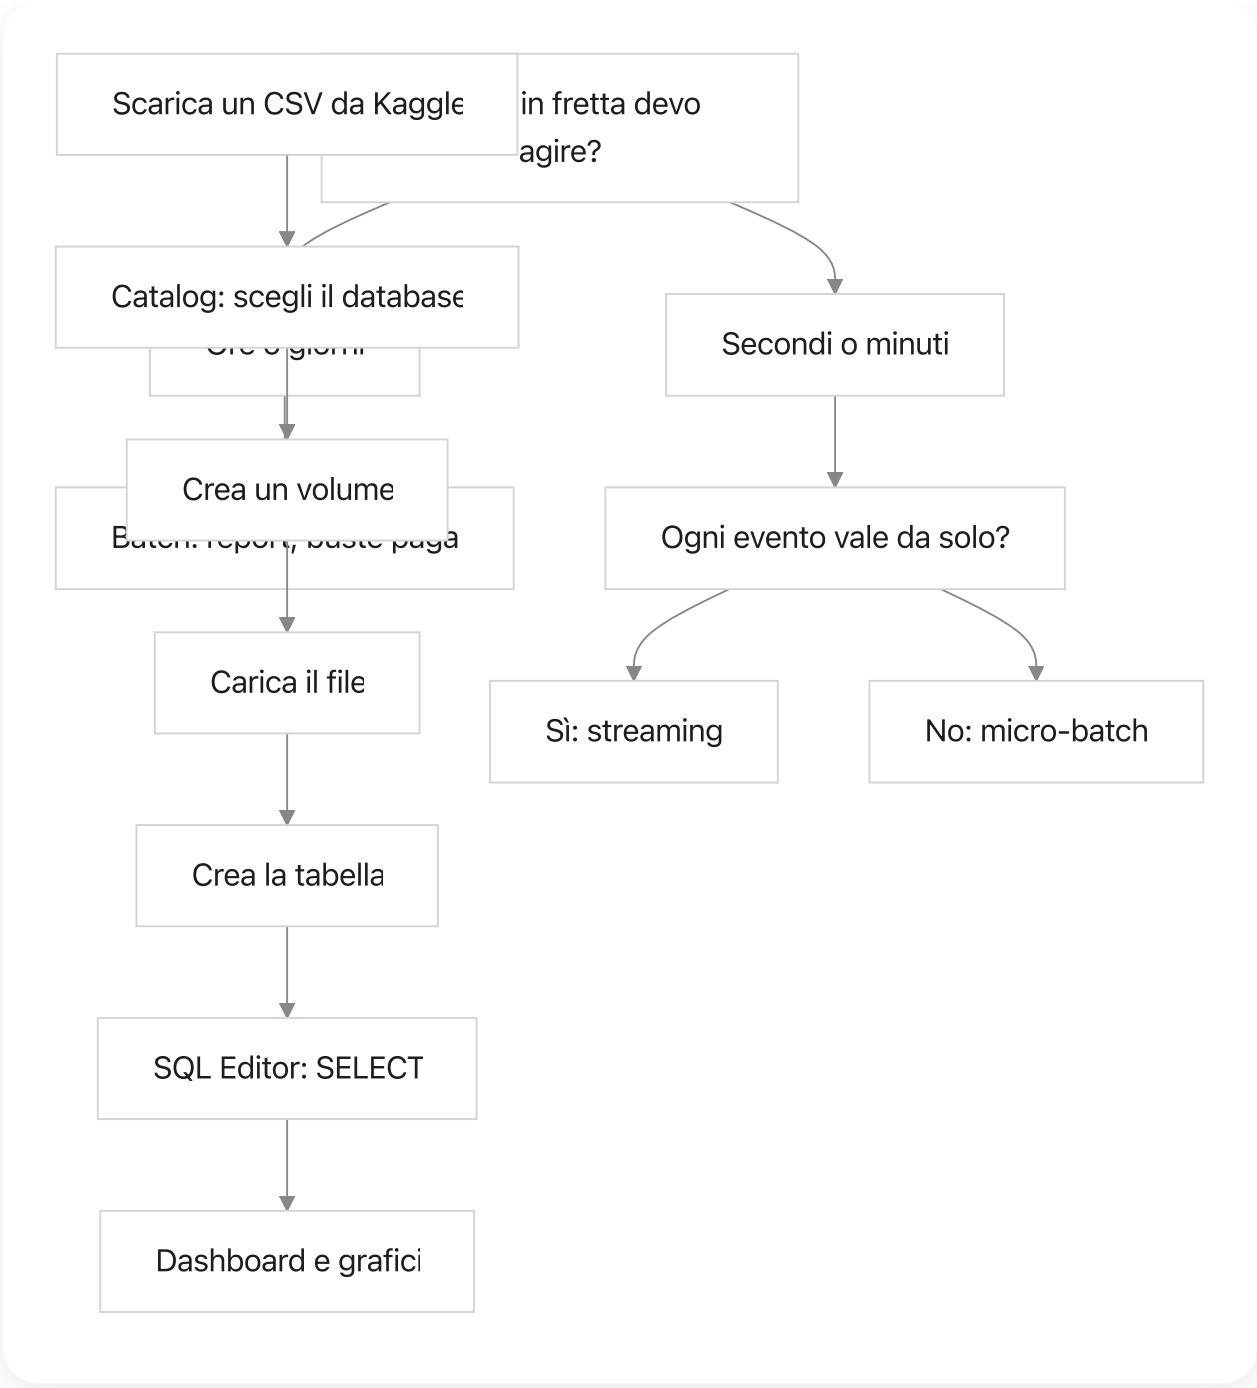
Caso reale · Visa: un punteggio di rischio per ogni transazione

Visa usa un sistema chiamato Visa Advanced Authorization che, mentre un pagamento viene autorizzato, gli assegna un punteggio di rischio frode calcolato da modelli di AI su centinaia di attributi. Secondo quanto riportato da CSO Online, il punteggio arriva in circa 300 millisecondi e nel 2021 il sistema avrebbe evitato frodi per 26 miliardi di dollari (cifre dichiarate dall'azienda). È lo streaming nella sua forma più pura: la banca decide se accettare il pagamento prima che il cliente esca dal negozio. Le stesse transazioni, però, finiscono anche in batch: nella riconciliazione contabile e nel riaddestramento dei modelli.

Batch e streaming con esempi pratici (Andreas Kretz) · apri su YouTube

:::

Le due strade non sono rivali. Nell'esempio retail della slide 17, lo stesso flusso di eventi (ordine, pagamento, spedizione, navigazione, recensione) va in due direzioni: lo **streaming** per la frode e per suggerire subito un prodotto (hai comprato un computer nuovo? forse ti serve un monitor), il **batch** per riconciliare ordini e pagamenti a fine mese e per i report di redditività. La maggior parte delle aziende ha bisogno di entrambi.



Per scegliere, Campana usa quattro trade-off (slide 18): **costo** (infrastruttura sempre accesa, competenze specialistiche), **velocità** (quanto in fretta l'informazione deve sostenere l'azione), **rischio** (errori di automazione, eventi persi, guasti del servizio), **usabilità** (risultati chiari, allarmi gestibili). La domanda finale: *una latenza più bassa crea abbastanza valore da giustificare costo e rischio in più?* E un'avvertenza: "troppo caro" non esiste in assoluto; se l'opzione economica ti fa perdere più soldi, era quella cara.

Laboratorio · Conviene passare le frodi allo streaming?

Frodi al mese:

120

Perdita media per frode (€):

400

Frodi bloccate in tempo dallo streaming (%):

60

Costo extra dello streaming al mese (€):

15000

Perdite evitate al mese: **28.800 €** · Saldo netto: **+13.800 €**

Lo streaming si ripaga: la latenza bassa crea più valore di quanto costa.

Numeri illustrativi, non di una banca reale. Con il batch la frode si scopre a cose fatte, quindi qui si assume che il batch non ne blocchi nessuna in tempo.

La sfida in classe (slide 19) chiedeva di classificare sei casi. Le risposte: buste paga → **batch** (si fanno a fine mese); frode con carta → **streaming**; segmentazione dei clienti per il marketing → **batch** (è una fotografia della base clienti, non una raccomandazione istantanea); monitoraggio dei pazienti in ospedale → **streaming** ("altrimenti il paziente può morire"); riconciliazione delle vendite → batch; tracciamento delle consegne → streaming o near-real-time.

Prova tu **Un'app di consegne calcola ogni notte i tempi medi per quartiere e intanto segue i rider via GPS. È batch o streaming?**

Dal caso al progetto: la mappa dei dati di un centro fitness

Il Team Work 2 di Rizzi mette tutto in pratica. Scenario: siete un piccolo team di consulenza per un centro fitness con abbonamenti, corsi, personal training, app e valutazioni del benessere. La consegna (slide 45):

1. Una **tabella dei touchpoint** (8–10 righe): punto di contatto, dati raccolti, fonte, uso di business.
2. Una **mappa dei dati**: un disegno semplice di come l'informazione si muove nel centro.
3. **Rischi e opportunità**: due problemi di qualità dei dati, un rischio privacy, due opportunità di business.
4. Pitch volontario di 5 minuti.

Esempio svolto · Quattro righe della tabella dei touchpoint (le prime due sono quelle della slide)

Touchpoint	Dati raccolti	Fonte	Uso di business
Visita al sito	pagine viste, click, dispositivo	web analytics	misurare l'interesse
Iscrizione	età, contatti, tipo di abbonamento	CRM	gestire i soci
Ingresso con badge	ora e giorno di accesso	tornelli (sensore)	prevedere l'affollamento
Prenotazione corso in app	corso, orario, cancellazioni	app	ottimizzare l'orario dei corsi

Qualità: chi si iscrive due volte con email diverse diventa due soci; badge prestati falsano le presenze. Privacy: i dati di salute delle valutazioni (peso, pressione) sono dati sensibili per il GDPR e richiedono consenso esplicito. Opportunità: consigliare gli orari meno affollati; prevedere chi sta per disdire (presenze in calo) e offrirgli una sessione con un trainer.

Dalle presentazioni sono emerse idee concrete: suggerire orari e sedi ai soci con turni di lavoro che cambiano, unire i dati delle prenotazioni a quelli dei personal trainer per capire quali corsi trattengono di più i clienti. Rizzi ha fatto notare due cose: i dati devono essere **facili da raccogliere** (se il socio deve inserirli a mano, non lo farà; meglio dedurli dagli ingressi e dalle macchine) e per i dati di allenamento e salute serve **il consenso**.

Prova tu **Nella tua tabella dei touchpoint metti il "battito cardiaco dal cardiofrequenzimetro del tapis roulant". Che cosa devi aggiungere prima di usarlo?**

Databricks: un solo posto per conservare, interrogare e far lavorare i dati

L'ultima parte della lezione è pratica: Campana apre **Databricks**, la piattaforma che userete per tutto il corso. La registrazione si ferma dopo le prime frasi, quindi questa sezione segue le slide 20–29 passo per passo e aggiunge le spiegazioni che servono per capirle.

La slide 21 la definisce così: *Databricks = Analytics + AI + (dati, strumenti e altro)*, una **piattaforma unificata e aperta** per costruire, mettere in produzione, condividere e mantenere dati, analisi e soluzioni di AI su scala aziendale. In pratica: invece di avere un programma per pulire i dati, un altro per i grafici e un altro ancora per i modelli, fai tutto nello stesso ambiente, sugli stessi dati.

L'idea in una frase

Databricks è una "cucina unica" dei dati: lo stesso dato entra una volta e da lì lo puliscono gli ingegneri, lo interrogano gli analisti e lo usano i modelli di machine learning.

I quattro pilastri (slide 22):

- **Unificata**: data engineering (preparare i dati), data science, machine learning e *business intelligence* (BI, i report e le dashboard per chi decide) in un solo posto.
- **Collaborativa**: i *notebook* (documenti in cui alterni codice, risultati e note) sono condivisi in tempo reale tra i membri del team, come un Google Doc per l'analisi.
- **Scalabile**: è *cloud-native*, cioè gira sui grandi cloud (AWS di Amazon, Azure di Microsoft, Google Cloud). Se i dati crescono, si affitta più potenza di calcolo invece di comprare server.

- **Aperta**: è costruita su progetti *open source* (codice libero, usabile da tutti): **Apache Spark** per elaborare enormi quantità di dati dividendo il lavoro tra tante macchine, **Delta Lake** per rendere affidabili i file di un data lake, **MLflow** per tenere traccia degli esperimenti di machine learning.

Caso reale · Da un laboratorio di Berkeley a piattaforma gratuita per studenti

Databricks nasce nel 2013 da sette ricercatori dell'AMPLab dell'Università di Berkeley, gli stessi che avevano creato Apache Spark; in seguito l'azienda ha lanciato anche Delta Lake e MLflow come progetti open source. L'11 giugno 2025, al Data + AI Summit di San Francisco, ha presentato la **Free Edition**, una versione gratuita per studenti e principianti, insieme a un investimento di 100 milioni di dollari nella formazione su dati e AI. È la versione che si vede nelle slide ("databricks Free Edition" nel logo) e che usate in classe: gratuita, pensata per imparare, non per uso commerciale. La strategia è chiara: chi impara su una piattaforma all'università tende a portarla in azienda.

Il piano della giornata (slide 23) era: visitare il sito, registrarsi, esplorare la Free Edition, orientarsi tra strumenti e funzioni, visualizzare un primo campione di dati. Le slide 25–27 sono la mappa del menu laterale:

Voce del menu	A che cosa serve
Home	la tua cartella personale, accesso rapido alle risorse
Learn	la Databricks Academy, con brevi tutorial
Workspace	l'esplora-file completo (notebook, cartelle)
Recents	le ultime attività
Catalog	sfogliare database, tabelle e lo spazio Delta Lake
Jobs & Pipelines	collegare e programmare i passaggi (es. un batch ogni notte)
Compute	la potenza di calcolo che fa girare analisi e modelli
Discover / Marketplace	modelli pronti e dati o strumenti di aziende partner

Nella sezione **SQL** ci sono gli strumenti per gli analisti. *SQL* (*Structured Query Language*) è il linguaggio standard per fare domande a una tabella di dati. Il *SQL Editor* è dove scrivi le domande (*query*); *Queries* conserva quelle salvate con un nome; *Dashboards* le trasforma in grafici; *Alerts* manda una notifica o lancia una query quando succede qualcosa (per esempio, scorte sotto soglia); *Query History* è la cronologia; i *SQL Warehouses* sono i motori di calcolo dedicati alle query. Le slide citano anche i *Genie Agents*, assistenti AI a cui fai la domanda in linguaggio naturale ("quanti clienti abbiamo perso a marzo?") e che scrivono la query per te.

La slide 27 aggiunge, "giusto per sapere", due aree che userete più avanti: **Data Engineering** (Runs, Data Ingestion, Visual Data Prep: le trasformazioni dei dati dall'inizio alla fine) e **AI/ML** (Playground, Agents, Experiments, Features, Models, Serving: tutto il ciclo di vita di un modello, dalla prova alla messa in produzione).

Giro guidato di Databricks Free Edition (Alex The Analyst) · apri su YouTube

:::

Infine, i **dati**. La slide 28 lo dice con una battuta: tutto questo funziona solo con i dati, e meglio di tanti dati ci sono… più dati, purché di buona qualità. Una fonte comoda per esercitarsi è **Kaggle**, la piattaforma di Google per competizioni di data science, dove si scaricano dataset gratuiti in formato CSV (una tabella in testo semplice, con i valori separati da virgole).

Esempio svolto · Dal file alla prima risposta (procedura delle slide 29)

1. Apri **Catalog** e scegli il database di lavoro.
2. Crea un **volume**: lo spazio in cui conservare file "grezzi" (CSV, JSON, immagini) dentro il catalogo, con permessi controllati.
3. Importa il file CSV (o un altro formato, o un connettore verso un'altra fonte).
4. Da **Create → Table** scegli il file: Databricks mostra un'anteprima e ti fa correggere nomi e tipi delle colonne (numero, testo, data).
5. Apri il **SQL Editor** e chiedi tutto il contenuto: `SELECT * FROM nome_tabella` (oppure leggi direttamente il file con il suo percorso nel volume).
6. Ora puoi filtrare, per esempio i film con più di 5 candidature agli Oscar: `SELECT titolo FROM oscar WHERE candidature > 5` (esempio ipotetico), e trasformare il risultato in un grafico.

Le query SQL partendo dalle basi (Aulab) · apri su YouTube

:::

Collegamento · Batch, streaming e Databricks

I due modi di elaborare visti con Campana vivono entrambi qui: con **Jobs & Pipelines** programmi un batch notturno; Spark gestisce anche flussi in streaming. Il catalogo e i volumi sono il primo assaggio del *data lake* della lezione del 13 ottobre, e la pratica con dashboard e query continua il 6 ottobre.

Prova tu **Il tuo team carica lo stesso CSV di vendite in tre notebook diversi, ognuno con la sua copia modificata a mano. Che cosa perdete e come lo eviteresti in Databricks?**

Richiamo a libro chiuso

1. Spiega con l'esempio di 1.000 persone che cosa significano sensibilità 0,70 e specificità 0,64, e perché la maggior parte degli allarmi del modello sono falsi.
2. Elenca le cinque fonti di Campana e, per ciascuna, che cosa vede, quanto è veloce e qual è il suo difetto tipico.
3. Descrivi i sei passi 'detect, match, predict, act, verify, learn' del caso assicurativo e dove entra lo streaming e dove il batch.
4. Classifica a memoria buste paga, frode con carta, segmentazione clienti, monitoraggio in terapia intensiva, riconciliazione vendite e tracciamento consegne in batch o streaming, con il motivo.

Quiz

1. Un modello per un raro difetto di fabbrica (1 pezzo su 100) dichiara 'accuratezza 99%'. Perché il responsabile qualità non è convinto?

- Perché un modello che dice sempre 'pezzo buono' avrebbe già il 99% di accuratezza: servono sensibilità e specificità
- Perché servirebbe un modello di AI generativa
- Perché l'accuratezza si misura solo in medicina
- Perché il 99% è troppo alto per essere vero

2. Nello studio NACC chi ha un BMI più alto ha un rischio osservato di demenza più basso. Un'azienda di integratori vuole dire 'ingrassare protegge il cervello'. Che cosa rispondi?

- Ha ragione, il modello XGBoost lo ha dimostrato
- È vero solo per chi ha più di 80 anni
- È un'associazione, probabilmente dovuta a causalità inversa (si dimagrisce negli anni prima della diagnosi): non è una causa né un consiglio
- Ha ragione, perché anche l'analisi di sopravvivenza lo conferma

3. Una compagnia vuole prezzare le polizze grandine dei vigneti. Quale combinazione di fonti è la più utile?

- Solo i post sui social durante i temporali
- Solo le vendite di vino dell'anno precedente
- Storico dei sinistri + dati radar e satellitari sulla grandine + posizione e caratteristiche dei vigneti assicurati
- Solo l'esperienza degli agenti locali

4. Un brand di moda vede esplodere le ricerche di 'scarpe argento' per tre giorni dopo il post di una celebrità. Che cosa dovrebbe fare il team prima di produrre 100.000 paia?

- Ignorare i dati: decide solo lo stilista
- Guardare solo le vendite della collezione dell'anno scorso
- Produrre subito: il picco è il segnale più forte
- Controllare il trend momentum: se la crescita persiste e si trasforma in acquisti e pochi resi, non solo in buzz

5. Al consiglio di amministrazione il marketing dice '2.000 clienti', le vendite '1.000'. Entrambi leggono dati corretti. Qual è il problema?

- Bisogna passare allo streaming
- Servono più dati
- Uno dei due database è stato hackerato
- Definizioni diverse di 'cliente' in sistemi diversi (silos): serve una definizione comune e un identificativo condiviso

6. Un sensore segna +100 °C in due minuti su un macchinario. Che cosa fa un buon sistema?

- Confronta con altri sensori e con la storia della macchina per distinguere guasto reale da guasto del sensore, poi allerta
- Ferma subito tutta la fabbrica, sempre
- Aspetta il report mensile
- Ignora il dato: i sensori sbagliano spesso

7. **Quale di questi processi ha bisogno di streaming e non di batch?**

- Calcolare le buste paga di fine mese
- Segmentare i clienti per la campagna del trimestre
- Bloccare un pagamento con carta clonata prima che venga autorizzato
- Riconciliare ordini e pagamenti per il bilancio

8. **Una startup di consegne costruisce tutta l'app sopra l'API di mappe di un grande fornitore. Qual è il rischio principale da mettere nel business plan?**

- Le API funzionano solo in batch
- Non c'è nessun rischio: le API sono sempre gratis
- Dipendenza dal fornitore: può cambiare prezzi, limiti d'uso o versione, come Google Maps nel 2018
- Le API sono illegali in Europa

Soluzioni del quiz

1. **A** — Con eventi rari l'accuratezza è dominata dai casi negativi. La domanda giusta è: quanti difetti veri trova (sensibilità) e quanti falsi allarmi dà (specificità)? Il 99% non è impossibile, la metrica non dipende dal settore e l'AI generativa non c'entra.
2. **C** — Due metodi che trovano la stessa associazione non la trasformano in causa: è un dato osservazionale. Le stesse slide parlano di possibile causalità inversa e la Lancet Commission considera l'obesità in mezza età un fattore di rischio. Nessun dato supporta la frase sugli 80 anni.
3. **C** — Il rischio si calcola unendo pericolo (meteo), esposizione (dove sono i beni) e vulnerabilità (che danni subiscono), più lo storico per tarare il modello. I social sono distorti e parziali, l'esperienza degli agenti è l'intuito che il modello sostituisce, le vendite di vino non misurano il rischio.
4. **D** — Un picco virale spesso svanisce. La slide propone momentum = crescita × persistenza × conversione commerciale. Ignorare i dati spreca un segnale utile; guardare solo l'anno scorso non vede il cambiamento.
5. **D** — È il rischio tipico di ERP e CRM: ognuno ha la sua definizione (abbonamento pagato negli ultimi 90 giorni contro chiunque abbia scaricato un documento). Più dati o più velocità non risolvono un problema di definizione; nessun indizio di attacco.
6. **A** — I dati dei sensori sono veloci ma rumorosi: un picco può essere un guasto o un'interferenza. Il caso Lion Air 610 mostra il pericolo di fidarsi di un solo sensore. Fermare sempre costa troppo, ignorare è rischioso, aspettare un mese arriva fuori dalla finestra di decisione.
7. **C** — La frode va fermata in millisecondi, prima del danno: la finestra di decisione è minuscola. Buste paga, segmentazione e riconciliazione possono aspettare ore o giorni e conviene farle in batch, che costa meno ed è più facile da controllare.
8. **C** — Le tre domande della slide 9: chi possiede il servizio, quali sono i limiti d'uso, come vengono gestiti i cambiamenti. Nel 2018 Google ha reso obbligatoria la fatturazione per le Maps API. Le API sono legali, possono servire anche dati in tempo reale e spesso sono a pagamento.

Applica a un caso nuovo

Caso ipotetico. Una catena italiana di 40 supermercati vuole ridurre lo spreco di prodotti freschi (frutta, latticini) e le rotture di stock. Ha: casse (scontrini), un'app fedeltà, celle frigorifere con sensori di temperatura, un'API meteo, recensioni e post social. Decidi: (1) quali tre fonti combini e perché; (2) che cosa elabori in streaming e che cosa in batch; (3) un rischio di qualità dei dati e un rischio privacy; (4) come misuri se il modello di previsione delle vendite funziona.

Mostra una soluzione ragionata

Decidi tu

Il modello che vede la demenza

Lavori in una startup di salute digitale. Il team ha addestrato un modello simile a quello dello studio NACC (sensibilità 0,70, specificità 0,64) e il CEO vuole lanciare un'app a pagamento: 'scopri in 5 minuti il tuo rischio di demenza', da vendere a tutti gli over 50.

Che cosa consigli al CEO?

Lanciare subito: il modello è stato pubblicato su una rivista seria

Rischiosa. Con una prevalenza intorno al 9%, su 1.000 utenti l'app darebbe circa 330 falsi allarmi contro 63 casi veri trovati, e ne perderebbe 27. Ansia, reclami e rischio legale: lo studio stesso dice che manca una validazione esterna.

Usarlo come strumento per i medici, che lo interpretano nel contesto e lo usano per indirizzare la prevenzione (depressione, istruzione, udito, vista), dopo una validazione su pazienti italiani

Scelta solida. È il percorso 'modello → clinico → prevenzione mirata' delle slide. Il modello aiuta a fare priorità, non a dare diagnosi; la validazione su una popolazione diversa dai volontari americani dei centri NACC controlla che regga.

Abbandonare il progetto: un'AUC di 0,73 non vale niente

Rischiosa. Troppo drastico. Un modello moderato può essere utile per decidere a chi offrire prima controlli e prevenzione, se lo si usa con i limiti dichiarati.

Le metriche decidono l'uso: con eventi rari anche un modello discreto produce molti falsi allarmi. Prevedere non significa diagnosticare.

La banca e l'architettura da 2 milioni

Sei l'analista di una banca regionale. Un fornitore propone di passare tutto allo streaming in tempo reale: frodi, buste paga dei dipendenti, report per la Banca d'Italia, segmentazione clienti. Costo: 2 milioni l'anno in più.

Che cosa proponi al comitato?

Tutto in streaming: più veloce è sempre meglio

Rischiosa. Paghi latenza bassa dove non crea valore: buste paga e report mensili non migliorano se calcolati al millisecondo, e lo streaming porta eventi duplicati e errori che si propagano subito.

Streaming solo per le frodi con carta, batch per buste paga, report e segmentazione; poi misuri le frodi evitate contro il costo extra

Scelta solida. È la regola di Campana: la latenza che la decisione richiede. Le frodi hanno una finestra di millisecondi, il resto di giorni. Il confronto tra perdite evitate e costo dice se l'investimento si ripaga.

Tutto in batch: lo streaming è troppo caro

Rischiosa. Una frode scoperta il giorno dopo è già un danno. Per i pagamenti la finestra di decisione è più corta di qualsiasi batch.

Batch e streaming lavorano insieme: si sceglie per ogni decisione, chiedendosi se la velocità in più vale il costo e il rischio in più.

Da vedere

Documentario · 2022

Downfall: The Case Against Boeing

I due incidenti del 737 MAX: un sistema automatico che si fidava di un solo sensore. Il lato oscuro dei dati 'machine-generated'.

Dove: Netflix

Documentario · 2020

The Social Dilemma

Come le piattaforme raccolgono i dati generati dalle persone e li usano per prevedere e orientare i comportamenti.

Dove: Netflix

Documentario · 2020

Coded Bias

Una ricercatrice del MIT scopre che i sistemi di riconoscimento facciale sbagliano di più su donne e persone nere: dati distorti, modelli distorti.

Film · 2011

Moneyball

Una squadra di baseball povera batte le ricche usando i dati al posto dell'intuito degli osservatori: lo stesso salto degli assicuratori di Rizzi.

Flashcard

Le due 'lenti' dello studio NACC sulla demenza?

Data-driven (XGBoost + SHAP: scopre schemi complessi) e hypothesis-driven (analisi di sopravvivenza, Kaplan-Meier e Cox: misura effetti medi interpretabili). Convergono sugli stessi predittori.

I quattro segnali principali trovati dallo studio NACC?

Età, bassa istruzione, depressione, BMI (quest'ultimo con il paradosso: più alto = rischio osservato più basso).

Sensibilità in una riga?

Quota dei casi veri che il modello trova (veri positivi / tutti i positivi reali).

Specificità in una riga?

Quota dei non-casi che il modello riconosce come tali (veri negativi / tutti i negativi reali).

Che cosa misura la ROC AUC?

Quanto bene il modello ordina i rischi: 0,5 = a caso, 1 = perfetto. Nello studio NACC 0,732.

Perché un'AI generativa è difficile da spiegare secondo Rizzi?

Perché lavora per probabilità statistiche, non per deduzioni come 'A è padre di B, B è padre di C, quindi A è nonno di C'. Per questo si usano metodi come SHAP.

Le tre parti del rischio assicurativo (slide 36)?

Pericolo (hazard: il meteo), esposizione (exposure: cosa è assicurato e dove), vulnerabilità (quanto si danneggia).

Formula della perdita attesa?

Somma di P(sinistro) × gravità attesa, poi corretta per franchigie, limiti, coperture e riassicurazione.

Trend momentum nella moda?

Crescita × persistenza × conversione commerciale: distingue il picco virale dalla domanda vera.

Le quattro origini dei big data (slide 4)?

Generati da persone, da processi, da macchine, esterni.

Che cosa vede ciascuna fonte (slide 10)?

Transazioni: cosa è successo. ERP/CRM: chi e come. Sensori: condizioni fisiche. Social: contesto pubblico. API: contesto esterno.

Le tre domande da fare prima di usare un'API?

Chi possiede il servizio? Quali sono i limiti d'uso (e i costi)? Come vengono gestiti i cambiamenti di versione?

Vantaggi e limiti del batch?

Pro: efficiente sui grandi volumi, facile da testare e verificare, costa meno. Contro: alta latenza, informazioni vecchie, problemi nascosti fino al ciclo dopo.

Vantaggi e rischi dello streaming?

Pro: intervento rapido, monitoraggio continuo, automazione. Contro: eventi in ritardo o duplicati, più complessità, gli errori si propagano subito.

I quattro pilastri di Databricks (slide 22)?

Unificata (engineering, data science, ML e BI insieme), collaborativa (notebook condivisi), scalabile (cloud: AWS, Azure, GCP), aperta (Spark, Delta Lake, MLflow).

La regola finale di Campana per scegliere?

Scegli la latenza che la decisione richiede: chiediti se una latenza più bassa crea abbastanza valore da giustificare costo e rischio in più.

Glossario

Predictive model · modello predittivo

Modello che stima la probabilità di un evento futuro a partire da dati passati. Esempio: la probabilità che un campo venga colpito dalla grandine nei prossimi 12 mesi.

Gradient boosting / XGBoost · potenziamento a gradiente

Tecnica che costruisce tanti piccoli alberi decisionali in fila, ognuno corregge gli errori del precedente. XGBoost è la versione più usata. Esempio: il modello sulla demenza dello studio NACC.

Sensitivity · sensibilità

Su 100 persone che hanno davvero l'evento, quante il modello ne segnala. Esempio: sensibilità 0,70 = trova 70 malati su 100.

Specificity · specificità
Su 100 persone che NON hanno l'evento, quante il modello riconosce come sane. Esempio: specificità 0,64 = 64 sani su 100 non ricevono un falso allarme.

ROC AUC · area sotto la curva ROC
Numero tra 0,5 (a caso) e 1 (perfetto) che dice quanto bene il modello mette i casi veri sopra i non-casi nella classifica di rischio. Esempio: 0,73 = discreto, non ottimo.

SHAP · valori di Shapley per spiegare
Metodo che a posteriori stima quanto ogni variabile ha spinto in su o in giù la previsione. Esempio: per una persona l'età pesa molto, l'istruzione poco. Spiega il modello, non prova cause.

Reverse causation · causalità inversa
Quando è l'effetto a generare la presunta causa. Esempio: la demenza in arrivo fa perdere peso, quindi il peso basso sembra 'causare' la demenza.

Expected loss · perdita attesa
Somma su tutte le polizze di probabilità di sinistro × danno atteso. Esempio: 2% × 10.000 € = 200 € per polizza.

ERP (Enterprise Resource Planning) · gestionale delle risorse
Sistema che registra l'esecuzione: finanza, magazzino, acquisti, produzione. Esempio: SAP che segna l'ordine e la fattura.

CRM (Customer Relationship Management) · gestione delle relazioni con i clienti
Sistema che segue contatti, opportunità e interazioni con i clienti. Esempio: Salesforce che ricorda quando hai chiamato un cliente e com'è andata.

IoT (Internet of Things) · internet delle cose
Oggetti con sensori collegati in rete che mandano misure continue. Esempio: un motore che invia temperatura e vibrazioni ogni secondo.

API (Application Programming Interface) · interfaccia di programmazione
Porta controllata con cui un sistema chiede dati o servizi a un altro secondo regole fisse. Esempio: un'app di consegne che chiede a Google Maps il percorso.

Batch processing · elaborazione a lotti

I dati si accumulano e vengono elaborati tutti insieme a orari fissi (ogni notte, ogni mese). Esempio: le buste paga di fine mese.

Stream processing · elaborazione in flusso

Ogni evento viene analizzato appena arriva, per agire subito. Esempio: bloccare un pagamento sospetto prima che venga autorizzato.

Decision window · finestra di decisione

Il periodo in cui un'informazione può ancora cambiare l'esito. Esempio: per una frode con carta sono millisecondi, per un bilancio sono giorni.

Video consigliati

#3 Le parole dell'epidemia: test diagnostici, sensibilità e specificità

Scienze Statistiche Unipd · 6 min · IT

Sensibilità e specificità spiegate da statistici dell'Università di Padova: proprio le metriche che Rizzi confonde a voce.

Inside the Secret World of Zara

Bloomberg Originals · 10 min · EN

Come Zara legge la domanda e cambia la produzione in poche settimane: il caso moda di Rizzi visto da dentro.

Cos'è l'Internet of Things? Scopri la rete che entra negli oggetti

Registroit · 5 min · IT

Il Registro .it (CNR) spiega in italiano sensori e oggetti connessi, la fonte 'machine-generated' di Campana.

Calling Bullshit 5.3: Big Data Hubris

UW Information School · 6 min · EN

Il fallimento di Google Flu Trends raccontato da due professori dell'Università di Washington: perché i dati generati dalle persone ingannano.

Stream vs Batch processing explained with examples

Andreas Kretz · 9 min · EN

Batch e streaming con esempi concreti da un data engineer: ripassa la seconda metà della lezione di Campana.

Intro to Databricks (Free Edition) | UI Walkthrough

Alex The Analyst · 11 min · EN

Il giro del menu di Databricks Free Edition che le slide 25–27 descrivono, cliccato dal vivo.

QUERY SQL: parti dalle BASI

Aulab · 11 min · IT

SELECT, FROM, WHERE spiegati in italiano: le prime query che scrivi nel SQL Editor.

Fonti

1. Registrazione PLAUD parte 1 — Rizzi (of_35d557621cb38a8488b7d64f02cb079b) — 10:03, 91 min: piano della lezione (0–3′), demenza (3–23′), grandine e alluvioni per le assicurazioni (23–38′), Refik Anadol (38–45′), moda e Zara (45–55′), consegna Team Work 2 (55–58′), lavoro a gruppi con conversazioni private non usate (58–82′), presentazioni (82–90′).
2. Registrazione PLAUD parte 2 — Campana (of_7ab7a081aa2952ef1cbbfc3d371cb0d9) — 12:03, 62 min, inizio mancante: metafora del maiale e dati come risorsa (0–6′), quattro origini dei dati (6–9′), transazioni (9–13′), ERP/CRM (13–17′), sensori (17–21′), social (21–24′), API (24–31′), gioco sulle fonti (32–40′), tabella riassuntiva (40–42′), finestra di decisione (42–45′), batch (45–48′), streaming (48–51′), dal tempo reale all'offline e lavoro insieme (51–54′), trade-off e sfida in classe (54–60′), inizio Databricks (60–62′).
3. Slide Canvas — Rizzi, BigDataBsnsRizzi2026Lesson2 (45 pagine) — Fonti pp. 2–11, batch/streaming pp. 12–19, Databricks pp. 20–29, casi pp. 30–43, Team Work 2 pp. 44–45.
4. Arnold D. et al. (2025), Stratifying dementia risk factors: A prediction model and hypothesis-driven analysis, Alzheimer's & Dementia 21(10): e70870
5. Livingston G. et al. (2024), Dementia prevention, intervention, and care: 2024 report of the Lancet standing Commission, The Lancet 404: 572–628
6. Alzheimer Europe — la Lancet Commission 2024 e i 14 fattori modificabili (circa 45% dei casi potenzialmente prevenibili o ritardabili)
7. ESSL — chicco di grandine di 19 cm confermato ad Azzano Decimo, 24 luglio 2023
8. Howden Italia su dati ANIA — premi assicurativi 2024 pari a circa il 6,9% del PIL
9. DATALAND — Refik Anadol, Machine Dreams: Rainforest (Los Angeles)
10. RetailDetail — chiude il primo negozio Zara, aperto ad A Coruña nel 1975

11. Modaes — la produzione di prossimità di Inditex (Spagna, Portogallo, Marocco, Turchia)
12. Lazer D., Kennedy R., King G., Vespignani A. (2014), The Parable of Google Flu: Traps in Big Data Analysis, Science 343: 1203–1205
13. BBC News — rapporto finale KNKT su Lion Air 610: una serie di errori, tra cui sensore AoA e MCAS
14. Geoawesomeness — la reazione degli sviluppatori al cambio di prezzi delle Google Maps API (2018)
15. CSO Online — How Visa fights fraud (Visa Advanced Authorization, punteggio di rischio in tempo reale)
16. Databricks — comunicato: lancio della Free Edition e investimento di 100 milioni in formazione (11 giugno 2025)
17. Databricks — press kit: fondata nel 2013 da sette ricercatori dell'AMPLab di Berkeley, creatori di Spark, Delta Lake e MLflow
18. Regolamento (UE) 2016/679 (GDPR), art. 5 — minimizzazione dei dati

Note di verifica