06 ottobre 2026

Dentro il motore dell'AI: come imparano le macchine, come un LLM sceglie la parola dopo, e una dashboard che racconta una storia

Foundation in Big Data — Lesson 3: Machine Learning, Predictive & Generative AI, LLMs, Data Lakes + Team Work 3 'Dashboarding Oscars'

Martedì · Rizzi, Campana · Completa

Due registrazioni PLAUD: parte 1 (Rizzi, 10:03, 87 min) quasi tutta lezione frontale su modalità d'esame, uso dell'AI, machine learning, tipi di apprendimento, Absolute Zero Reasoner, reti neurali e LLM; parte 2 (Campana, 12:03, 88 min) laboratorio a squadre 'Dashboarding Oscars' su Databricks: poche istruzioni del docente, molto lavoro di gruppo e conversazioni non didattiche (saltate), alcune presentazioni finali. Slide Canvas 'BigDataBsnsRizzi2026Lesson3' (55 pagine, nel file del corso dal 6/10): pp. 3–35 svolte a voce da Rizzi; pp. 36–48 (data lake) solo nelle slide, non spiegate a voce e qui spiegate dal testo delle slide; pp. 49–55 = consegna del laboratorio di Campana. Le slide-immagine 13, 15, 18, 21–23, 25–27, 29 sono state guardate come immagine; i due 'giochi' interattivi delle pp. 14 e 16 (link esterni) non sono stati aperti. Audio della parte 1 spesso confuso: alcuni passaggi sono ricostruiti dal contesto e dalle slide.

In breve

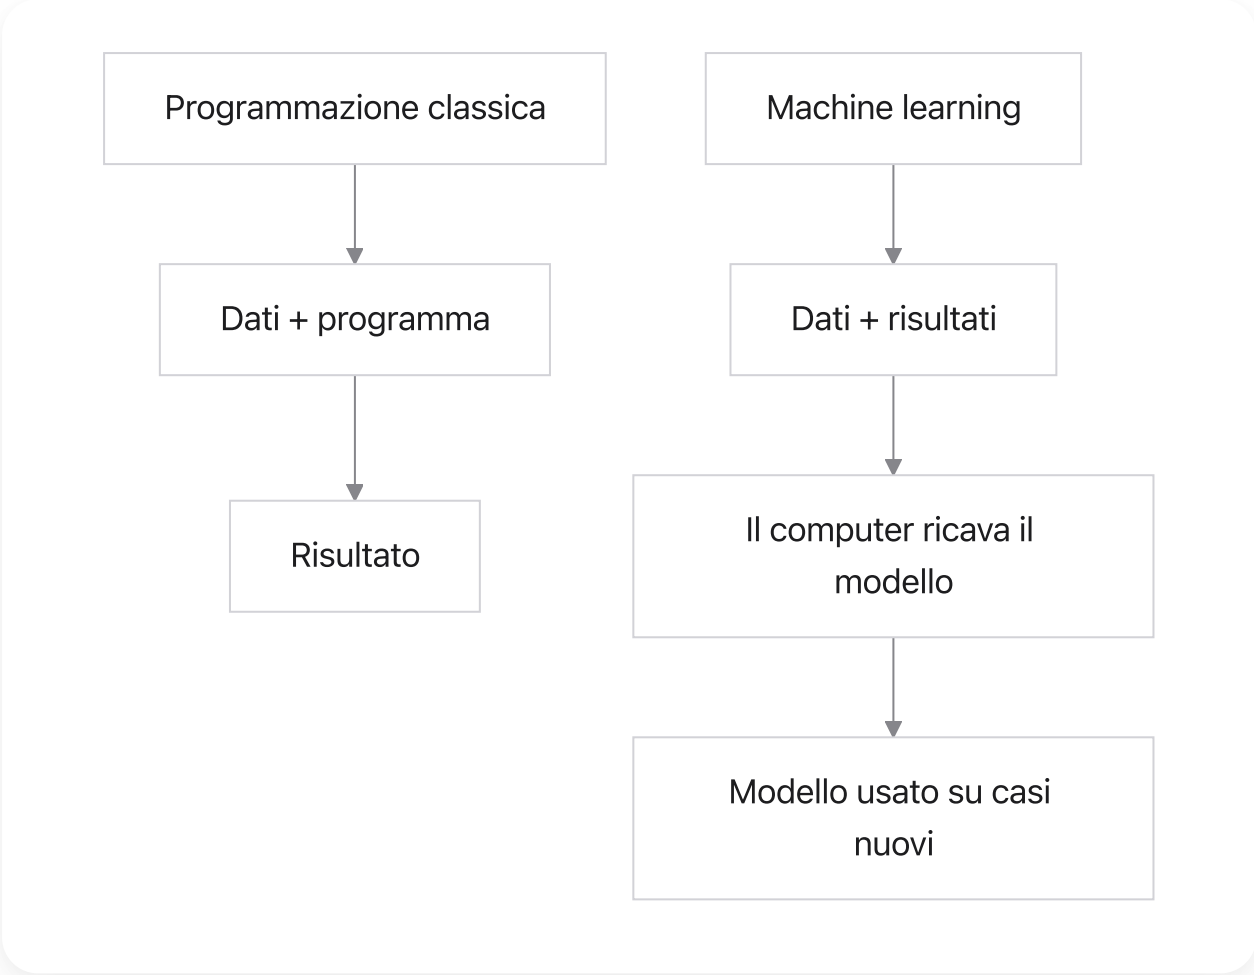
Rizzi apre il "cofano" dell'intelligenza artificiale. Il machine learning ribalta la programmazione classica: invece di scrivere le regole, dai al computer dati ed esempi di risultato e lui ricava il modello. Si impara in quattro modi (supervisionato, non supervisionato, semi-supervisionato, per rinforzo) e ora si sperimenta un quinto, in cui il modello si inventa da solo gli esercizi. Un LLM, visto da dentro, fa due cose semplici: spezza il testo in token e sceglie la parola successiva più probabile. Nella seconda parte Campana fa costruire a squadre una dashboard su Databricks: conta la domanda giusta, non il numero di grafici.

- Programmazione classica: dati + programma → risultato. Machine learning: dati + risultati → il computer ricava il programma (il modello).
- Un problema di ML è ben definito solo se dici T (compito), P (come misuri il successo) ed E (da quali dati impara).
- Il ML conviene se il compito si ripete, l'errore costa poco, serve su larga scala e le regole cambiano; non funziona dove non c'è un pattern (Superenalotto).
- Supervisionato = dati con etichette; non supervisionato = senza etichette, cerca gruppi; semi-supervisionato = poche etichette (raccomandazioni Netflix); rinforzo = tentativi e ricompense (Pac-Man).
- L'AI è una matrioska: AI ⊃ machine learning ⊃ deep learning ⊃ AI generativa ⊃ LLM. La generativa non è sempre la scelta migliore.
- Un albero di classificazione spiega le sue decisioni; una rete neurale profonda funziona con milioni di pesi illeggibili (scatola nera).
- Un LLM tokenizza il testo e genera un token alla volta scegliendo tra parole candidate con probabilità diverse; la temperatura decide quanto rischiare.
- Prima della dashboard viene la domanda: scegliere i dati, capirli, decidere l'insight, disegnare la storia, costruire solo ciò che serve. Correlazione non è causa.

Il machine learning serve quando le regole non si sanno scrivere

Per cinquant'anni l'informatica ha funzionato così: una persona scrive un *programma* (una lista di regole), il computer lo applica ai dati e produce un risultato. Vuoi sapere se un numero è primo? Scrivi le regole, inserisci il numero, il computer risponde.

Il *machine learning* (ML, apprendimento automatico) ribalta lo schema. Dai al computer i dati **e** i risultati giusti, e lui ricava la regola. Quella regola ricavata si chiama *modello*. È lo schema più importante della giornata.



Quando conviene? Ci sono quattro situazioni tipiche:

1. **Non esiste esperienza umana**: nessuno era mai atterrato sulla Luna, quindi nessuno sapeva scrivere le regole in anticipo.
2. **Gli umani non sanno spiegare quello che sanno fare**: capiamo la voce di un amico al telefono, ma non sappiamo scrivere le regole del perché.
3. **Il modello va personalizzato**: la medicina personalizzata adatta la cura al singolo paziente.
4. **I dati sono enormi**: nella genomica nessun essere umano può guardare miliardi di dati a mano.

A queste si aggiungono quattro condizioni pratiche perché un progetto di ML abbia senso in azienda: il compito si **ripete** (arrivano sempre casi nuovi), l'**errore costa poco** (un film consigliato male non è un dramma), serve **su larga scala** (il modello lavora 24 ore su 24) e i **pattern cambiano** (gli esperti non riescono a tenere aggiornate le regole).

E quando non funziona? Prova a chiederti se si possa prevedere il Superenalotto. Risposta: no. Le estrazioni sono *eventi indipendenti*: il numero uscito ieri non dice nulla su quello di domani. Se dai a un modello trent'anni di estrazioni, non trova niente, perché non c'è niente da trovare. Per la Borsa il discorso è simile, anche se meno netto: i prezzi sono in larga parte imprevedibili e molti tentativi di "battere il mercato" con l'AI falliscono.

L'idea in una frase

Il machine learning non crea informazione: trova pattern che esistono già nei dati. Se il pattern non c'è, nessun modello lo inventa.

Caso reale · La matematica che ha portato l'Apollo sulla Luna

Rizzi racconta che due ricercatori della NASA svilupparono un metodo che "imparava" durante la discesa verso la Luna, in un ambiente sconosciuto. Il fatto storico dietro questo racconto è il *filtro di Kalman*. Nel 1960 il matematico Rudolf Kálmán pubblicò un metodo per stimare la posizione e la velocità di un oggetto aggiornando la stima ogni volta che arriva una nuova misura. Stanley Schmidt, a capo di un reparto del centro NASA Ames in California, capì come adattarlo al problema non lineare delle traiettorie lunari. La versione di Schmidt finì nel computer di navigazione delle missioni Apollo, e la stessa matematica oggi serve al controllo del traffico aereo. Attenzione: non è l'atto di nascita del machine learning (il termine lo usa Arthur Samuel nel 1959 per un programma che imparava a giocare a dama). Ma l'idea è la stessa: un sistema che corregge sé stesso con i dati che arrivano.

Prova tu **Un'azienda deve applicare l'aliquota IVA giusta a ogni fattura. Le serve un modello di ML?**

Un problema di machine learning si definisce con tre lettere: T, P, E

"Usiamo l'AI" non è un progetto. Per renderlo un progetto serve la definizione che Tom Mitchell ha dato nel suo manuale del 1997: un programma **impara** se migliora in un compito **T** (*task*), misurato da **P** (*performance*), grazie all'esperienza **E** (*experience*). Prima di Mitchell, Herbert Simon aveva detto la stessa cosa in modo più semplice: imparare è migliorare grazie all'esperienza.

Quattro esempi classici:

Compito T	Misura P	Esperienza E
Giocare a dama	% di partite vinte	partite giocate contro sé stesso
Riconoscere parole scritte a mano	% di parole riconosciute	foto di parole etichettate da persone
Guidare in autostrada con telecamere	km percorsi prima di un errore	immagini e sterzate di un guidatore umano
Separare spam e posta buona	% di email classificate bene	archivio di email, alcune etichettate

Funziona anche con gli scacchi. Il compito è giocare, la misura è vincere, l'esperienza sono le partite passate e le strategie. Il numero di partite possibili è astronomico (la stima classica di Claude Shannon è circa 10^120), quindi nessun essere umano può esplorarle tutte.

Caso reale · Deep Blue contro Kasparov, 1997

Nel maggio 1997, a New York, il computer Deep Blue di IBM vinse una sfida di sei partite contro il campione del mondo Garry Kasparov: 3½ a 2½. Era la prima volta che una macchina batteva il campione del mondo in un match regolare. Kasparov accusò IBM di aver aiutato la macchina con interventi umani e chiese la rivincita, ma IBM ritirò Deep Blue. Per precisione: Deep Blue vinceva soprattutto con la forza bruta, valutando circa 200 milioni di posizioni al secondo con regole scritte da esperti di scacchi. Il vero salto del machine learning nei giochi arriverà nel 2016 con AlphaGo, che impara anche giocando contro sé stesso.

Deep Blue contro Kasparov in tre minuti (BBC News) · apri su YouTube

Ora portiamo tutto in azienda. Nel mondo reale un progetto non parte da un "compito di previsione" già pronto, ma da un **problema di business**: "perdiamo clienti", "il magazzino è sempre sbagliato". La competenza chiave è **tradurre il problema di business nel giusto problema di dati**: fare le domande giuste, elencare le soluzioni possibili, esplorare i dati per scegliere. Per farlo un *data scientist* combina SQL (estrarre dati), Python (il linguaggio di lavoro), presentazione e visualizzazione, machine learning, servizi cloud e librerie di deep learning. Non serve saperle tutte per fare una buona domanda, ma serve sapere a cosa servono.

C'è anche un problema di nomi: *data mining*, *knowledge discovery*, *pattern recognition*, *data science*, *predictive analytics* sono etichette diverse per attività molto vicine. Cambia l'accento: chi parla di *business analytics* mette al centro l'applicazione aziendale, chi dice *data science* il rigore statistico.

Prova tu **Un capo dice: "Voglio un modello che renda i clienti più felici". Che cosa manca?**

Quattro modi di imparare: con le risposte, senza, a metà, per tentativi

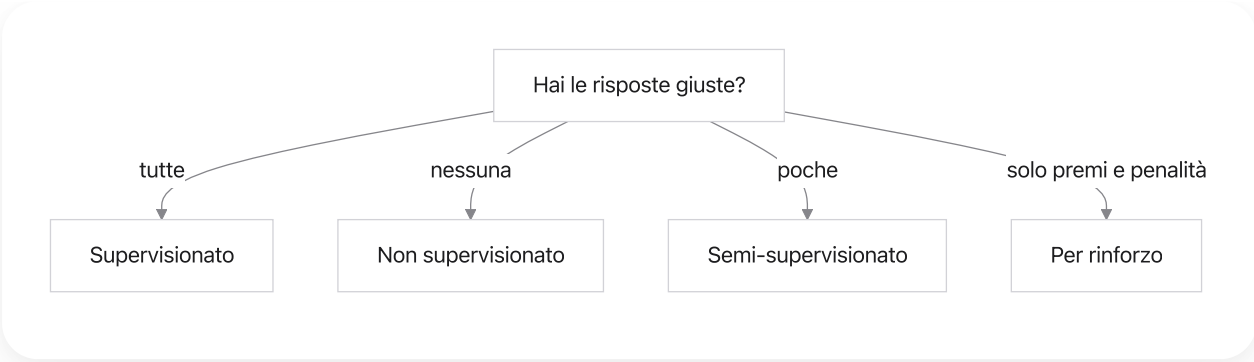
Ci sono quattro tipi di apprendimento. Il criterio per distinguerli è semplice: **quanto aiuto ricevi sotto forma di risposte giuste**.

1. Supervisionato (*supervised*). Ogni esempio arriva con la sua *etichetta* (*label*), la risposta giusta messa da un "supervisore", di solito umano. Un gioco lo mostra bene: questo è un gatto (quattro zampe, miagola), questo è un cane (quattro zampe, abbaia, è fedele), questo è un pesce (nuota). Prima c'è la fase di **addestramento** (*training*), poi quella di **test**: arriva un animale nuovo senza etichetta e il modello deve dire cos'è. Il ragionamento usato è l'**induzione**: da tanti casi ricavo una regola generale.

2. Non supervisionato (*unsupervised*). Nessuna etichetta. Il modello riceve mele, banane, carote, broccoli e deve arrangiarsi. Misura la **somiglianza** (forma, colore, gusto dolce o amaro) e forma dei *cluster*, gruppi di elementi simili. Non sa che cosa sia una mela: sa solo che certi oggetti si somigliano.

3. Semi-supervisionato (*semi-supervised*). Poche etichette e tanti dati senza. L'esempio è Netflix: sa che a una serie hai dato cinque stelle, ma non sa nulla dei film che non hai visto. Li stima guardando gli utenti con gusti simili ai tuoi. Si chiama *matrix completion*: riempire una tabella utenti × film quasi vuota.

4. Per rinforzo (*reinforcement learning*). Nessun dato di partenza: un *agente* prova delle azioni e riceve una ricompensa o una penalità. È il modo in cui impara un bambino. Un esempio è un programma che gioca a Pac-Man (progetto open source *PacmanDQN*): all'inizio si muove a caso e viene mangiato subito; dopo migliaia di partite mangia quasi tutto lo schermo e impara a scappare dai fantasmi.



I primi due si confrontano bene su un caso medico, la sepsi (un'infezione grave). Supervisionato: impari da pazienti già diagnosticati "sepsi sì/no" e poi prevedi la diagnosi di un paziente nuovo, con algoritmi come la regressione logistica o il *gradient boosting*. Non supervisionato: prendi pazienti tutti con sepsi e cerchi sottogruppi ("fenotipi") che si comportano in modo diverso, con algoritmi come il *k-means*. Il primo risponde a una domanda nota, il secondo scopre domande nuove.

Supervisionato, non supervisionato e di rinforzo, in italiano (Yuri Mariotti) · apri su YouTube

Caso reale · Netflix Prize: un milione di dollari per indovinare i gusti

Nel 2006 Netflix offrì un milione di dollari a chi avesse migliorato del 10% il suo sistema di raccomandazione, Cinematch, nel prevedere i voti degli utenti. I partecipanti ricevettero circa 100 milioni di voti reali anonimizzati. Il 21 settembre 2009 vinse il team BellKor's Pragmatic Chaos, nato dall'unione di tre gruppi di ricerca, con un miglioramento del 10,06%. La tecnica centrale era proprio il completamento della matrice utenti × film. Il seguito è istruttivo: Netflix non mise mai in produzione l'intera soluzione vincente perché era troppo complessa rispetto al guadagno, e un secondo concorso fu cancellato per problemi di privacy. Lezione: un modello più preciso non vale sempre il suo costo.

Il supervisionato ha un costo nascosto: **le etichette le mettono persone**, spesso tante e pagate poco. Nel gennaio 2023 un'inchiesta di TIME ha rivelato che OpenAI, tramite l'azienda Sama, aveva fatto etichettare contenuti violenti da lavoratori in Kenya pagati meno di 2 dollari l'ora, per insegnare a ChatGPT a rico-

noscerli. Il caso opposto è Builder.ai, startup londinese sostenuta anche da Microsoft: prometteva un'AI che scriveva app da sola, ma secondo la stampa gran parte del lavoro era fatto da circa 700 sviluppatori in India. Nel maggio 2025 è finita in bancarotta.

Prova tu **Hai i dati di acquisto di 100.000 clienti e nessuna etichetta. Il marketing vuole "capire che tipi di clienti abbiamo". Che approccio usi?**

L'AI è una matrioska, e l'LLM è solo l'ultima bambola

Molti pensano che "AI" voglia dire ChatGPT. In realtà è solo il centro di una matrioska:

- **Intelligenza artificiale**: tutto il campo dei sistemi "intelligenti".
- Dentro c'è il **machine learning**: imparare dai dati (regressione, classificazione, clustering, rinforzo).
- Dentro ancora il **deep learning**: reti neurali con molti strati.
- Dentro ancora l'**AI generativa**: modelli che creano contenuti nuovi.
- Al centro gli **LLM** (*large language models*), come ChatGPT, Claude, Gemini.

Accanto al ML c'è un'altra famiglia, l'**AI simbolica**: conoscenza scritta come regole e logica esplicita (per esempio il linguaggio Prolog o i sistemi di pianificazione). Oggi si combinano spesso le due cose. Il messaggio di Rizzi: **non è vero che l'AI generativa sia sempre la più potente**. Per prevedere le vendite di domani una regressione può battere un LLM, costare mille volte meno e spiegare le sue scelte.

Ecco la differenza tra due modelli che riconoscono una mela.

Il primo è un **albero di classificazione**: prima chiede il colore (giallo, rosso, blu), poi la forma (ovale o cilindrica), poi la superficie (liscia o ruvida). Alla fine dice

"mela". Il suo pregio è la *explainability*, spiegabilità. Puoi leggere il percorso e sapere perché ha deciso così.

Il secondo è una **rete neurale** (*neural network*). È ispirata al cervello: tanti "neuroni" collegati, e ogni collegamento ha un *peso*, un numero tra 0 e 1 che dice quanto conta. Uno strato potrebbe rappresentare il colore, uno la forma, uno la superficie; nella realtà gli strati sono decine o centinaia. La rete impara regolando milioni o miliardi di pesi. Funziona molto bene, ma i pesi non si leggono: è una *black box*, scatola nera.

Che cos'è una rete neurale, strato per strato (3Blue1Brown) · apri su YouTube

Un chiarimento sui numeri detti a lezione. Il cervello umano ha circa **86 miliardi di neuroni** (studio di Azevedo e colleghi, 2009). Confrontarli con i "500 miliardi di parametri" di un modello è un paragone sbagliato: i parametri di una rete somigliano piuttosto alle sinapsi, cioè ai collegamenti tra neuroni, e nel cervello quelle sono centinaia di migliaia di miliardi. Il grafico qui sotto mostra quanto è cresciuto il numero di parametri dei modelli di AI.

Quanti parametri hanno i sistemi di AI più noti · Dati interattivi: Our World in Data. Cambia paesi e anni dal grafico. Apri a schermo intero

Collegamento · Corso di International Business

Spiegabilità e scatola nera non sono solo una questione tecnica. L'AI Act europeo (in vigore dal 2024) chiede trasparenza e supervisione umana per i sistemi ad alto rischio, come quelli per il credito o le assunzioni. Un'azienda che opera in Europa può dover preferire un modello leggibile anche se un po' meno preciso: è una differenza istituzionale tra mercati che pesa sulle scelte tecnologiche.

Prova tu **Un ospedale deve scegliere tra un albero di classificazione (accurato all'88%) e una rete profonda (91%) per decidere chi ricoverare. Che cosa valuti oltre al 3% di differenza?**

Un LLM sceglie la parola successiva, un pezzo alla volta

Perché gli LLM sono esplosi proprio adesso, dopo decenni di ricerca? In aula qualcuno risponde "l'energia". Rizzi dice che conta, ma non è il punto. Il punto è che **il nostro modo di pensare passa dal linguaggio**: parole, simboli matematici, note musicali, codice. Un modello che sa trattare il linguaggio tocca quasi tutto ciò che sappiamo.

Visto da dentro, un LLM fa due cose semplici.

1. Tokenizzazione. Il testo viene spezzato in *token*, pezzi di parole. Per semplicità pensali come parole, ma non lo sono: secondo OpenAI, in inglese 100 token sono circa 75 parole; in italiano di solito servono più token. Ed è sui token che si paga quando si usa un LLM tramite API.

2. Previsione del token successivo. Data la frase fin qui, il modello calcola una probabilità per ogni token possibile e ne sceglie uno. Poi lo aggiunge alla frase e ricomincia. Per questo vedi la risposta di ChatGPT comparire una parola alla volta: non è un effetto grafico, è proprio il modo in cui viene generata.

Da dove vengono le probabilità? Dall'addestramento su enormi quantità di testo: libri, siti, articoli. Rizzi usa un'immagine: un alieno che ha "mangiato" tutte le parole scritte del mondo. Se ha letto mille volte "chi fa da sé fa per tre", dopo "chi fa da sé fa per" il token "tre" avrà una probabilità altissima. È proprio quello che succede: con il contesto giusto, "per 3" arriva a 0,7 mentre le altre continuazioni restano basse.

Formula · Dalla classifica dei token alle probabilità (softmax con temperatura)

Il modello dà a ogni token candidato i un punteggio z_i (*logit*, un numero senza unità). Lo trasforma in probabilità così: p_i = e^(z_i / T) / somma di tutti gli e^(z_j / T). T è la temperatura. Esempio con due candidati, "tre" (z = 4) e "due" (z = 2), con T = 1: e^4 ≈ 54,6 ed e^2 ≈ 7,4, quindi p(tre) = 54,6 / 62 ≈ 0,88 e p(due) ≈ 0,12. Con T = 2: e^2 ≈ 7,4 ed e^1 ≈ 2,7, quindi p(tre) ≈ 0,73. Più alta la temperatura, più le probabilità si avvicinano: il modello rischia di più.

La **temperatura** (*temperature*) serve perché un modello che sceglie sempre il token più probabile scrive testi ripetitivi e piatti. Con un po' di temperatura introduce varietà, "creatività". Per questo la stessa domanda a ChatGPT dà risposte simili ma non identiche. Prova qui sotto.

Laboratorio · Che cosa scrive dopo "Chi fa da sé fa per..."?

Temperatura:

1.0



"tre": **87%** · "te": **7%** · "due": **4%** · "sempre": **2%**

Quasi sempre "tre": testo prevedibile e corretto.

Punteggi inventati a scopo illustrativo (tre = 5, te = 2,5, due = 2, sempre = 1). I modelli veri valutano decine di migliaia di token candidati.

Come funziona un LLM in otto minuti (3Blue1Brown) · apri su YouTube

Caso reale · Il transformer: inventato da Google, sfruttato da OpenAI

Rizzi racconta che l'idea alla base degli LLM nacque da un ricercatore di Google, che i dirigenti non la presero sul serio e che OpenAI la trasformò in un business con un miliardo di dollari di Microsoft. La versione documentata: nel 2017 otto ricercatori di Google pubblicarono l'articolo *Attention Is All You Need*, che presentava il *transformer*, l'architettura su cui si basano quasi tutti gli LLM. Google la usò (per esempio nel modello BERT, 2018), ma fu OpenAI a costruirci sopra la serie GPT. Nel luglio 2019 Microsoft investì 1 miliardo di dollari in OpenAI, diventando il suo partner preferito e facendo del cloud Azure la piattaforma della sua ricerca. Quando ChatGPT uscì, a fine 2022, Google si trovò a inseguire con Bard e poi Gemini. Lezione di business: inventare una tecnologia non basta, vince chi la trasforma per primo in un prodotto.

Infine, che cos'è un LLM? La risposta è "tutte queste cose insieme": un modello di deep learning, un modello linguistico, un "database statistico" di probabilità tra parole, una grande rete neurale, un insieme di pesi, un algoritmo, e alla fine una sequenza di 0 e 1. In più, i modelli generativi conservano una rappresentazione semplificata dei dati di addestramento e la usano per creare contenuti **simili ma non identici**. Non c'è niente di magico, ma serve tantissima potenza di calcolo, che costa denaro ed energia: un tema per le prossime lezioni.

Cosa c'è dietro un chatbot, in italiano (Geopop) · apri su YouTube

Prova tu **Perché un LLM può scrivere una frase convincente ma falsa?**

La nuova frontiera: un modello che si inventa gli esercizi

Un'idea uscita nel maggio 2025 è l'*Absolute Zero Reasoner* (AZR), da un articolo di ricercatori della Tsinghua University, del Beijing Institute for General Artificial Intelligence e della Penn State. Il nome dice "zero" perché il modello **non ri-**

ceve esercizi preparati da umani: se li crea da solo. Attenzione, però: parte da un modello linguistico già addestrato.

Il ciclo ha cinque passi:

1. **Proporre**: il modello, nel ruolo di "proponente", inventa un piccolo problema di programmazione in Python.
2. **Validare**: un esecutore di codice controlla che il problema sia valido.
3. **Risolvere**: lo stesso modello, nel ruolo di "risolutore", prova a risolverlo.
4. **Verificare e premiare**: l'esecutore controlla la risposta e assegna una ricompensa. Il proponente è premiato di più per i problemi né troppo facili né impossibili.
5. **Aggiornare e ripetere**: con l'apprendimento per rinforzo entrambi i ruoli migliorano.

I problemi allenano tre forme di ragionamento che vengono dalla filosofia:

- **Deduzione**: conosco la regola e il caso, ricavo il risultato. Programma f(x) = 2x + 1 e x = 3, quindi 7. Esempio umano: A è padre di B, B è padre di C, quindi A è nonno di C.
- **Abduzione**: conosco la regola e il risultato, cerco la causa. f(x) = 2x + 1 e il risultato è 7, quindi x = 3. È il ragionamento del medico che dai sintomi risale alla malattia, o del meccanico che dall'auto che non parte risale alla batteria.
- **Induzione**: vedo tanti esempi e ricavo la regola. 1 → 3, 2 → 5, 3 → 7, quindi f(x) = 2x + 1. È quello che fa l'apprendimento supervisionato.

Perché fa discutere? Perché riduce il bisogno di dati preparati da umani, che sono costosi e stanno finendo. Rizzi invita a non avere paura: c'è sempre un essere umano che avvia il processo e controlla i dati. Per ora AZR funziona su problemi verificabili, come codice e matematica, dove un computer può controllare se la risposta è giusta.

Collegamento · Il dibattito tra AI forte e AI debole

La lezione si chiude con una domanda: la gelosia si può rappresentare in un modello linguistico? È il dibattito tra *AI debole* (le macchine simulano l'intelligenza) e *AI forte* (le macchine possono davvero capire). Rizzi sostiene che, quando la sintassi diventa abbastanza complessa, "diventa semantica", cioè il modello sembra capire. Il filosofo John Searle, nel 1980, sosteneva il contrario con l'esperimento della "stanza cinese": manipolare simboli secondo regole non vuol dire capirne il significato. È una questione aperta: tienila presente quando leggi che un'AI "capisce".

Prova tu **Un modello vede la regola "prezzo finale = prezzo × 1,22" e il prezzo finale 122 €, e risale a 100 €. Che ragionamento è?**

Il data lake: tenere tutto, ma con l'etichetta

Il *data lake* non è stato spiegato a voce in questa lezione: lo riprende quella del 13 ottobre. Ecco l'essenziale.

Un **data lake** è un deposito che conserva grandi quantità di dati **strutturati** (tabelle), **semi-strutturati** (file JSON o XML) e **non strutturati** (testi, immagini, log), ciascuno nel suo formato originale. L'immagine è quella di un lago: tanti affluenti (database, sensori, log delle macchine) che portano acqua nello stesso bacino. A differenza del *data warehouse*, organizzato in modo gerarchico e con uno schema deciso prima, il lago ha un'architettura "piatta": ogni dato riceve un identificativo unico e dei *metadati* (dati sui dati: da dove viene, quando, che cosa contiene). Lo schema si decide quando si interroga il dato, non quando lo si salva.

I livelli dell'architettura seguono il viaggio del dato: **ingestion** (i dati entrano, a blocchi o in tempo reale), **storage** (la zona di atterraggio, per esempio HDFS, il file system di Hadoop), **distillation** (i dati grezzi diventano tabelle ordinate),

processing (algoritmi e query), **insights** (analisi con SQL o anche Excel) e **unified operations** (controllo e gestione di tutto il sistema).

Sei "guardiani" evitano che il lago diventi una palude:

Guardiano	Domanda a cui risponde	Esempio
Governance	Chi può usare quali dati, e per cosa?	il marketing vede le vendite, non le buste paga
Sicurezza	Chi sei e che permessi hai?	accesso solo con login aziendale e ruoli
Qualità	Questi dati sono affidabili?	controllo dei campi vuoti prima dell'analisi
Discovery	Dove trovo il dato che mi serve?	etichetta "vendite 2025, Italia, mensili"
Auditing	Chi ha cambiato cosa, e quando?	registro delle modifiche a una tabella
Lineage	Da dove viene il dato e come è stato trasformato?	dal gestionale al report, passaggio per passaggio

Dati scadenti producono analisi scadenti: per questo i guardiani vengono prima degli algoritmi. Il percorso di adozione ha quattro fasi di maturità, dall'acquisire dati su larga scala fino a una gestione "enterprise" che poche organizzazioni raggiungono.

Collegamento · Lezione del 29 settembre

La settimana scorsa avete visto le fonti dei dati e la differenza tra elaborazione a blocchi (*batch*) e in tempo reale (*streaming*). Il livello di ingestion del data lake è proprio il punto in cui quei flussi entrano. E unire fonti diverse richiede chiavi coerenti, come visto nel caso dei join.

Prova tu **Un'analista scopre un errore nel fatturato di un report. Quale funzione del data lake la aiuta a capire dove è nato?**

Dashboarding Oscars: la curiosità viene prima dei clic

La seconda parte della giornata, con Campana, è un laboratorio a squadre: i *Dashboarding Oscars*. Lo slogan: *i dati sono il copione, gli insight sono la storia, la dashboard è l'interpretazione*.

Le regole:

- squadre equilibrate (curiosità, competenze sui dati, senso visivo), **nessuno solo, nessun passeggero**;
- **10 minuti** per scegliere i dati, **40 minuti** per costruire la dashboard su Databricks;
- un **pitcher** presenta in **3 minuti esatti**, partendo dall'insight, direttamente dalla dashboard e non da un PowerPoint;
- un **voter** classifica le altre squadre su Mentimeter, mettendo la propria per ultima (*fair play*: non ci si incorona da soli);
- cinque premi: miglior design, insight più profondo, miglior integrazione di dati diversi, miglior storytelling, premio del pubblico. Il risultato unisce la classifica della giuria e il voto del docente.

Il metodo vale ben oltre l'esercizio:

1. **Scegli** un dataset (per esempio su Kaggle, ma va bene qualsiasi CSV affidabile) che ti incuriosisce davvero.
2. **Esplora**: capisci i campi, la qualità, i pattern, le sorprese.
3. **Fai la domanda**: decidi quale insight vuoi scoprire. Gli insight nascono sempre da domande, non dai dati da soli.
4. **Disegna** la storia e l'impaginazione prima di aprire Databricks.

5. **Costruisci** solo ciò che sostiene la storia.
6. **Taglia**: meno grafici, più impatto, un messaggio finale chiaro.

Il docente ha detto

"Anyone can make a chart. The AI can make a chart." Sulla slide: "AI can make a chart. Only you can decide what matters."

I passaggi tecnici mostrati ai gruppi in difficoltà: in Databricks crei un *volume* (uno spazio per i file) scegliendo catalogo e *schema* (una cartella logica, anche "test" va bene), carichi il CSV, crei una **tabella** dal file, poi apri una **dashboard**, aggiungi la tabella come dati e costruisci ogni grafico scegliendo asse x e asse y.

Costruire una dashboard AI/BI in Databricks (Databricks) · apri su YouTube

Nelle presentazioni sono emersi due esempi utili. Una squadra ha mostrato prima tre numeri chiave (*KPI*: durata media del sonno, qualità, stress) e poi li ha scomposti per professione, età e attività fisica: struttura chiara, dal generale al particolare. Un'altra ha cercato un legame tra due fenomeni sociali in diversi Paesi e non l'ha trovato. Ed è qui la lezione più importante: **correlazione non è causa**, e **"non c'è correlazione" è un risultato**. L'esempio classico citato in aula è quello dei gelati e dei furti: nelle città e nei mesi in cui si vendono più gelati ci sono più furti, ma la causa comune è il caldo (più gente in giro), non il gelato.

Esempio svolto · **Preparare una dashboard in 10 minuti (caso ipotetico)**

1. **Dati**: un CSV pubblico sulle vendite di biglietti di 50 musei italiani per mese, 2019–2024.
2. **Esplora**: controlli che i mesi siano completi; scopri che nel 2020 molti valori sono zero (chiusure Covid).
3. **Domanda**: "I musei delle città d'arte sono tornati ai livelli del 2019 più in fretta di quelli di provincia?"
4. **Disegno su carta**: in alto un KPI (% di recupero rispetto al 2019), al centro una linea per ciascun gruppo di musei, in basso una barra per regione.
5. **Costruzione**: solo questi tre grafici, con le zone 2020 segnalate.
6. **Messaggio finale**: una frase, per esempio "le città d'arte hanno recuperato prima, trainate dal turismo straniero", con il limite dichiarato: è una correlazione con il turismo, non una prova della causa.

Il docente ha detto

Sull'uso dell'AI nelle prove d'esame, Rizzi propone un "gentlemen's agreement". L'AI è ammessa e utile nella fase delle idee (concept) e come assistente per capire come impostare una soluzione. Ma la scrittura finale dev'essere tua: "If you write, you think." Valuta concetti, competenze e idee, non l'inglese, e segnala che esistono strumenti per riconoscere i testi copiati.

Prova tu **La tua dashboard ha 14 grafici e il pitch dura 3 minuti. Che cosa fai?**

Richiamo a libro chiuso

1. Disegna a memoria i due schemi 'programmazione classica' e 'machine learning' e spiega la differenza con un esempio aziendale.

2. Scrivi il T–P–E di un filtro anti-spam e di un'auto che guida da sola in autostrada.
3. Spiega a un amico, senza termini tecnici, come ChatGPT produce una risposta parola per parola e perché due risposte alla stessa domanda sono diverse.
4. Elenca i sei passaggi per preparare una dashboard prima di aprire Databricks e di' perché 'meno grafici' è meglio.

Quiz

1. Una banca calcola gli interessi di un conto con una formula fissata dal contratto. Quale approccio è corretto?

- Programma classico: la regola è nota, stabile e va applicata esatta
- ML supervisionato: lo storico dei conti contiene già le risposte giuste
- ML, perché i clienti sono milioni e serve lavorare su larga scala
- ML non supervisionato, per raggruppare i conti con interessi simili

2. Una startup promette di prevedere i numeri del Superenalotto con un modello addestrato su 30 anni di estrazioni. Qual è la critica corretta?

- Le estrazioni sono indipendenti: manca un pattern da imparare
- Funziona solo se il dataset copre più anni e più tipi di estrazioni
- Serve una rete neurale profonda, capace di vedere pattern nascosti
- Va usato il non supervisionato per trovare gruppi di numeri ricorrenti

3. **Un'azienda vuole un modello che smisti i reclami dei clienti. Quale T–P–E è completo e corretto?**

- T: classificare i reclami; P: % giusti sugli stessi dati di training; E: reclami passati
- T: classificare i reclami; P: % giusti su reclami nuovi; E: reclami già smistati
- T: ridurre i reclami del 20%; P: soddisfazione clienti; E: archivio reclami
- T: classificare i reclami; P: tempo risparmiato; E: manuale delle categorie

4. **Hai 10.000 foto di prodotti, tutte controllate e marcate 'difettoso' o 'buono' dagli ispettori. Che tipo di apprendimento usi?**

- Supervisionato
- Semi-supervisionato
- Per rinforzo
- Non supervisionato

5. **Un servizio di musica conosce i 'mi piace' di ogni utente su una trentina di brani, in un catalogo di milioni, e vuole stimare il gradimento di tutti gli altri. Che apprendimento è?**

- Non supervisionato: si formano gruppi di brani simili, senza usare voti
- Per rinforzo: ogni ascolto è una ricompensa che aggiorna la strategia
- Supervisionato: i 'mi piace' sono etichette sufficienti per ogni brano
- Semi-supervisionato: poche etichette, il resto si stima da utenti simili

6. Una banca deve spiegare a un cliente perché il prestito è stato rifiutato. A parità di precisione accettabile, quale modello sceglie?

- Un albero di classificazione: il percorso delle domande è leggibile
- Un LLM che scrive la motivazione: il testo spiega già la decisione
- Una rete neurale profonda: con più strati la decisione è più precisa
- Un clustering dei clienti: i gruppi di rischio spiegano il rifiuto

7. Chiedi due volte a un chatbot lo stesso slogan e ottieni due frasi diverse. Qual è la spiegazione corretta?

- Il modello ha imparato dalla prima risposta e ora prova a migliorarla
- Con temperatura zero il modello estrae a caso tra tutti i token possibili
- Con temperatura sopra zero il token è estratto tra i candidati probabili
- Il tokenizzatore spezza la domanda in modo diverso a ogni invio

8. La tua squadra scopre che nelle città dove si vendono più gelati ci sono anche più furti. Che cosa metti nella dashboard?

- Il legame causale: le due curve salgono sempre insieme, quindi è causa
- Un modello che prevede i furti dalle vendite di gelati del mese prima
- La correlazione, avvisando che un terzo fattore come il caldo la spiega
- Niente: un dato senza legame causale non merita spazio in dashboard

Soluzioni del quiz

1. **A** — La regola esiste ed è scritta nel contratto: un programma classico è esatto, controllabile e costa poco. Il ML serve quando la regola non si sa scrivere o cambia. Avere uno storico non basta a giustificare il supervisionato (la risposta la dà già la formula); la larga scala è una condizione utile, ma non sufficiente; il clustering risponde a un'altra domanda.
2. **A** — Il ML trova solo pattern che esistono: in un'estrazione onesta ogni numero ha la stessa probabilità a prescindere dal passato. Più anni di dati, una rete più profonda o un clustering applicano strumenti giusti a un caso sbagliato: nessuno di loro crea un segnale che non c'è.
3. **B** — Serve un compito preciso, una misura su casi nuovi e dati con la risposta giusta. 'Ridurre i reclami' è un obiettivo di business, non un compito di ML; misurare sugli stessi dati di addestramento premia chi impara a memoria; il manuale delle categorie sono regole, non esperienza, e il tempo risparmiato non misura se la classificazione è giusta.
4. **A** — Ogni foto ha la risposta giusta: è il caso tipico del supervisionato. Il semi-supervisionato servirebbe se fossero etichettate solo poche foto; il non supervisionato se non ce ne fosse nessuna; il rinforzo se il sistema imparasse per tentativi e ricompense.
5. **D** — La tabella utenti × brani è quasi vuota: i pochi 'mi piace' sono etichette, il resto si stima da chi ha gusti simili (matrix completion). Non è supervisionato puro perché le etichette mancano per quasi tutto; non è non supervisionato perché i voti si usano; il rinforzo richiederebbe un agente che prova azioni e riceve premi.
6. **A** — L'albero mostra il percorso ('reddito sotto X, debiti sopra Y'): è spiegabile. La rete profonda è una scatola nera, e più strati non la rendono leggibile; un LLM può scrivere una motivazione convincente che non è la vera ragione del modello di credito; il clustering crea gruppi ma non decide né spiega il singolo rifiuto.
7. **C** — Il modello calcola una probabilità per ogni token e, con temperatura positiva, ne estrae uno: frasi diverse sono normali. Non si riaddestra tra una domanda e l'altra; con temperatura zero (o vicina a zero) sceglie quasi sempre il più probabile, quindi l'opzione inverte la regola; la tokenizzazione dello stesso testo è sempre uguale.
8. **C** — Due variabili salgono insieme perché dipendono entrambe dal caldo (più gente in giro): mostrare la correlazione con l'avviso è corretto. Leggerla come causa è l'errore classico; scartarla del tutto butta via un insight; usare i gelati per prevedere i furti tratta come affidabile un legame che dipende da un terzo fattore.

Applica a un caso nuovo

Caso ipotetico. Una catena di farmacie italiana (300 punti vendita) vuole 'usare l'AI'. Ha tre idee: (a) prevedere ogni settimana quante confezioni di ogni farmaco servono in ogni negozio; (b) un chatbot che risponde ai clienti sugli orari e sulla disponibilità; (c) indovinare quali clienti vinceranno al gratta e vinci venduto in

alcune farmacie, per mandare loro offerte. Per ciascuna idea scrivi il T–P–E, il tipo di apprendimento o di tecnologia adatto e se conviene davvero.

Mostra una soluzione ragionata

Decidi tu

Il fornitore che vende 'AI'

Sei il responsabile operativo di un e-commerce di arredamento. Un fornitore propone un 'assistente AI' che, dice, scrive da solo le schede prodotto e risponde ai clienti, a 8.000 € al mese. La demo è impressionante. Il tuo capo vuole firmare entro venerdì.

Che cosa chiedi prima di firmare?

Firmi subito: la demo funzionava e i concorrenti lo usano già

Rischiosa. Non sai che cosa fa davvero il sistema né come misurerai il risultato. Il caso Builder.ai (2025) mostra che dietro un'AI dichiarata può esserci soprattutto lavoro umano: lo scopri solo quando è tardi.

Chiedi il T–P–E: quale compito preciso, con quale metrica e su quali dati; poi fai un test di un mese su tuoi prodotti veri con controlli a campione

Scelta solida. Trasformi una promessa in un esperimento misurabile: % di schede pubblicate senza correzioni, errori sulle misure dei mobili, tempo risparmiato. Se i numeri non tornano, non rinnovi.

Rifiuti: l'AI generativa sbaglia sempre

Rischiosa. Troppo drastico. Per testi ripetitivi su larga scala l'AI generativa può convenire; il problema non è la tecnologia ma la mancanza di una misura e di un controllo umano.

Prima la definizione del problema (T–P–E), poi la tecnologia. Un'AI si compra su metriche verificate, non su una demo.

La squadra senza correlazione

Mancano dieci minuti ai 'Dashboarding Oscars'. La tua squadra ha unito due dataset per vedere se nei Paesi dove si scommette di più c'è anche un fenomeno sociale più frequente. La dashboard mostra punti sparsi a caso: nessuna relazione.

Che cosa presenti?

Cambi variabile all'ultimo finché trovi una correlazione qualsiasi

Rischiosa. Provare tante coppie finché una 'esce' è pescare a caso (data dredging): prima o poi una correlazione la trovi per puro caso, ma non significa nulla.

Presenti l'assenza di relazione come risultato: domanda, dati usati, perché ci si poteva aspettare un legame e perché non c'è, con i limiti dei dati

Scelta solida. È un insight onesto e utile: smonta un luogo comune con i dati. La giuria valuta la storia e la profondità, non il fatto che la retta salga.

Fai una presentazione PowerPoint senza la dashboard

Rischiosa. La consegna chiede di presentare direttamente dalla dashboard Databricks, in tre minuti: perdi il punto dell'esercizio.

Un 'no' ben argomentato è un risultato. Le domande decidono l'insight; i grafici sono solo il mezzo.

Da vedere

Documentario · 2017

AlphaGo

Racconta la sfida del 2016 tra il programma AlphaGo e il campione Lee Sedol: reti neurali e apprendimento per rinforzo in un gioco molto più complesso degli scacchi.

Dove: Disponibile gratis sul canale YouTube di Google DeepMind

Documentario · 2003

Game Over: Kasparov and the Machine

La sfida Kasparov–Deep Blue del 1997 citata a lezione, con i sospetti di Kasparov sull'intervento umano di IBM.

Dove: Disponibilità variabile in Italia (noleggio/acquisto digitale o servizi con pubblicità): verificare su JustWatch Italia

Film · 2014

Ex Machina

Un test su una macchina che sembra capire: utile per il dibattito tra AI forte e AI debole con cui si chiude la lezione.

Dove: Noleggio/acquisto digitale o abbonamento a seconda del periodo: verificare su JustWatch Italia

Flashcard

Programmazione classica vs machine learning?

Classica: dati + programma → risultato. ML: dati + risultati → il computer ricava il programma (modello).

Perché riconoscere la voce di un amico è un compito da ML?

Perché gli umani sanno farlo ma non sanno spiegarne le regole: il modello le ricava dagli esempi.

Definizione di Tom Mitchell?

Un programma impara dall'esperienza E rispetto a un compito T e una misura P se la sua prestazione su T, misurata da P, migliora con E.

Perché 'l'errore costa poco' è una condizione per usare il ML in azienda?

Un modello sbaglia sempre una parte dei casi: conviene dove l'errore è tollerabile (un film consigliato male), non dove è grave.

Supervisionato in una riga?

Esempi con la risposta giusta (etichetta): il modello generalizza per induzione.

Non supervisionato in una riga?

Nessuna etichetta: il modello cerca somiglianze e forma gruppi (cluster).

Rinforzo in una riga?

Tentativi, ricompense e penalità: dopo migliaia di episodi l'agente impara la strategia (es. Pac-Man).

Qual è la matrioska dell'AI?

AI ⊃ machine learning ⊃ deep learning ⊃ AI generativa ⊃ LLM. Accanto c'è l'AI simbolica, basata su regole esplicite.

Le due operazioni base di un LLM?

1) Tokenizzare il testo. 2) Prevedere il token successivo, uno alla volta.

Che cosa fa la temperatura?

Appiattisce (alta) o accentua (bassa) le differenze di probabilità tra i token candidati: più varietà o più prevedibilità.

Deduzione vs abduzione?

Deduzione: regola + input → ricavo l'output. Abduzione: regola + output → risalgo all'input (come il medico dai sintomi alla malattia).

Che cos'è l'induzione?

Da tanti esempi input/output ricavo la regola: è il ragionamento dell'apprendimento supervisionato.

Cos'è 'zero' in Absolute Zero Reasoner?

Nessun dataset di esercizi curato da umani: il modello (già preaddestrato) propone i compiti, un esecutore di codice li verifica, lui li risolve.

Il flusso vincente dei 'Dashboarding Oscars'?

Scegli dati che ti incuriosiscono → capiscili → decidi la domanda → disegna la storia → costruisci solo ciò che serve → taglia i grafici inutili.

Che cosa sono lineage e auditing in un data lake?

Lineage: da dove viene un dato e che trasformazioni ha subito. Auditing: chi ha cambiato cosa e quando.

Glossario

Machine learning (ML) · apprendimento automatico

Approccio in cui il computer ricava le regole dagli esempi invece di riceverle scritte. Esempio: un filtro anti-spam che impara da migliaia di email già marcate 'spam' o 'buona'.

Model · modello

Il risultato dell'addestramento: la regola ricavata dai dati che poi applichi a casi nuovi. Esempio: la funzione che dato il testo di un'email dice 'spam' con il 92% di probabilità.

T–P–E (Task, Performance, Experience) · compito, misura, esperienza

La definizione di Tom Mitchell: un sistema impara se migliora nel compito T, misurato da P, grazie all'esperienza E. Esempio: T classificare email, P % classificate bene, E archivio di email etichettate.

Label · etichetta
La risposta giusta associata a un esempio di addestramento, di solito messa da un essere umano. Esempio: la foto con scritto 'gatto'.

Supervised learning · apprendimento supervisionato
Imparare da esempi con etichetta per poi prevedere l'etichetta di casi nuovi. Esempio: prevedere se un paziente ha la sepsi da casi già diagnosticati.

Unsupervised learning · apprendimento non supervisionato
Imparare senza etichette, cercando strutture nei dati, come gruppi di elementi simili (clustering). Esempio: dividere frutta e verdura per colore e sapore senza sapere i nomi.

Semi-supervised learning · apprendimento semi-supervisionato
Pochi esempi con etichetta e molti senza. Esempio: Netflix conosce i voti che hai dato a pochi film e deve stimare tutti gli altri.

Reinforcement learning · apprendimento per rinforzo
Un agente prova azioni, riceve ricompense o penalità e impara la strategia che rende di più. Esempio: un programma che gioca migliaia di partite a Pac-Man finché impara a evitare i fantasmi.

Neural network · rete neurale
Modello fatto di 'neuroni' artificiali collegati da connessioni con un peso numerico; impara regolando i pesi. Con molti strati si parla di deep learning.

Black box · scatola nera
Modello che dà risultati ma non permette di leggere il perché, come una rete con miliardi di pesi. Il contrario di un albero decisionale, che mostra il percorso.

Token · pezzo di testo
L'unità con cui un LLM legge e scrive: una parola o un pezzo di parola. In inglese 100 token sono circa 75 parole, ed è sui token che si paga l'uso delle API.

Temperature · temperatura
Parametro che regola quanto il modello rischia nella scelta del token successivo: bassa = sceglie quasi sempre il più probabile, alta = più varietà e più errori.

Generative AI · AI generativa

Modelli di deep learning che creano contenuti nuovi (testi, immagini, audio) simili ma non identici ai dati su cui sono stati addestrati. Oggi quasi tutti si basano sui transformer.

Data lake · lago di dati

Deposito che conserva dati strutturati, semi-strutturati e non strutturati nel formato originale, con metadati per ritrovarli. Esempio: vendite, log del sito e email dei clienti nello stesso archivio.

Dashboard · cruscotto

Pagina che riunisce pochi indicatori e grafici collegati ai dati per rispondere a una domanda. Una buona dashboard porta a una decisione, non mostra tutto.

Video consigliati

Supervisionato, Non supervisionato e di Rinforzo - Come imparano le AI?

Yuri Mariotti · 11 min · IT

I tre modi di imparare spiegati in italiano con esempi semplici: ripassa la parte centrale della lezione.

But what is a neural network? | Deep learning chapter 1

3Blue1Brown · 19 min · EN

Fa vedere strati, neuroni e pesi su un esempio di cifre scritte a mano: è l'idea dello schema 'colore, forma, superficie' della lezione, fatta bene.

Large Language Models explained briefly

3Blue1Brown · 8 min · EN

Previsione della parola successiva, probabilità e addestramento in otto minuti, con animazioni chiarissime.

Cosa c'è dietro un chatbot AI? Vi spieghiamo come apprende e il ruolo dei supercomputer

Geopop · 8 min · IT

Lo stesso meccanismo in italiano, più il costo in calcolo ed energia citato alla fine della lezione.

Deep Blue vs Kasparov: How a computer beat best chess player in the world

BBC News · 3 min · EN

Il match del 1997 in tre minuti, con le immagini dell'epoca: completa il caso Deep Blue.

The Basics of Building an AI/BI Dashboard in Databricks

Databricks · 6 min · EN

I passaggi del laboratorio (dati, visualizzazioni, pubblicazione) mostrati da chi ha fatto lo strumento.

Fonti

1. Registrazione PLAUD parte 1 — Rizzi (of_3093455417400f717884be503d952a86) — 10:03, 87 min: esame e accordo sull'uso dell'AI (0–14′), perché il ML (16–28′), tipi di apprendimento (28–50′), tassonomia e Absolute Zero (50–57′), reti neurali (57–62′), LLM, token, temperatura, storia del transformer, AI forte/debole (62–86′).
2. Registrazione PLAUD parte 2 — Campana (of_0708aef2163da62525a63c38558bf68a) — 12:03, 88 min: istruzioni 'Dashboarding Oscars' (3–7′), lavoro di gruppo, aiuto pratico su Databricks (56–68′), presentazioni (71–87′). Conversazioni private di studenti non usate.
3. Slide Canvas — Rizzi, BigDataBsnsRizzi2026Lesson3 (55 pagine) — ML pp. 3–23, AI predittiva e generativa pp. 24–30, LLM pp. 31–35, data lake pp. 36–48, Team Work 3 pp. 49–55.
4. Mitchell, T. (1997). Machine Learning. McGraw-Hill — definizione T–P–E
5. NASA — Stanley Schmidt e il filtro di Kalman per la navigazione Apollo
6. Deep Blue batte Kasparov 3½–2½, maggio 1997
7. Netflix Prize: premio di 1 milione di dollari a BellKor's Pragmatic Chaos, 21/9/2009, +10,06% su Cinematch
8. TIME (gennaio 2023) — lavoratori Sama in Kenya pagati meno di 2 $/ora per etichettare contenuti per OpenAI (ripreso da BigDATAwire)
9. Builder.ai in bancarotta (maggio 2025) dopo le rivelazioni sul lavoro umano dietro 'Natasha' (eWEEK)
10. Zhao A. et al. (2025), Absolute Zero: Reinforced Self-play Reasoning with Zero Data, arXiv 2505.03335 (Tsinghua, BIGAI, Penn State)
11. Azevedo F. et al. (2009), J Comp Neurol 513:532-541 — circa 86 miliardi di neuroni nel cervello umano
12. OpenAI Help — What are tokens and how to count them (1 token ≈ ¾ di parola in inglese)

13. Vaswani A. et al. (2017), Attention Is All You Need — il transformer
14. Microsoft investe 1 miliardo di dollari in OpenAI (22 luglio 2019), Fortune
15. Our World in Data — parametri dei sistemi di AI

Note di verifica