13 ottobre 2026

Dal lago di dati alla decisione: conservare tutto, scegliere il formato giusto, non confondere previsione e causa

Data Lakes, File Formats (CSV, XML, JSON, Parquet) and AI Capabilities: Prediction, Classification, Personalization, Automation

Martedì · Rizzi, Campana · Completa

Lezione ricostruita dai materiali: nessuna registrazione PLAUD salvata per questa giornata (slot Rizzi 10:00–11:30 e Campana 12:00–13:30) e nessun'altra parte trovata tra i file locali; il connettore PLAUD e il notebook NotebookLM non erano raggiungibili in questo giro, Canvas non accessibile. Fonti: slide Canvas 133640 'BigDataBsnsRizzi2026Lesson4' (42 pagine), tutte ricontrollate il 6/11/2026, comprese le slide-immagine 6, 8, 27–32, 34–38 e 40 guardate come immagine; i quattro file del laboratorio Canvas 133641 letti direttamente, compreso forecast.parquet (16 righe mese × regione decodificate). Divisione della giornata: nelle slide i blocchi marcati 'B' (data lake, formati, laboratorio, pp. 2–25) e 'A' (capacità dell'AI, previsione e causa, errori, warm-up, pp. 26–41) seguono la stessa convenzione della Lesson 2, dove B era Campana e A Rizzi: è un'inferenza, non una prova. Tutto il testo spiega le slide della sessione; casi, numeri ed esempi aggiunti sono integrazione con fonti dichiarate.

In breve

La lezione segue i dati dal deposito alla decisione. Prima il data lake: un grande deposito che accoglie dati di ogni tipo nel formato originale, utile solo se ha metadati, qualità, sicurezza e governance. Poi i formati di file (CSV, XML, JSON, Parquet) e come scegliere quello giusto, con un laboratorio Databricks che unisce quattro file in una vista affidabile. Infine le quattro cose che l'AI fa con i dati (prevedere, classificare, personalizzare, automatizzare) e l'errore più costoso: scambiare una previsione per la prova che un'azione funziona.

- Un data lake conserva dati strutturati, semi-strutturati e non strutturati nel formato originale; lo schema si decide quando li usi (schema-on-read).
- Senza metadati, qualità, sicurezza e governance un data lake diventa una palude di dati che nessuno sa usare.
- L'architettura va dall'ingestione (batch o tempo reale) allo storage, alla distillazione e all'elaborazione, fino agli insight; un livello di operazioni unificate governa tutto.
- CSV è semplice, XML rigoroso, JSON flessibile per API ed eventi, Parquet veloce per l'analisi: nessun formato vince, conta l'adattamento allo scopo.
- Una vista affidabile richiede di pulire chiavi, date e duplicati prima di unire le tabelle: un doppione nel catalogo prodotti gonfia i ricavi.
- L'AI con i dati fa quattro cose: prediction (stima), classification (etichetta), personalization (ordinamento per persona), automation (azione).
- Un buon punteggio storico non prova un guadagno: attenzione a data leakage, feedback loop e alla differenza tra chi compra e chi compra grazie a te.
- Per misurare l'effetto di un'azione serve un esperimento (test A/B), non una correlazione.

Un data lake conserva tutto, ma vale solo se sai cosa c'è dentro

Le lezioni precedenti hanno spiegato da dove arrivano i dati e come si dividono tra *batch* (a lotti) e *streaming* (in tempo reale). Oggi la domanda è: dove li metti, in che forma, e che cosa ci fai?

La prima risposta è il *data lake* (lago di dati): un deposito che accoglie grandi quantità di dati **strutturati** (tabelle di vendita), **semi-strutturati** (file JSON o XML) e **non strutturati** (testi, immagini, log), ciascuno nel suo formato originale.

L'immagine è quella di un lago vero: tanti affluenti (database, sensori, log delle macchine, email) che portano acqua continuamente nello stesso bacino.

La differenza con il *data warehouse* (magazzino dati) è il momento in cui decidi la struttura.

- Nel **warehouse** i dati vengono puliti e messi in tabelle **prima** di entrare (*schema-on-write*). Ottimo per report noti in anticipo: le vendite mensili per negozio.
- Nel **lake** i dati entrano così come sono e la struttura si decide **quando li usi** (*schema-on-read*). Ottimo quando non sai ancora quali domande farai.

I vantaggi promessi sono: costo basso per conservare tutto, meno *silos* (archivi chiusi tra reparti), una "vista a 360° del cliente", agilità, basi per il machine learning. Attenzione però: sono **possibilità**, non conseguenze automatiche. Più dati non vuol dire analisi migliori se sono duplicati, sbagliati o non rappresentativi. E la vista a 360° funziona solo se riesci a riconoscere che il "cliente 1" del sito e il "cliente 1" del negozio sono la stessa persona.

Per questo ogni elemento del lago deve avere un identificativo unico e dei *metadata* (metadati): da dove viene, quando è arrivato, in che formato, chi ne è responsabile, che cosa significano le colonne. Un lago senza metadati diventa quello che gli addetti chiamano *data swamp*, una palude: c'è tutto, ma nessuno trova niente e nessuno si fida.

L'idea in una frase

Il data lake ti permette di non decidere subito come usare i dati. Il prezzo è che devi decidere subito come descriverli.

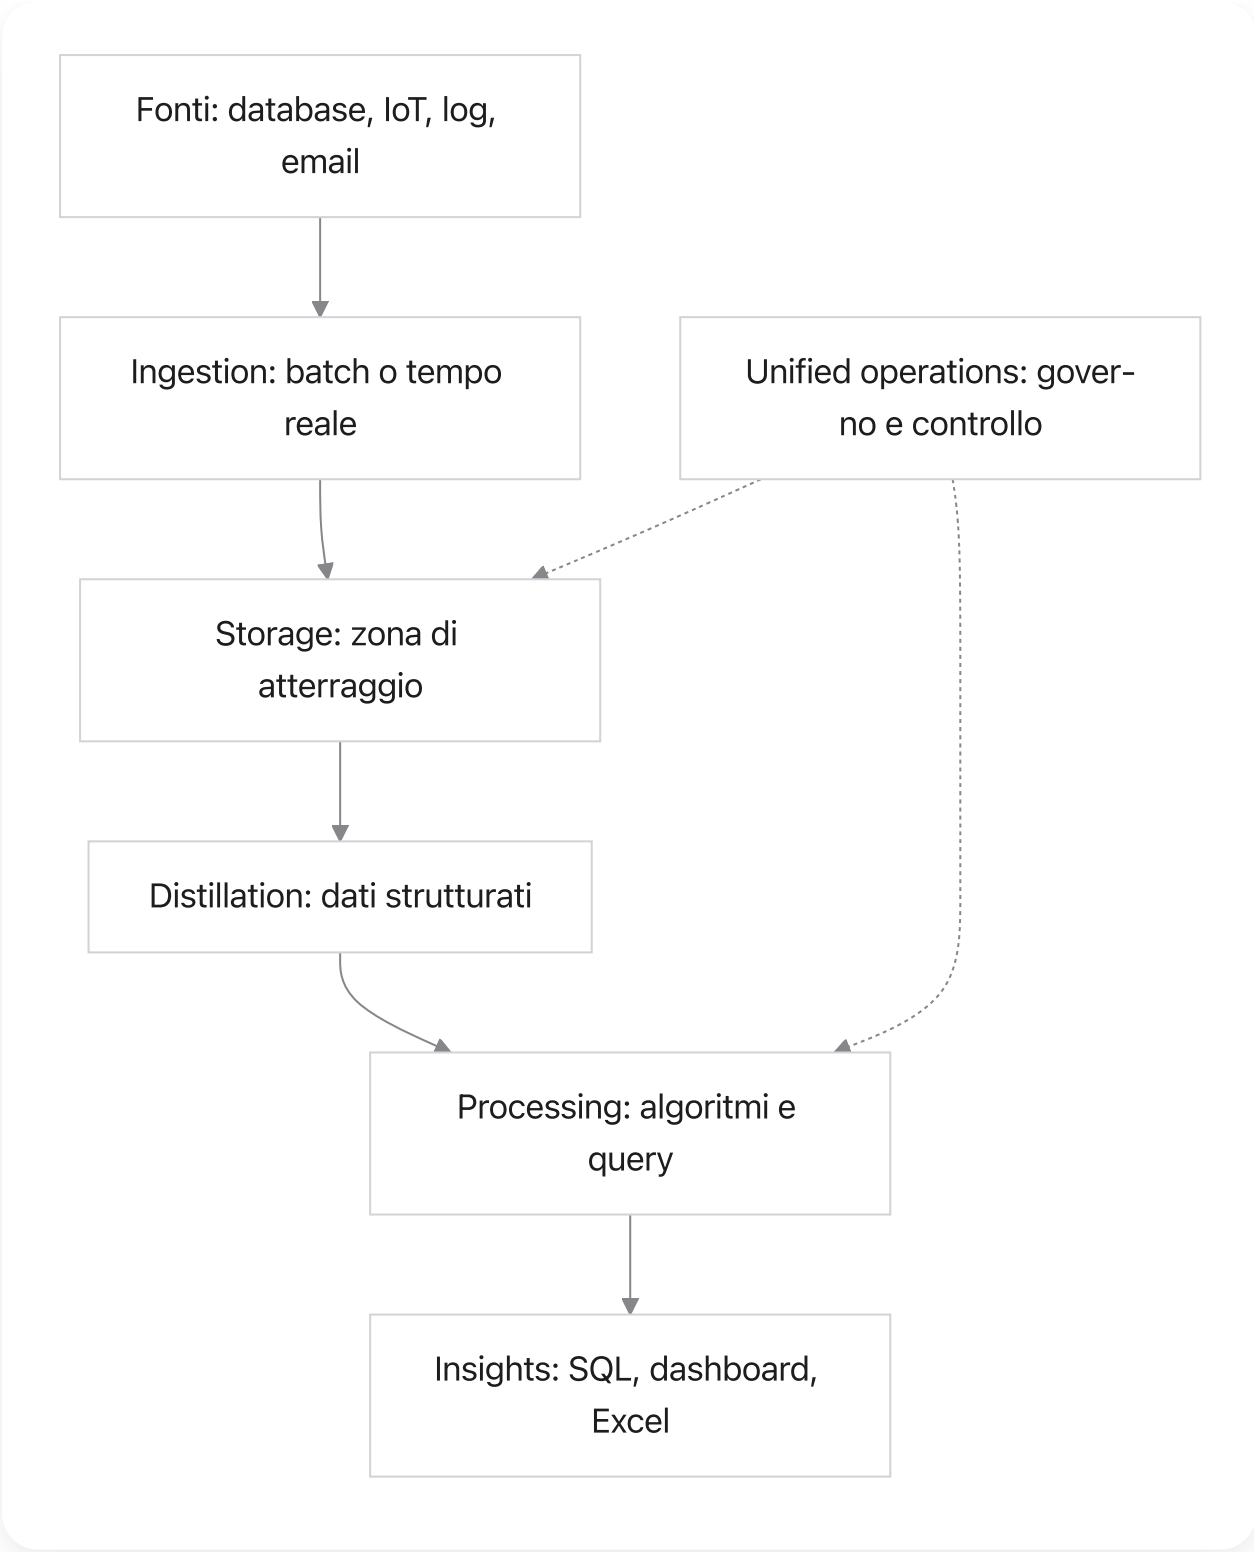
Data lake, data warehouse e lakehouse a confronto (IBM Technology) · apri su YouTube

Prova tu **Una startup ha solo una tabella di vendite e tre report fissi al mese. Le serve un data lake?**

Dall'ingresso all'insight: l'architettura e i suoi guardiani

Il percorso dei dati nel lago si descrive come una serie di livelli (*tier*). In basso ci sono i dati "a riposo", in alto quelli che scorrono in tempo reale.

1. **Ingestion tier** (acquisizione): i dati arrivano dalle fonti, a lotti, in tempo reale o con un caricamento unico.
2. **Storage** (archiviazione): la "zona di atterraggio" dove i dati restano a riposo. Un esempio classico è *HDFS*, il file system distribuito di Hadoop, economico per dati di ogni tipo.
3. **Distillation tier** (distillazione): prende i dati grezzi e li trasforma in dati strutturati, più facili da analizzare.
4. **Processing tier** (elaborazione): esegue algoritmi e interrogazioni, in tempo reale, interattive o a lotti.
5. **Insights tier**: dove le persone usano i risultati, con query SQL o NoSQL o anche con Excel.
6. **Unified operations tier**: governa tutto il sistema con monitoraggio, auditing, gestione dei dati e dei flussi di lavoro.



Intorno all'architettura servono i "guardiani" che fanno funzionare il lago:

- **Data governance**: chi può usare quali dati e chi garantisce che siano disponibili, utilizzabili, sicuri e integri.
- **Security**: va applicata a ogni livello (archiviazione, ricerca, uso). Le funzioni base sono autenticazione (chi sei), autorizzazione (che cosa puoi fare),

accounting (registro di ciò che hai fatto) e protezione dei dati.

- **Data quality**: dati di cattiva qualità producono insight di cattiva qualità. Non c'è tecnologia che lo compensi.
- **Data discovery**: con i *tag* si descrive che cosa c'è nel lago, prima di preparare qualsiasi analisi.
- **Data auditing**: traccia le modifiche agli elementi importanti, cioè come, quando e chi le ha fatte. Serve a valutare rischio e conformità.
- **Data lineage** (genealogia): da dove viene un dato e che cosa gli è successo lungo il percorso. Se un numero nel cruscotto è sbagliato, la lineage ti dice a che punto si è rotto.
- **Data exploration**: la prima fase dell'analisi, che parte dalla scelta del dataset giusto.

Si distinguono quattro **fasi di maturità**: (1) acquisire e gestire dati su larga scala; (2) costruire il "muscolo analitico", cioè trasformare e analizzare i dati con gli strumenti adatti alle competenze del team; (3) warehouse e lake lavorano insieme e i dati arrivano a più persone possibile; (4) il lake acquista capacità "enterprise": governance delle informazioni, gestione del ciclo di vita dei dati, gestione dei metadati. Secondo questo modello, poche organizzazioni arrivano al quarto stadio.

Infine le buone pratiche: supportare i formati originali dei dati, accogliere ciò che è disponibile senza fissare prima lo schema, usare componenti sostituibili collegati da API, gestire separatamente acquisizione, archiviazione, qualità e visualizzazione, adattare l'architettura al settore, aggiungere in fretta le nuove fonti e restare compatibili con i metodi di gestione dati che l'azienda già usa.

Prova tu **Nel cruscotto il fatturato di marzo è raddoppiato da un giorno all'altro. Quale "guardiano" ti aiuta di più a capire perché?**

Stessi dati, quattro formati: scegli in base al lavoro

Prendiamo un dataset minuscolo, tre ascolti musicali, e salviamolo in quattro formati diversi. Il messaggio: non esiste un formato vincitore, esiste quello adatto allo scopo (*fit-for-purpose*).

Formato	Struttura	Superpotere	Limite	Uso tipico
CSV	righe piatte, testo	semplicità, si apre ovunque	i tipi non sono dichiarati (1200 è numero o testo?), virgole nei testi da gestire	esportazioni, scambi rapidi
XML	albero di tag, testo	validazione con uno schema rigoroso	verboso, molti tag ripetuti	messaggi tra sistemi aziendali
JSON	oggetti e liste annidati, testo	flessibile, valori tipizzati, lingua delle API	i nomi dei campi si ripetono in ogni record	log, eventi, app
Parquet	per colonne, binario, compresso	velocità di analisi: legge solo le colonne che servono	non si legge né si modifica a mano	analisi su grandi volumi (lakehouse)

L'esempio rende l'idea. In CSV i tre brani sono tre righe: `101,Nova,IT,1200`. In XML ogni brano è un blocco `<track id="101">` con un tag per ogni campo. In JSON ogni brano è un oggetto che può contenere anche una lista, per esempio `"tags": ["indie", "live"]`: una cosa che il CSV non sa rappresentare senza trucchi. In Parquet i dati sono salvati colonna per colonna: tutti i `country` insieme, tutti gli `streams` insieme. Se vuoi la somma degli stream, il motore legge solo quella colonna, e valori simili vicini si comprimono molto bene.

La scelta si riduce a tre domande: i dati sono **piatti**? devono **modificarli persone**? il lavoro è **analitico**? Piatti e modificabili: CSV. Annidati e per applicazioni:

JSON. Validazione rigorosa: XML. Analisi su larga scala: Parquet. Poi c'è lo schema più comune nei data lake: si **ingeriscono** formati testuali, si **puliscono**, si **pubblicano** in Parquet o Delta (un formato basato su Parquet con funzioni in più).

Perché Parquet è veloce: il formato colonnare spiegato semplice (Data Mozart) · apri su YouTube

Prova tu **Il reparto vendite deve correggere a mano ogni settimana un listino di 200 righe. Parquet o CSV?**

Il laboratorio: una cifra giusta nasce da una regola giusta

Il laboratorio è una sfida pratica su Databricks, usando l'assistente AI con i comandi in linguaggio naturale (*prompting*). Si caricano quattro file in quattro formati diversi: clienti (CSV), prodotti (XML), vendite (JSON), previsioni (Parquet). L'obiettivo: **una vista affidabile** mese × regione × ricavo reale × previsione × scostamento. Le fasi sono cinque: *ingest* (creare le tabelle), *polish* (uniformare codici, date, regioni, quantità e prezzi, lasciando visibili le righe dubbie), *combine* (unire le vendite a clienti e prodotti, calcolare il ricavo, sommare per mese e regione), *compare* (aggiungere la previsione e calcolare scostamento e percentuale di raggiungimento), *present* (un cruscotto per la direzione). E un passaggio che conta più di tutti: il **controllo umano** su numero di righe, chiavi senza corrispondenza e totali.

Esempio svolto · I trabocchetti nascosti nei file del laboratorio

1. **Catalogo prodotti (XML)**: P01 Standard 9,99; P02 Premium 14,99; P03 Live Pack 44,99. Ma **P03 compare due volte**, identico.
2. **Vendite (JSON)**: nove righe, ma la vendita **S008 è ripetuta** identica. In più S001 ha una quantità di 1.200, molto più alta delle altre (80–220): va segnalata e verificata, non cancellata.
3. **Ricavo per vendita** = quantità × prezzo. S001: 1.200 × 14,99 = 17.988,00 (gennaio, regione South). S002: 180 × 9,99 = 1.798,20 (gennaio, North). S006: 100 × 44,99 = 4.499,00 (marzo, North).
4. **Totale corretto**, tenendo una sola copia di P03 e di S008: **35.677,80** unità monetarie (i file non indicano la valuta).
5. **Totale con il join ingenuo**: ogni vendita di P03 si collega a due righe di catalogo (S003 e S006 contate due volte) e S008 resta doppia. Risultato **45.973,80**: 10.296,00 in più, quasi il 29% di ricavo che non esiste.
6. **Confronto con la previsione**: scostamento (*variance*) = reale – previsto; raggiungimento (*attainment*) = 100 × reale / previsto. Se il previsto è zero, il raggiungimento non si calcola: si segnala.

Il file `forecast.parquet` contiene 16 righe: una previsione di ricavo per ogni combinazione di 4 mesi (gennaio–aprile 2026) e 4 regioni (South, North, West, Central), in totale **30.250**. Ecco che cosa esce dal confronto con le vendite puli-
te (le celle senza vendite hanno reale 0):

Mese × regione	Reale	Previsto	Scostamento	Attainment
2026-01 × South	17.988,00	2.200	+15.788,00	817,6%
2026-01 × North	1.798,20	1.700	+98,20	105,8%
2026-02 × South	3.599,20	2.400	+1.199,20	150,0%
2026-02 × West	2.248,50	1.500	+748,50	149,9%
2026-03 × South	1.349,10	2.500	−1.150,90	54,0%
2026-03 × North	4.499,00	1.950	+2.549,00	230,7%
2026-03 × Central	1.998,00	1.800	+198,00	111,0%
2026-04 × West	2.197,80	1.850	+347,80	118,8%
altre 8 celle	0	14.250	−14.250	0%
Totale	**35.677,80**	**30.250**	**+5.427,80**	**117,9%**

Esempio svolto · Leggere la tabella come un analista

1. Il totale dice "sopra il piano del 18%": sembra una buona notizia.
2. Ma più della metà del ricavo viene da una sola vendita, S001 (1.200 abbonamenti Premium a gennaio nel South, 817% del previsto).
3. Senza S001 il reale scende a 17.689,80: il 58,5% del previsto, cioè sotto il piano di oltre il 40%.
4. In più, metà delle celle mese × regione non ha nessuna vendita.
5. Conclusione: prima di festeggiare si verifica S001 (è un contratto vero o un errore di battitura, magari 120 invece di 1.200?). Il numero giusto da mostrare dipende da una verifica, non dal codice.

Prova tu **Il direttore guarda solo la card "Attainment totale 117,9%" della dashboard e vuole alzare il forecast di maggio. Che cosa gli fai vedere prima?**

Formula · Variance e attainment

Variance = actual – forecast (stessa unità monetaria). Positivo = sopra il piano. Attainment % = 100 × actual / forecast, solo se forecast ≠ 0. Esempio: actual 4.499, forecast 4.000 (ipotetico) → variance +499, attainment 112,5%.

L'idea in una frase

Un assistente AI scrive il codice in un secondo; capire se il totale è giusto resta compito tuo.

Prevedere, classificare, personalizzare, automatizzare

La seconda parte della giornata spiega che cosa fa l'AI con i dati. Il filo è un negozio di giocattoli sotto Natale, con un unico "hub" che raccoglie vendite storiche, ricerche e prodotti visti, wishlist e carrello, carta fedeltà, scorte dei negozi e online, prezzi e promozioni, tempi dei fornitori, trend social ed eventi stagionali. Sugli stessi dati si possono fare quattro domande diverse: quante unità di un giocattolo nuovo venderò prima di Natale? questo pagamento online è legittimo o sospetto? quali giocattoli mostrare a questo cliente? devo riordinare un giocattolo che va forte? **È la domanda di business a decidere l'analisi, non i dati.** Le capacità sono quattro, e si distinguono da che cosa producono.

- **Prediction** (previsione) → una **stima** o una probabilità. Esempio: la consegna di un pacco. Il modello combina disponibilità del prodotto, carico del magazzino, storico del corriere, distanza, traffico, meteo e festività, e dice "domani tra le 14 e le 17" o "85% di probabilità entro due giorni" (numeri illustrativi). Si misura con l'errore medio (quanto sbaglio in ore), con la quota di consegne arrivate nella finestra promessa e con la stabilità delle stime.
- **Classification** (classificazione) → un'**etichetta**. Esempio: un pagamento è sospetto o legittimo? Segnali: importo, tipo di negozio, ora e luogo,

dispositivo, abitudini, frequenza. Rischio basso: approvato; medio: verifica aggiuntiva; alto: revisione umana. Qui contano i due errori: il **falso positivo** (blocco un pagamento lecito, cliente infastidito) e il **falso negativo** (lascio passare una frode, perdita). Abbassare la soglia trova più frodi ma crea più falsi allarmi: la soglia si sceglie in base ai costi dei due errori. Nel linguaggio dei modelli, "positivo" significa "ho trovato la cosa che cercavo" (la frode, il cibo avariato, il post da rimuovere), non "cosa buona". Servono metriche adatte: la *precision* (dei pagamenti segnalati, quanti erano davvero frodi?), il *recall* (di tutte le frodi vere, quante ne ho trovate?), il *false-positive rate* (quanto spesso disturbo un cliente onesto) e l'*F1 score*, che bilancia precision e recall. Perché non basta l'accuratezza? Perché le frodi sono rare: un modello che dice sempre "legittimo" sarebbe accurato al 99% e inutile.

- **Personalization** (personalizzazione) → una **classifica** di opzioni per una persona. Esempio: la musica. Ascolti completi, riascolti, skip, like, playlist e contesto (ora, dispositivo) dicono che cosa proporti. I metodi: *content-based* (brani simili a quelli che ascolti), *collaborative filtering* (cosa ascolta chi ti somiglia), *context-aware* (cosa ti serve adesso), *hybrid* (tutti insieme). Rischi: bolla di filtraggio, ripetizione, favorire solo i brani già famosi, privacy.
- **Automation** (automazione) → un'**azione**. Esempio: la richiesta di un mutuo. Si verificano i documenti, si calcola il rapporto rata/reddito (*debt-to-income ratio* = rate mensili dei debiti / reddito mensile lordo; ipotesi: 800 / 3.200 = 25%) e si instrada la pratica. I livelli vanno da *manual* (decide la persona) ad *assisted* (il sistema raccomanda), *supervised* (una persona approva o cambia) e *conditional* (i casi chiari vanno da soli, le eccezioni a una persona). Per decisioni pesanti come un mutuo servono motivazioni comprensibili, registro delle decisioni, test di equità, possibilità di correggere e di fare ricorso.

Il ciclo completo è: dati → prevedere → classificare → personalizzare → agire → **misurare** → imparare, con la governance (qualità, spiegabilità, equità, privacy, supervisione umana, monitoraggio) che attraversa ogni passaggio.

Capacità	Domanda	Metodi tipici	Come si valuta
Prediction	che cosa succederà?	regressione, serie storiche, gradient boosting	errore di previsione, calibrazione
Classification	a che categoria appartiene?	regressione logistica, alberi decisionali, reti neurali	precision, recall, F1
Personalization	che cosa è più rilevante per questa persona?	collaborative filtering, modelli sui contenuti, ranking	coinvolgimento, varietà, soddisfazione
Automation	quale azione eseguire ora?	regole, soglie, orchestrazione	tempo risparmiato, tasso di eccezioni, qualità dell'esito

Quando automatizzare? La regola: conseguenze piccole e reversibili → più automazione; conseguenze gravi e difficili da annullare → più controllo umano. Un suggerimento musicale sbagliato si salta; un mutuo negato no.

Come funziona una raccomandazione basata sui contenuti (start2impact) · apri su YouTube

Collegamento · Lezione del 3 novembre

Falsi positivi e falsi negativi tornano nella lezione del 3/11 con la matrice di confusione, la precision e il recall: lì impari a calcolarli. La lezione del 20/10 mostra invece il primo modello di classificazione, l'albero decisionale.

Prova tu **Spotify che ti propone una playlist per lo studio e un sistema che riordina automaticamente il magazzino quando le scorte scendono: quali capacità sono?**

Predire non è dimostrare: tre trappole prima di festeggiare

Qui arriva la domanda chiave della lezione: stiamo **misurando** cosa preferiscono le persone, **prevedendo** cosa faranno, o **provando** che la nostra azione cambia il loro comportamento? Sono tre cose diverse, e confonderle costa caro.

Trappola 1: popolarità non è personalizzazione. La pizza più venduta non è la pizza giusta per chi è vegano o cerca il prezzo più basso. Una classifica uguale per tutti misura la popolarità; la personalizzazione misura la rilevanza per una persona.

Trappola 2: guardare indietro non è prevedere (data leakage). Un modello può sembrare perfetto perché, senza volerlo, usa informazioni del futuro. Tre esempi: usare le vendite reali di domani per prevedere la domanda di domani; usare il fatto che un video è stato guardato tutto per prevedere se verrà guardato; usare l'ora di arrivo reale per prevedere il ritardo. Il rimedio: fissare il momento della decisione, addestrare sul passato e testare sul periodo successivo.

Trappola 3: il circolo che si autoalimenta (feedback loop). Il sistema raccomanda, le persone vedono, reagiscono, il modello impara da quella reazione. La pizza messa in cima riceve più ordini anche perché è in cima; un prodotto nuovo mai mostrato non riceve clic e quindi "sembra" poco gradito. Rimedi: mostrare ogni tanto opzioni meno esposte, confrontare le risposte tenendo conto dell'esposizione, controllare varietà e soddisfazione nel tempo.

E infine la distinzione più importante: **predire chi comprerà** non è **misurare chi compra grazie a te**. Per la seconda serve un *A/B test*: si assegnano gli utenti **a caso** alla versione attuale (A) o a quella nuova (B), si misura la stessa cosa nello stesso periodo e la differenza stima l'effetto. Esempio ipotetico: 12 acquisti su 100 in B, 10 su 100 in A → +2 punti percentuali. Con campioni così piccoli, però, la differenza può essere dovuta al caso. Due regole pratiche. Primo, **pianifica prima**: decidi metrica, numero di utenti e durata del test prima di guardare i ri-

sultati, altrimenti finisci per fermarti quando il numero ti piace. Secondo, misura la cosa giusta: per uno sconto del 10% sulla pizza non basta contare gli ordini, conta il **profitto per cliente assegnato**, perché lo sconto riduce il margine anche a chi avrebbe ordinato comunque.

Caso reale · eBay e gli annunci che non servivano

eBay spendeva molto in annunci a pagamento sui motori di ricerca, anche sulle parole "ebay" e simili. I dati osservati sembravano dare ragione: chi cliccava sugli annunci comprava. Tre economisti, Thomas Blake, Chris Nosko e Steven Tadelis, hanno fatto esperimenti sul campo con eBay: hanno sospeso gli annunci sul marchio su alcuni motori di ricerca e, per le altre parole chiave, li hanno spenti in alcune zone degli Stati Uniti lasciandoli accesi in altre, confrontando le vendite. Risultato (NBER Working Paper 20171, 2014): gli annunci sul nome del marchio non portavano benefici misurabili nel breve periodo, perché chi cercava "ebay" sarebbe arrivato comunque con il link gratuito. Gli altri annunci funzionavano soprattutto su clienti nuovi o occasionali, mentre la spesa andava in gran parte a clienti abituali che avrebbero comprato lo stesso. Nel contesto studiato il rendimento medio risultava negativo. Lezione: un'azione mostrata a chi è già propenso a comprare sembra efficace anche quando non lo è. Solo un confronto casuale separa la propensione dall'effetto. Il risultato vale per eBay in quel periodo, non per tutta la pubblicità.

Laboratorio · **Il test A/B: differenza vera o caso?**

Utenti per gruppo:

1000



Conversione gruppo A (attuale), %:

10



Conversione gruppo B (nuovo), %:

12



Effetto stimato: **+2.0** punti percentuali · margine di incertezza circa ± **2.7**

La differenza sta dentro il margine: potrebbe essere solo caso. Servono più utenti o un effetto più grande.

Numeri illustrativi. Il margine è un intervallo approssimato al 95% (circa 2 errori standard della differenza tra due proporzioni). Prova a tenere fisso +2 punti e a cambiare il numero di utenti.

Correlazione o causa: perché serve un test A/B (Data36) · apri su YouTube

Imparare dagli errori: quando i dati portano fuori strada

La lezione si chiude con una frase di Samuel Beckett ("Ever tried. Ever failed. No matter. Try again. Fail again. Fail better.") e con tre casi di fallimento. Ognuno insegna un limite diverso.

- **Zillow Offers (2021)**: il portale immobiliare americano comprava case basandosi sulle stime di prezzo del suo algoritmo, per rivenderle. Quando i prezzi si sono mossi in modo inatteso, si è trovato con troppe case pagate troppo. Nel terzo trimestre 2021 ha registrato una svalutazione delle case in magazzino di 304,4 milioni di dollari e il 2 novembre 2021 ha annunciato la

chiusura dell'attività, con un taglio di circa il 25% del personale (documenti ufficiali alla SEC). Lezione: una previsione buona "in media" diventa pericolosa quando su di essa impegni molti soldi; servono limiti di esposizione e attenzione all'incertezza.

- **Amazon e la selezione del personale (2018)**: secondo Reuters, Amazon ha abbandonato un sistema sperimentale che valutava i curriculum perché, addestrato su dieci anni di candidature in prevalenza maschili, penalizzava i curriculum con riferimenti femminili. Lezione: un modello impara anche le ingiustizie del passato; bisogna controllare i risultati per gruppi e le variabili che fanno da "spia" (*proxy*).
- **eBay (2014)**: il caso visto sopra. Lezione: senza un esperimento, scambi chi avrebbe comprato comunque per un effetto della tua azione.

Un modello più preciso non avrebbe risolto nessuno dei tre problemi. Servivano rispettivamente limiti al rischio, controllo delle disparità e una misura causale.

In chiusura era previsto un *warm-up assessment* in classe ("AI & Big Data fundamentals"): le domande non sono nel materiale.

Collegamento · Corso di International Business

Il caso Amazon ha un risvolto internazionale: un modello addestrato sui dati di un paese o di una cultura può funzionare male altrove. Prima di usare lo stesso sistema in mercati diversi bisogna verificare che i dati siano rappresentativi di quei mercati.

Prova tu **Un'azienda dice: "Il nostro nuovo algoritmo di prezzo è più preciso del 15%, quindi non rischiamo più di fare un caso Zillow". È giusto?**

Richiamo a libro chiuso

1. Disegna l'architettura di un data lake dai dati sorgente agli insight, nominando i livelli e il livello di operazioni unificate.
2. Spiega con l'esempio dei tre brani musicali (Nova, Echo) che cosa cambia tra CSV, XML, JSON e Parquet.
3. Racconta come nel laboratorio un prodotto duplicato e una vendita duplicata cambiano il ricavo totale.
4. Spiega la differenza tra predire chi comprerà e misurare chi compra grazie a un'azione, con un esempio.

Quiz

1. Un'azienda di moda vuole conservare foto dei prodotti, recensioni, log del sito e tabelle di vendita, senza sapere ancora quali analisi farà. Che cosa le serve?

- Un data lake, con metadati e catalogo per ogni file
- Un cruscotto BI collegato direttamente alle fonti
- Un unico database relazionale per tutti i reparti
- Un data warehouse, con tabelle fissate prima del carico

2. Dopo due anni un data lake contiene migliaia di file, ma nessuno sa da dove vengono né che cosa significano le colonne. Che cosa è mancato?

- Più capacità di calcolo nel livello di processing
- Un'ingestione in tempo reale invece che a lotti
- Metadati, catalogo dei dati e regole di governance
- Una conversione sistematica dei file in Parquet

3. **Un analista deve calcolare ogni giorno la media degli stream per paese su 2 miliardi di righe con 60 colonne. In che formato pubblichi la tabella finale?**

- CSV, perché si apre con qualunque strumento
- JSON, perché conserva i tipi dei valori
- Parquet, perché legge solo le colonne usate
- XML, perché valida i dati con uno schema

4. **Un negozio online unisce gli ordini al listino tramite il codice prodotto. Nel listino il codice B12 compare due volte, identico. Che cosa succede al ricavo totale?**

- Gli ordini di B12 contano doppio e il ricavo sale
- Il ricavo scende perché B12 resta senza prezzo
- Il join si ferma e segnala la chiave doppia
- Nulla: le due righe identiche si fondono da sole

5. **Un ospedale vuole che un sistema dica, per ogni radiografia, 'sospetta frattura' oppure 'nessuna frattura'. Quale capacità dell'AI usa?**

- Classification: assegna un'etichetta
- Personalization: ordina per paziente
- Prediction: stima una quantità futura
- Automation: esegue un'azione da sola

6. **Un modello prevede se un cliente disdirà l'abbonamento il mese dopo e arriva al 99% di accuratezza. Tra le variabili c'è 'ha compilato il modulo di disdetta'. Che cosa non va?**

- Popolarità: premia i casi più frequenti
- Data leakage: usa un dato che arriva dopo
- Feedback loop: impara dalle proprie scelte
- Overfitting: ha troppi pochi clienti

7. **Una catena di palestre nota che i soci che usano l'app fanno il 40% di ingressi in più. Il direttore vuole renderla obbligatoria per aumentare la frequenza. Che cosa obietti?**

- Va misurato il recall dell'app sui soci
- L'app crea un feedback loop da correggere
- Con migliaia di soci la correlazione basta
- Chi usa l'app era già più motivato: test A/B

8. **In un sistema antifrode un falso positivo costa una telefonata al cliente, un falso negativo una perdita media di 2.000 €. Come imposti la soglia di allarme?**

- La tieni al 50%, che è neutrale
- La abbassi e accetti più falsi allarmi
- La alzi, così riduci i falsi allarmi inutili
- Scegli quella con l'accuracy più alta

Soluzioni del quiz

1. **A** — Dati di tipo diverso e usi futuri non definiti sono il caso tipico del data lake (schema-on-read), purché ogni file sia descritto. Il warehouse è la confusione più comune: funziona quando le domande sono note e i dati sono tabelle, non foto e testi. Un database relazionale impone comunque uno schema prima del carico. Un cruscotto è il livello degli insight: mostra i dati, non li conserva.
2. **C** — Il problema è trovare e fidarsi dei dati: senza metadati e governance il lago diventa una palude (data swamp). Più calcolo velocizza le analisi ma non spiega che cosa c'è nei file. Parquet migliora la velocità, non il significato delle colonne. Il tempo reale cambia quando arrivano i dati, non quanto sono descritti.
3. **C** — Il lavoro è analitico e tocca 2 colonne su 60: Parquet salva per colonne, è compresso e legge solo ciò che serve. JSON è tipizzato ma va letto tutto, record per record. La comodità del CSV vale per file piccoli da toccare a mano. La validazione rigorosa di XML è utile nello scambio tra sistemi, non nella velocità di analisi.
4. **A** — Un join collega ogni ordine a ogni riga con la stessa chiave: due righe B12 raddoppiano ogni ordine B12 e gonfiano il ricavo, senza alcun errore visibile. Il blocco automatico è ciò che molti si aspettano, ma il join non lo fa. Il prezzo non manca, anzi c'è due volte. Le righe identiche non si fondono: vanno tolte con una regola esplicita prima del join.
5. **A** — L'output è un'etichetta tra due categorie: è classificazione. La prediction produce una stima o un tempo (quanti giorni di ricovero). La personalization ordina opzioni per una persona, qui non c'è nulla da ordinare. L'automation agisce (prenota un controllo); potrebbe seguire la classificazione, ma non è la stessa cosa.
6. **B** — Il modulo di disdetta è quasi il risultato stesso e al momento della previsione non c'è ancora: il modello sbircia il futuro e in produzione crollerà. Il feedback loop riguarda sistemi che influenzano i dati con cui poi imparano. L'overfitting non spiega un punteggio così alto con una variabile del genere. La popolarità è un problema delle raccomandazioni uguali per tutti.
7. **D** — È una correlazione: chi scarica l'app è probabilmente già più assiduo. Solo assegnando a caso l'app (o una sua funzione) a un gruppo si misura l'effetto. Tanti dati non trasformano una correlazione in una causa. Il recall è una metrica di classificazione, non misura effetti. Il feedback loop riguarda le raccomandazioni, non questo confronto.
8. **B** — Se il falso negativo costa molto più del falso positivo conviene segnalare di più, entro la capacità di chi controlla. Alzare la soglia ottimizza l'errore sbagliato, quello che costa poco. Il 50% non tiene conto dei costi. L'accuracy è dominata dai pagamenti normali: un modello che non segnala nulla sarebbe accurato al 99%.

Applica a un caso nuovo

Caso ipotetico. Una catena di pizzerie con app vuole: (1) unire ordini (JSON dall'app), menu (XML dal fornitore del gestionale) e clienti (CSV dal CRM) per un cruscotto mensile per città; (2) mandare uno sconto del 20% ai clienti 'a rischio

di non tornare' e dimostrare al CFO che lo sconto funziona. Come imposti il lavoro?

Mostra una soluzione ragionata

Decidi tu

Il cruscotto che non torna

Hai costruito con l'assistente AI di Databricks il cruscotto mese × regione. Il ricavo totale è 45.973,80, ma l'ufficio vendite dice che dovrebbe essere intorno ai 35.000. La presentazione al direttore è tra un'ora.

Che cosa fai?

Presenti comunque: il codice l'ha scritto l'AI, sarà giusto

Rischiosa. Porti un numero gonfiato di oltre 10.000: un prodotto duplicato nel catalogo e una vendita duplicata moltiplicano le righe del join.

Controlli righe prima e dopo il join, chiavi duplicate e totali; togli i doppioni e dichiari la regola usata

Scelta solida. Trovi P03 doppio e S008 doppia, il totale scende a 35.677,80 e puoi spiegare perché. È il controllo umano (human checkpoint) del laboratorio.

Cancelli la vendita S001 da 1.200 pezzi perché sembra strana

Rischiosa. Un valore anomalo va segnalato e verificato, non cancellato: potrebbe essere vero. E comunque non spiega l'errore principale, che sono i

duplicati.

Una vista affidabile nasce dalla pulizia di chiavi e duplicati e da un controllo umano sui totali, anche quando il codice lo scrive un assistente AI.

Lo sconto che sembra funzionare

Sei l'analista di un'app di delivery. Il modello individua i clienti più propensi a ordinare nel weekend e il marketing manda loro un coupon. Il 40% usa il coupon. Il marketing chiede più budget.

Che cosa consigli?

Più budget subito: il 40% è un ottimo risultato

Rischiosa. Il modello sceglie proprio chi avrebbe ordinato comunque: molti coupon sono sconti regalati, e il margine scende.

Un test A/B: metà dei clienti selezionati riceve il coupon, metà no, e confronti il profitto per cliente

Scelta solida. Separi chi compra grazie al coupon da chi avrebbe comprato comunque, e misuri il guadagno vero al netto degli sconti.

Mandare il coupon a tutti i clienti per avere più dati

Rischiosa. Aumenti costi e rumore senza un gruppo di confronto: continui a non sapere se il coupon funziona.

Predire chi comprerà non è dimostrare che la tua azione fa comprare: per l'effetto serve un confronto casuale.

Da vedere

Documentario · 2020

Coded Bias

Algoritmi che imparano dai dati del passato e ne ripetono le discriminazioni: lo stesso rischio del sistema di selezione del personale di Amazon visto nella lezione.

Dove: Netflix

Documentario · 2020

The Social Dilemma

Mostra dall'interno personalizzazione e feedback loop: il feed impara da ciò che ti mostra e ti mostra sempre più di ciò che ha imparato.

Dove: Netflix

Flashcard

Che cos'è un data lake?

Un deposito di dati di ogni tipo nel formato originale, analizzati in seguito con schema-on-read.

Data lake o data warehouse: differenza chiave?

Nel lake la struttura si decide alla lettura; nel warehouse i dati sono puliti e strutturati prima di entrare.

Che cosa fa il distillation tier di un data lake?

Trasforma i dati grezzi in dati strutturati, più facili da analizzare.

Che cosa traccia il data auditing?

Le modifiche agli elementi importanti: come, quando e chi le ha fatte. Serve a rischio e conformità.

Che cosa si perde senza metadati in un data lake?

La possibilità di trovare i dati e di fidarsene: il lago diventa una palude (data swamp).

Perché Parquet è veloce per l'analisi?

Salva i dati per colonne e compressi: una query legge solo le colonne che le servono.

Che cosa sa fare JSON che CSV non sa fare?

Rappresentare dati annidati, per esempio una lista di tag dentro un record.

Formula della variance?

Variance = actual − forecast; positiva significa sopra il piano.

Formula dell'attainment?

Attainment % = 100 × actual / forecast; se il forecast è zero non si calcola, si segnala.

Che cosa misura la precision?

Dei casi segnalati dal modello, quanti erano davvero il target.

Che cosa misura il recall?

Di tutti i casi target reali, quanti il modello ne ha trovati.

Prediction o classification: che cosa producono?

La prediction una stima o una probabilità; la classification un'etichetta.

Personalization o automation: che cosa producono?

La personalization una classifica di opzioni per una persona; l'automation un'azione.

Che cos'è il data leakage?

Usare in addestramento informazioni che al momento della decisione non ci sono: il punteggio è gonfiato.

Che cos'è un feedback loop nelle raccomandazioni?

Ciò che è mostrato riceve più clic e il modello lo mostra ancora di più: i clic non sono preferenze pure.

Come si misura se un'azione cambia il comportamento?

Con un test A/B: gruppi assegnati a caso, stessa metrica, stessa finestra; effetto = risultato B − risultato A.

Glossario

Data lake · lago di dati
Deposito che accoglie dati di ogni tipo (tabelle, JSON, testi, immagini, log) nel loro formato originale, per analizzarli in seguito.

Data warehouse · magazzino dati
Deposito di dati già puliti e organizzati in tabelle per analisi note in anticipo, per esempio i report di vendita mensili.

Schema-on-read · struttura decisa alla lettura
I dati entrano così come sono e la loro struttura si definisce solo quando qualcuno li interroga. Il contrario è schema-on-write, tipico del data warehouse.

Metadata · metadati
Dati che descrivono i dati: provenienza, formato, data, proprietario, significato. Senza metadati un file nel lago è introvabile o inutilizzabile.

Data governance · governo dei dati
Regole e responsabilità che garantiscono disponibilità, usabilità, sicurezza e integrità dei dati. Esempio: chi può vedere i dati dei clienti e chi li corregge.

Data lineage · genealogia del dato
Il percorso di un dato dall'origine alla destinazione, con tutte le trasformazioni: serve a trovare dove è nato un errore.

Ingestion · acquisizione
Caricamento dei dati nel lago dalle fonti (database, server web, email, sensori IoT, FTP), a lotti (batch), in tempo reale o una tantum.

Parquet · formato colonnare Parquet

Formato di file binario e compresso che salva i dati per colonne: un'analisi che usa solo 2 colonne su 50 legge solo quelle.

JSON · notazione a oggetti JavaScript

Formato testuale con oggetti e liste annidate, lingua comune delle API e dei log di eventi. Esempio: un brano con un elenco di tag.

Join · unione di tabelle

Operazione che collega due tabelle tramite una chiave comune, per esempio vendite e prodotti tramite product_id. Se la chiave è duplicata, le righe si moltiplicano.

Data leakage · fuga di informazioni

Il modello usa, in addestramento, informazioni che al momento della decisione non avrebbe, come le vendite reali di domani per prevedere la domanda di domani.

Feedback loop · circolo di retroazione

Il sistema raccomanda, le persone reagiscono a ciò che vedono e il modello impara da quelle reazioni: ciò che è più mostrato sembra sempre più gradito.

A/B test · esperimento A/B

Si assegnano a caso gli utenti a due versioni (A attuale, B nuova) e si confronta lo stesso risultato: la differenza stima l'effetto della novità.

False positive / false negative · falso positivo / falso negativo

Falso positivo: segnalo un problema che non c'è (blocco un pagamento lecito). Falso negativo: non segnalo un problema che c'è (lascio passare una frode).

Video consigliati

Data Lake vs. Data Warehouse vs. Data Lakehouse: Which One to Choose?

IBM Technology · 8 min · EN

Le tre architetture a confronto alla lavagna: chiarisce la differenza tra lake e warehouse.

Data Warehouse vs Data Lake vs Lakehouse: Which One Should You Build?

Data with Baraa · 19 min · EN

Versione più lunga e visiva, con esempi di quando scegliere ciascuna architettura.

Parquet File Format - Explained to a 5 Year Old!

Data Mozart · 11 min · EN

Perché salvare per colonne rende Parquet veloce e compatto: completa la parte sui formati.

Content Based Recommendation: Come Funziona (Intelligenza Artificiale)

start2impact · 8 min · IT

In italiano: come un sistema di personalization propone contenuti simili a quelli che hai già apprezzato (metodo content-based).

A/B Testing Course 004: The Correlation vs. Causation Problem

Data36 · 5 min · EN

In cinque minuti perché una correlazione non basta e serve un esperimento.

Fonti

1. Slide Canvas 133640 — Rizzi, BigDataBsnsRizzi2026Lesson4 (42 pagine) — Data lake pp. 2–14, formati pp. 15–23, laboratorio pp. 24–25, capacità AI pp. 26–32, previsione vs causalità pp. 33–38, casi di errore pp. 39–40, warm-up p. 41.
2. Canvas 133641 — Databricks Mixed Formats Lab Data (ZIP) — customers.csv, products.xml, sales.json letti il 5/11/2026; forecast.parquet decodificato il 6/11/2026 (16 righe, totale previsto 30.250); ricavi, scostamenti e attainment ricalcolati.
3. Archivio Codex 2026-10-13__spiegazione-estesa.md — Usato solo come appunto per le slide-immagine (pp. 27–32, 34–38, 40); non copiato.
4. Blake, Nosko, Tadelis — Consumer Heterogeneity and Paid Search Effectiveness: A Large Scale Field Experiment, NBER WP 20171 (2014)
5. Apache Parquet — documentazione ufficiale
6. Reuters, 10/10/2018 — Amazon scraps secret AI recruiting tool that showed bias against women
7. Zillow Group — Form 10-Q, terzo trimestre 2021 (svalutazione scorte Zillow Offers di 304,4 milioni di dollari)
8. Zillow Group — Form 8-K del 2 novembre 2021 (chiusura Zillow Offers)

Note di verifica