03 novembre 2026

Dal modello al reparto: misurare bene un modello e costruire un team analytics che il CEO usi davvero

Big Data Pipelines, Model Evaluation and 'The CEO Wants Answers' — designing an enterprise analytics department

Martedì · Rizzi, Campana · Completa

Lezione ricostruita dai materiali. Nessuna registrazione PLAUD per questa lezione (slot Campana 10:00–11:30 e Rizzi 12:00–13:30; ricontrollato l'elenco PLAUD il 6/11: nessuna registrazione il 3/11). Fonte d'aula: slide Canvas 134187 'BigDataBsnsRizzi2026Lesson6' (46 pagine, caricate il 2/11), spiegate tutte: pipeline di machine learning, valutazione dei modelli, esercitazione 'The CEO wants answers' con le carte degli imprevisti. Le slide 4–12 sono immagini e sono state lette come tali. Integrazione dal programma del corso (agenda 'Lesson 6 — How Machine Learning Really Works'): feature contro label, divisione training/validazione/test e il teamwork 'valutare due modelli predittivi con metriche diverse', ricostruito qui con un esempio svolto. Il pacchetto 134188 (IoT, fog, edge e cloud), caricato lo stesso giorno, è assegnato alla lezione del 4/11.

In breve

Lezione in due blocchi. Il primo spiega come si costruisce una pipeline di machine learning (raccolta, pulizia, feature, addestramento, valutazione, messa in produzione) e soprattutto come si misura un modello senza farsi ingannare: accuracy, precision, recall, F1, overfitting e test onesti. Il secondo è un caso aziendale: un CEO con "dashboard ovunque" non capisce perché calano i profitti, e tu devi progettare in 90 giorni, con cinque persone, un reparto analytics che risponda alle domande giuste.

- Una pipeline di ML ha cinque fasi: raccolta dati, preprocessing, addestramento, valutazione, deployment con monitoraggio.

- Accuracy da sola inganna quando i casi positivi sono rari: servono precision (quanti allarmi sono veri) e recall (quanti casi veri trovo), sintetizzati dall'F1.
- Overfitting: il modello impara il rumore del training e sbaglia su dati nuovi; underfitting: è troppo semplice e sbaglia ovunque.
- Una valutazione onesta separa training, validazione e test, confronta con una baseline semplice ed evita il leakage.
- Un reparto analytics parte da decisioni, non da dati: ogni domanda ha un proprietario, un'azione e un orizzonte temporale.
- I casi d'uso si scelgono con un punteggio (valore, fattibilità, dati pronti, adozione) ma i vincoli bloccanti vengono prima.
- Il modello hub-and-spoke unisce standard centrali e analisti vicini al business; il RACI chiarisce chi decide cosa.
- Il successo si misura su consegna, fiducia, adozione e risultato economico, non sul numero di dashboard.

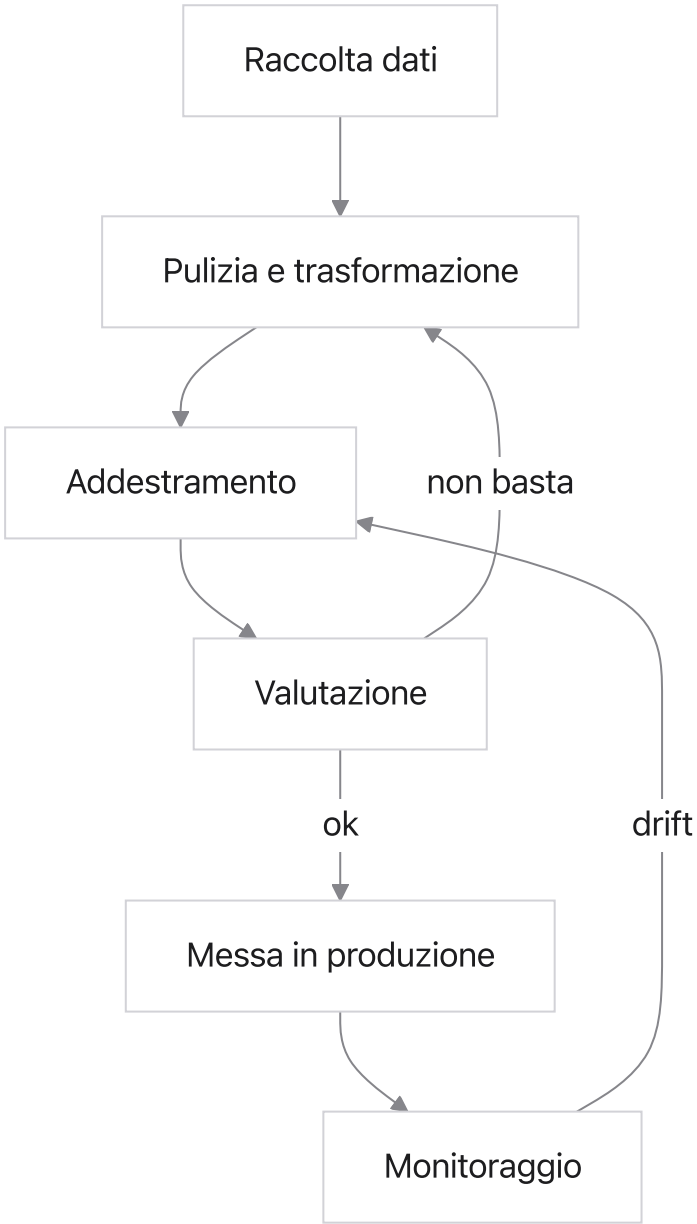
Una pipeline è una catena: se un anello è debole, cede tutto

La lezione riprende il filo delle settimane scorse. Il 20 ottobre abbiamo visto alberi decisionali e clustering, cioè i *modelli*. Oggi la domanda è: come si porta un modello dall'idea alla produzione, e come si capisce se funziona davvero?

La risposta è la *pipeline* (catena di lavorazione dei dati): una sequenza di passaggi, il più possibile automatizzati, che porta i dati dalla raccolta fino a un modello che lavora ogni giorno. Le fasi sono cinque:

1. **Data collection** (raccolta): mettere insieme dati da fonti diverse, controllandone qualità e varietà.
2. **Data preprocessing** (preparazione): pulire e trasformare i dati perché il modello possa usarli.

3. **Model training** (addestramento): scegliere un algoritmo e farlo imparare sui dati preparati.
4. **Model evaluation** (valutazione): misurare le prestazioni con metriche adatte e correggere.
5. **Deployment** (messa in produzione): rendere il modello parte del lavoro quotidiano, con monitoraggio e manutenzione.



Le frecce che tornano indietro sono il punto: una pipeline non è una linea retta. Se la valutazione è deludente si torna ai dati; se in produzione le prestazioni ca-

lano si riaddestra.

Da dove vengono i dati. Le fonti tipiche sono sei: *survey* (sondaggi ben costruiti), *web scraping* (raccolta automatica da siti), *API* (canali con cui un servizio fornisce dati in tempo reale), *database* aziendali con lo storico, *log* applicativi (le tracce di ciò che gli utenti fanno su un'app o un sito) e *interviste*, che danno informazioni qualitative. È lo stesso discorso della lezione del 29 settembre sulle fonti e sul batch contro streaming: qui le fonti diventano il primo anello della catena.

Come si preparano. Il preprocessing ha sette passi: rimuovere i dati irrilevanti, gestire i valori mancanti, normalizzare (portare le variabili su una scala comune), codificare le variabili categoriche in numeri (ad esempio "Milano/Roma/Napoli" in colonne 0/1), dividere il dataset in training e test, selezionare le variabili importanti, verificare l'integrità finale.

L'idea in una frase

Un modello non è migliore dei dati che lo nutrono: la maggior parte del lavoro, e degli errori, sta prima dell'algoritmo.

Le variabili giuste valgono più dell'algoritmo più potente

Il *feature engineering* (costruzione delle variabili) è l'arte di trasformare dati grezzi in informazioni che il modello può usare. Ha quattro effetti tecnici: migliora l'accuratezza, riduce l'overfitting eliminando variabili inutili, rende compatibili i dati categorici, uniforma le scale. E quattro benefici di business: prestazioni migliori, modelli più robusti, scoperta di schemi utili alle decisioni, ritorno sull'investimento più chiaro.

Esempio svolto · Dalla data alla variabile utile (ipotetico)

1. Hai la colonna "data della prenotazione" e "data della cena".
2. Da sole dicono poco al modello: sono solo date.
3. Crei "giorni di anticipo" = data cena – data prenotazione.
4. Crei "giorno della settimana" della cena e "prenotazione fatta di notte sì/no".
5. Ora il modello può scoprire, per esempio, che chi prenota con molto anticipo per il sabato disdice di più. Il dato era già lì: lo hai reso leggibile.

Che modello scegliere. Due famiglie a confronto. Gli **alberi decisionali** (che conosciamo dal 20 ottobre) sono facili da interpretare e da disegnare, gestiscono bene i valori mancanti e sono veloci da addestrare, ma vanno in overfitting se non si limita la profondità. Le **reti neurali** catturano relazioni complesse in grandi dataset e richiedono meno feature engineering, perché imparano da sole gli schemi, ma costano molto in calcolo e tempo e, se non regolate bene, generalizzano male. In azienda la scelta dipende anche da quanto devi **spiegare** la decisione: a un cliente a cui neghi un prestito devi saper dire perché.

Gli iperparametri. Sono le impostazioni scelte prima dell'addestramento, come la profondità massima di un albero. Si regolano con la *grid search* (provare in modo esaustivo tutte le combinazioni di una griglia definita a mano), la *random search* (provare combinazioni a caso, spesso più veloce), l'ottimizzazione bayesiana (usare un modello probabilistico per scegliere le prove più promettenti), sempre valutando con la cross-validation e con metriche adatte.

Attenzione

La slide sulle "best practices" riporta numeri come +15% di accuracy con il tuning, 3 dollari di ritorno per ogni dollaro speso in etichettatura, –30% di tempo di addestramento, +25% di engagement. Le slide non indicano la fonte: prendili come esempi di ordine di grandezza, non come dati da citare all'esame.

Prova tu **Perché in banca si sceglie spesso un albero invece di una rete neurale, anche se è un po' meno preciso?**

L'accuracy può mentire: precision, recall e F1

È il cuore tecnico della lezione. Prendiamo un esempio concreto: prevedere le **disdette delle prenotazioni** di un ristorante. "Positivo" significa "il cliente disdice". Su 100 prenotazioni:

	Disdice davvero	**Viene davvero**
Il modello dice: disdice	TP = 15	FP = 10
Il modello dice: viene	FN = 5	TN = 70

Questa tabella si chiama *confusion matrix* (matrice di confusione). TP e TN sono le previsioni giuste; FP è un falso allarme; FN è una disdetta che il modello non ha visto.

Formula · Le quattro metriche

- **Accuracy** = (TP + TN) / totale = (15 + 70) / 100 = **85%**. Quante previsioni sono giuste in generale.
- **Precision** = TP / (TP + FP) = 15 / 25 = **60%**. Delle prenotazioni segnalate, quante disdicono davvero.
- **Recall** = TP / (TP + FN) = 15 / 20 = **75%**. Di tutte le disdette, quante ne troviamo.
- **F1** = 2 × P × R / (P + R) = 2 × 0,60 × 0,75 / 1,35 ≈ **66,7%**. Media armonica: è alta solo se lo sono entrambe.

Ora la **trappola dell'accuracy**. Nel campione disdice il 20% (20 su 100). Un modello pigro che dice sempre "viene" sbaglia solo quei 20: accuracy **80%**.

Sembra quasi buono come il nostro, ma il suo recall è **0%**: non trova nessuna disdetta. Ecco perché, quando i casi che ti interessano sono rari (frodi, abbandoni, guasti), l'accuracy è quasi inutile.

The Confusion Matrix (StatQuest, 7 min) · apri su YouTube

Quale metrica privilegiare dipende dal **costo degli errori**. Se un falso allarme costa poco e un caso perso costa tanto (frodi, malattie), si punta sul recall. Se ogni allarme genera un'azione costosa (mandare un tecnico, fare uno sconto), si punta sulla precision.

Laboratorio · Matrice di confusione: muovi i numeri

Veri positivi (TP) **15**

Falsi positivi (FP) **10**

Falsi negativi (FN) **5**

Veri negativi (TN) **70**

Accuracy 85.0% · Precision 60.0% · Recall 75.0% · F1 66.7%

Valori di partenza: l'esempio delle disdette delle slide. Prova a portare TP a 0 e FN a 20: l'accuracy resta alta, il recall crolla.

Esempio svolto · Correggere una tabella delle slide

La slide "Model Evaluation Metrics" confronta quattro modelli. Ricalcoliamo l'F1 del modello A: precision 80%, recall 82%. 1. Prodotto: 0,80 × 0,82 = 0,656; per due: 1,312. 2. Somma: 0,80 + 0,82 = 1,62. 3. F1 = 1,312 / 1,62 ≈ **0,81**, non 0,84 come in tabella. Allo stesso modo: B ≈ 86,5% (non 89%), C ≈ 77%, D ≈ 84%. Inoltre il commento dice "recall di C al 78%", ma 78% è la sua accuracy. La conclusione resta: B è il migliore su tutte le metriche. Lezione pratica: ricalcola sempre i numeri che ti presentano.

Matrice di confusione, precisione e richiamo (Piero Savastano, 9 min, IT) · apri su YouTube

Due modelli a confronto: vince chi sbaglia meno dove costa

Il programma del corso per questa lezione ("How Machine Learning Really Works") mette in fila tre idee che le slide danno per scontate e un esercizio di gruppo: valutare due modelli predittivi con metriche diverse. Vale la pena fissarle.

Feature e label. Ogni riga dei dati storici ha due parti. Le *feature* (variabili in ingresso) sono gli indizi: giorni di anticipo, numero di persone, canale di prenotazione. La *label* (etichetta) è la risposta giusta, già nota nel passato: la prenotazione è stata disdetta oppure no. Il modello impara il legame tra indizi e risposta; in produzione vedrà solo gli indizi. Da qui la regola anti-leakage: una feature è ammessa solo se, nel momento reale della previsione, la conosceresti già.

Tre pile di dati. I dati etichettati si dividono in tre parti, spesso intorno a 70% / 15% / 15%: il *training set* per imparare, il *validation set* per scegliere tra modelli e impostazioni, il *test set* da aprire una volta sola, alla fine, per misurare il modello scelto. Se guardi il test più volte e intanto aggiusti il modello, il test diventa un secondo training e il punteggio finale smette di essere onesto.

Il confronto. Due modelli possono "vincere" su metriche diverse. Quale scegli dipende dal costo degli errori, non dal numero più alto.

Esempio svolto · **Churn: il modello con meno accuracy che fa guadagnare di più (numeri ipotetici)**

Una compagnia telefonica ha 1.000 clienti nel test; 50 se ne andranno davvero. Ogni cliente perso vale 500 € di margine. Contattare un cliente con un'offerta costa 20 € e ne trattiene la metà di quelli che stavano per andarsene. 1. **Modello A**: TP 40, FN 10, FP 160, TN 790. Accuracy (40+790)/1.000 = **83%**; precision 40/200 = **20%**; recall 40/50 = **80%**; F1 = 2×0,2×0,8/1,0 = **32%**. 2. **Modello B**: TP 20, FN 30, FP 10, TN 940. Accuracy (20+940)/1.000 = **96%**; precision 20/30 ≈ **67%**; recall 20/50 = **40%**; F1 ≈ **50%**. 3. Sulle metriche B sembra migliore (accuracy e F1 più alte). 4. Ora il valore. A contatta 200 clienti: costo 200 × 20 = 4.000 €; trattiene 40 × 0,5 = 20 clienti, cioè 20 × 500 = 10.000 €. Netto **+6.000 €**. 5. B contatta 30 clienti: costo 600 €; trattiene 20 × 0,5 = 10 clienti = 5.000 €. Netto **+4.400 €**. 6. Conclusione: qui un falso allarme costa poco (20 €) e un abbandono perso costa tanto (500 €), quindi vince il recall. Se l'offerta costasse 200 € a cliente, il conto si ribalterebbe: A spenderebbe 40.000 € per recuperarne 10.000. Prima di scegliere il modello, scrivi quanto costa ogni tipo di errore.

Prova tu **Il team ha provato 40 versioni del modello guardando ogni volta il punteggio sul test set, e alla fine riporta "F1 = 0,78 sul test". Ti fidi?**

Imparare a memoria non è imparare: overfitting e test onesti

L'obiettivo di un modello è imparare schemi che funzionano anche su **dati mai visti**. Si vede bene con due curve: l'errore sul training e l'errore sulla validazione, al crescere della complessità del modello.

- **Underfitting**: il modello è troppo semplice. Sbaglia tanto sia sul training sia sulla validazione. Rimedio: variabili più ricche o un modello più flessibile.
- **Overfitting**: il modello impara anche il rumore del training. L'errore sul training scende, quello sulla validazione risale. Rimedio: regolarizzazione (penalizzare la complessità), modelli più semplici, dati più rappresentativi.

Il punto giusto è in mezzo, dove l'errore sulla validazione è minimo.

Overfitting, underfitting e dati sporchi (IBM Technology, 7 min) · apri su YouTube

Una valutazione onesta ha quattro tempi: *train* (si adattano modello e preprocessing ai dati di addestramento), *validate* (si confrontano modelli e impostazioni su dati di validazione o con cross-validation), *test* (si misura il modello scelto su dati mai toccati, confrontandolo con una *baseline* semplice), *monitor* (dopo il deployment si seguono errori e cambiamenti nei dati in arrivo).

Prima di fidarsi di un punteggio servono quattro controlli sui dati: valori mancanti o impossibili (unità sbagliate, date assurde); etichette sbagliate o duplicati finiti sia nel training sia nel test; copertura e freschezza (gruppi di clienti assenti, comportamenti vecchi); *leakage*, cioè informazioni che al momento della previsione non avresti. Regola d'oro: **lo split deve imitare la realtà**. Per prevedere il futuro, alleni sul passato e testi sui periodi più recenti; tieni insieme i dati della stessa entità (tutte le prenotazioni dello stesso cliente da una parte sola).

Caso reale · Zillow Offers: quando il mondo cambia più in fretta del modello (2021)

Zillow, il grande portale immobiliare americano, usava un algoritmo di stima dei prezzi per comprare case, sistemarle e rivenderle (Zillow Offers). Nel 2021, con il mercato reso instabile dalla pandemia, il modello ha sopravvalutato molte case: Zillow ha comprato troppo caro. Il 2 novembre 2021 il consiglio ha deciso di chiudere l'attività, citando l'imprevedibilità dei prezzi; l'azienda ha registrato una svalutazione delle scorte di 304 milioni di dollari nel terzo trimestre (407,9 milioni nell'intero 2021) e ha tagliato circa il 25% del personale. È l'esempio classico di *model drift* e del rischio di affidare decisioni da miliardi a un modello senza monitoraggio e freni.

Restano le sfide comuni nel costruire pipeline: qualità dei dati incoerente, scalabilità con grandi volumi, *model drift* (prestazioni che calano nel tempo), complessità di integrazione tra sistemi, risorse insufficienti, vincoli di compliance (pensiamo al GDPR).

Prova tu **Un modello di churn ha 95% di accuracy. Ti basta per lanciare una campagna?**

Il CEO ha dashboard ovunque e non capisce niente

La seconda metà delle slide è un caso di gestione: "The CEO wants answers". Un'impresa immaginaria ha dati frammentati e margini in calo. Il CEO dice: "Abbiamo dashboard ovunque. Eppure non capisco perché calano i profitti, quali clienti potrebbero andarsene e che cosa dovremmo fare." Il tuo mandato: progettare un reparto capace di rispondere a domande importanti **in modo ripetibile**. I vincoli: cinque assunzioni e 90 giorni per dimostrare valore.

La prima domanda non è "che tecnologia compro?" ma **"quale decisione aziendale deve cambiare?"**. Il progetto si organizza in tre scelte di disegno

(perché: una missione legata a decisioni reali; cosa: un modello operativo con responsabilità chiare; chi: un team adatto ai primi casi d'uso) e tre condizioni di successo (un processo di consegna ripetibile; dati affidabili e controlli proporzionati; adozione e prove di valore). Se ne manca una, le altre crollano.

Da preoccupazione a domanda. Una buona domanda analitica identifica un'azione, un proprietario e un orizzonte:

Preoccupazione del CEO	Domanda analitica	Chi decide e cosa fa
I profitti calano	Quali prodotti, clienti o canali spiegano il calo del margine?	CFO o commerciale: rivede prezzi o costi
I clienti se ne vanno	Quali clienti hanno alto rischio di abbandono il mese prossimo?	Responsabile retention: testa un intervento mirato
Il servizio è lento	Dove si accumulano i ritardi nel processo?	Operations: cambia personale o flusso

Quale tipo di analytics. Tornano utili i quattro livelli: *descrittiva* (che cosa è successo: KPI, aggregazioni, grafici), *diagnostica* (perché: drill-down, segmentazione, test di ipotesi), *predittiva* (che cosa succederà: regressione, classificazione, previsioni), *prescrittiva* (che cosa fare: ottimizzazione, simulazione, esperimenti). Il CEO ha bisogno di una previsione, di una spiegazione o di una raccomandazione?

Le regole del gioco. Il reparto nasce con un *analytics charter* (statuto): missione (per esempio "aiutare commerciale e finanza a migliorare la redditività dei clienti"), sponsor e clienti interni, servizi offerti e confini, percorso di escalation, budget, diritti decisionali e misure di successo. Deve dire anche che cosa il reparto **non** fa. Ogni richiesta entra con un *intake brief* (scheda di richiesta) uguale per tutti: decisione e proprietario, risultato atteso e punto di partenza, utenti e flusso di lavoro, dati e vincoli, criteri di accettazione e supporto.

Scegliere da dove partire, e con chi

Il punteggio dei casi d'uso. Si valuta ogni progetto da 1 a 5 su quattro criteri pesati: valore 40%, fattibilità 25%, dati pronti 20%, adozione 15%. Ma i controlli obbligatori e le dipendenze critiche vengono prima: sono cancelli, non punti.

Esempio svolto · Il punteggio dei tre candidati (dati delle slide)

1. Dashboard di redditività: 4, 5, 4, 5 → 0,4×4 + 0,25×5 + 0,2×4 + 0,15×5 = 1,6 + 1,25 + 0,8 + 0,75 = **4,40**.
2. Modello di churn: 5, 2, 2, 3 → 2,0 + 0,5 + 0,4 + 0,45 = **3,35** (le slide arrotondano a 3,40).
3. Piattaforma dati aziendale: 4, 2, 3, 2 → 1,6 + 0,5 + 0,6 + 0,3 = **3,00**.
4. Decisione proposta: partire con un prodotto di redditività mirato, costruendo sotto un lavoro sui dati riutilizzabile. Il churn ha il valore più alto ma dati e fattibilità deboli: torna in gioco se arrivano prove che i dati sono pronti.

Come organizzarsi. Tre modelli. *Centralizzato*: competenze, standard e visione d'insieme condivisi, ma la coda unica diventa un collo di bottiglia. *Decentralizzato*: analisti vicini alle decisioni locali, ma lavoro duplicato e definizioni incoerenti. *Hub-and-spoke* (mozzo e raggi): un centro che gestisce piattaforma, dataset riutilizzabili, definizioni delle metriche e qualità, coaching; e "raggi" nelle aree di business che scoprono i problemi locali, fanno analisi ed esperimenti, curano l'adozione. Serve però coordinamento attivo: chi decide quando una metrica locale contrasta con quella aziendale?

Chi decide cosa. Una matrice *RACI* chiarisce le responsabilità: le priorità del portafoglio sono dello sponsor esecutivo; la definizione di un KPI è del responsabile di business, con data steward e analisti; la consegna del prodotto è del product owner analytics; l'azione operativa è del responsabile del processo. Ritmo suggerito: revisione settimanale delle consegne, mensile del portafoglio, trimestrale della strategia.

Il team di cinque. Dietro i titoli ci sono capacità: tradurre il business in domande (analytics lead, business analyst), costruire l'ingestione dei dati (data engineer), creare modelli di dati testati e metriche condivise (analytics engineer), analizzare e comunicare (BI/data analyst), modellare statisticamente (data scientist). Per un portafoglio che parte dalla redditività il team proposto è: 1 analytics lead con ownership di prodotto, 1 data engineer, 1 analytics engineer, 2 BI/data analyst. Esperti di finanza, IT, sicurezza e un supporto statistico/ML arrivano da fuori, quando servono. Il data scientist entra quando i casi predittivi diventano prioritari.

Chi paga. Le fondamenta condivise si finanziano come capacità aziendali; i prodotti di dominio contro risultati concordati; e va messo a budget anche manutenzione, formazione e monitoraggio.

Collegamento

La logica è la stessa del corso di International Business sulla struttura organizzativa delle multinazionali: centralizzare dà coerenza ed economie di scala, decentralizzare dà vicinanza al mercato. Hub-and-spoke è la versione "transnazionale" applicata ai dati.

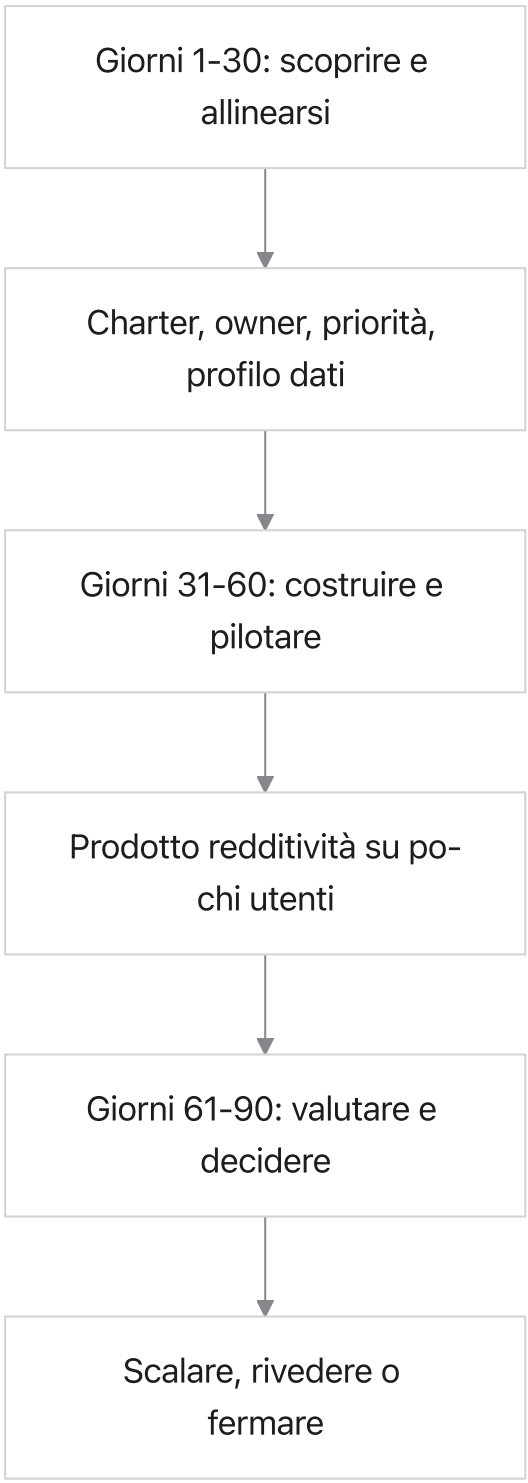
Consegnare in piccolo, misurare il valore, resistere agli imprevisti

Il processo. Il ciclo di consegna segue CRISP-DM, il metodo standard nato a fine anni '90 da un consorzio industriale: comprensione del business, comprensione dei dati, preparazione, modellazione, valutazione, deployment. Si torna indietro quando le prove cambiano. Il consiglio: cicli brevi con un **primo rilascio piccolo ma completo**: una sola decisione e pochi utenti, una fetta di dati stretta ma affidabile, un risultato dentro un flusso di lavoro che esiste già. È "fatto" quando i controlli passano, gli utenti sanno spiegare il risultato e agire, ed esistono un proprietario, documentazione e supporto.

Qualità dei dati proporzionata alla decisione. Sei dimensioni, ognuna con un controllo: completezza (gli identificativi cliente ci sono), unicità (la stessa transazione non compare due volte), coerenza (i codici valuta coincidono tra fonti), tempestività (i dati arrivano prima della decisione), validità (date e importi rispettano le regole), accuratezza (un campione coincide con una fonte affidabile). Un dataset può essere completo e valido ma comunque sbagliato.

Adozione. Una dashboard tecnicamente perfetta può restare inutilizzata. Per evitarlo: mappare utenti, incentivi e momenti di decisione; co-progettare con un piccolo gruppo pilota; portare l'informazione dove il lavoro già avviene; formare le persone sulle loro decisioni; usare "campioni" interni e feedback regolari; misurare l'uso ripetuto e se le azioni cambiano.

Misurare il successo. Quattro tipi di misura: *delivery* (tempo dalla domanda approvata al risultato usabile), *fiducia* (errori di riconciliazione e problemi di qualità aperti), *adozione* (decisioni supportate e uso ripetuto), *risultato di business* (margine in più, costi ridotti, perdite evitate). Esempio delle slide: pilota con 80.000 € di beneficio attribuibile – 30.000 € di costo incrementale = **50.000 € di beneficio netto**. La domanda critica: che prove abbiamo per dire "attribuibile"? Serve un confronto, idealmente un gruppo di controllo.



Le carte degli imprevisti. L'esercitazione finale chiede a ogni squadra (business, analytics, tecnologia, finanza) di pescare una carta e rivedere i propri impegni: (1) un quarto dei record clienti non ha un identificativo usabile: riparare i dati, ridurre il perimetro o cambiare progetto? (2) il budget è tagliato del 40%: cosa proteggere, rimandare o condividere? (3) le vendite rifiutano di assegnare

un esperto: chi possiede il lavoro, quando fermarsi? (4) il CEO vuole l'AI e trova la dashboard poco ambiziosa: come difendere o adattare il piano senza perdere lo scopo? (5) il pilota non ha utenti, i manager continuano con i fogli Excel: che cosa deve cambiare nel prodotto, nel flusso o negli impegni?

L'idea in una frase

Un reparto analytics non si giudica dal numero di dashboard o dalla sofisticazione dei modelli, ma da quante decisioni cambia e da quanto valore misurabile produce.

Prova tu **Il pilota funziona ma i manager usano ancora Excel. Che cosa guardi per primo?**

Richiamo a libro chiuso

1. Disegna a memoria una matrice di confusione e ricava accuracy, precision, recall e F1 dall'esempio delle disdette (TP 15, FP 10, FN 5, TN 70).
2. Spiega la differenza tra overfitting e underfitting usando le due curve di errore (training e validazione).
3. Quali sono le cinque informazioni che una richiesta deve contenere nel 'consistent intake brief'?
4. Racconta il piano a 90 giorni del reparto analytics: che cosa si fa nei giorni 1-30, 31-60, 61-90 e che prova serve a ogni revisione.

Quiz

1. **Un modello per le disdette di un ristorante ha accuracy 85%. Il 20% delle prenotazioni viene davvero disdetto. Che cosa controlli prima di festeggiare?**

- Il recall sulle disdette: 'nessuno disdice' fa già 80%
- L'accuracy sul training, per vedere se supera l'85%
- L'F1 sulle prenotazioni confermate, la classe più ampia
- Che l'85% superi il 50% di un classificatore a caso

2. **Una banca usa un modello antifrode. Bloccare una carta per errore costa una telefonata, lasciar passare una frode costa migliaia di euro. Quale metrica privilegi?**

- L'accuracy: è la più stabile quando le frodi sono rare
- L'F1: in antifrode i due errori pesano sempre uguale
- La precision: ogni blocco sbagliato irrita un cliente
- Il recall: meglio qualche blocco inutile che frodi perse

3. **Precision 60% e recall 75%. Quanto vale l'F1?**

- 75,0%
- 66,7%
- 67,5%
- 45,0%

4. **Il tuo modello ha errore 2% sul training e 25% sui dati di validazione. Che cosa sta succedendo?**

- Underfitting: aggiungi variabili e profondità all'albero
- Leakage: il test è servito per scegliere il modello
- Classi sbilanciate: passi dall'accuracy al recall
- Overfitting: semplifichi o regolarizzi il modello

5. **Vuoi prevedere le vendite del prossimo trimestre con tre anni di dati mensili. Come dividi i dati per il test?**

- A caso, così ogni mese compare in entrambe le parti
- Per tempo: alleni sul passato, testi sui mesi recenti
- Per cliente, tenendo ognuno in una sola delle due parti
- Cross-validation casuale su tutti i mesi, senza test

6. **Il CEO di una catena di negozi dice: 'I profitti calano, voglio un modello di AI'. Qual è la prima mossa di un buon capo analytics?**

- Scegliere la piattaforma dati utile a tutti i progetti
- Un modello predittivo sul churn, il caso di più valore
- Una dashboard con tutti i KPI di margine disponibili
- Tradurla in una domanda con proprietario e azione

7. **Hai tre progetti: dashboard di redditività (punteggio 4,40), modello di churn (3,40), piattaforma dati (3,00). Il churn ha il valore potenziale più alto. Quando potrebbe passare primo?**

- Se alzi il peso del valore, dove il churn ha 5 su 5
- Se nuove prove alzano i punteggi su dati e adozione
- Se mostra un'accuracy alta sui dati storici dei clienti
- Mai: la classifica del punteggio pesato è definitiva

8. **Un'azienda con dieci divisioni molto diverse ha analisti sparsi che usano definizioni diverse di 'cliente attivo'. Quale modello organizzativo suggerisci?**

- Decentralizzato: ogni divisione conosce i propri clienti
- Una RACI: basta dire chi è Accountable per ogni report
- Centralizzato: un solo ufficio garantisce definizioni uniche
- Hub-and-spoke: definizioni centrali, analisti nelle divisioni

Soluzioni del quiz

1. **A** — Con classi sbilanciate l'accuracy inganna: il modello pigro che dice sempre 'viene' ha già 80%, quindi serve sapere quante disdette trova (recall). L'accuracy sul training confonde valutazione e addestramento; il confronto con il 50% vale solo con classi bilanciate; l'F1 va calcolato sulla classe che ti interessa (le disdette), non su quella più numerosa.
2. **D** — Quando il falso negativo (frode persa) costa molto più del falso positivo (telefonata), si vuole trovare quasi tutti i casi veri: recall. Puntare sulla precision ottimizza l'errore economico. L'accuracy con frodi rare è dominata dalle transazioni normali (trappola dell'accuracy). L'F1 tratta i due errori come equivalenti, mentre qui non lo sono.
3. **B** — F1 = 2·0,60·0,75 / (0,60+0,75) = 0,90 / 1,35 ≈ 0,667. 67,5% è la media semplice (l'F1 è una media armonica e punisce lo squilibrio), 45% è il solo prodotto senza il resto della formula, 75% è il recall preso da solo.
4. **D** — Errore bassissimo sul training e alto su dati nuovi è la firma dell'overfitting. L'underfitting ha errori alti su entrambi, e aggiungere profondità peggiorerebbe le cose. Il leakage gonfia i punteggi anche fuori dal training, non li fa crollare. Lo sbilanciamento cambia la metrica da guardare ma non spiega il divario training/validazione.
5. **B** — Lo split deve imitare la realtà: il modello prevederà il futuro, quindi va provato su periodi che non ha visto. Lo split casuale fa 'vedere il futuro' al modello (leakage temporale). Tenere insieme ogni cliente è la regola giusta contro un altro tipo di leakage, ma non risolve quello temporale. Una cross-validation casuale senza test finale ha lo stesso difetto e manca della misura onesta finale.
6. **D** — Si parte dalla decisione da cambiare: quali prodotti o clienti spiegano il calo, e chi deciderà su prezzi o costi. Un'altra dashboard ripete il problema del CEO che ha 'dashboard ovunque'. Saltare al churn sceglie la tecnologia prima della domanda. La piattaforma è una fondamenta utile, ma senza domanda e proprietario produce costo senza azione.
7. **B** — Il churn perde punti su fattibilità, dati pronti e adozione: se nuove prove li alzano, la classifica cambia. Il punteggio è uno strumento, non una sentenza (quindi 'mai' è sbagliato). Cambiare i pesi per far vincere il progetto preferito svuota il metodo. Un'accuracy alta sullo storico può essere la trappola dell'accuracy e non dice nulla sull'adozione.
8. **D** — Il problema è l'incoerenza delle definizioni, ma le divisioni sono diverse e servono analisti vicini al business: hub-and-spoke tiene entrambe le cose. Il centralizzato risolve le definizioni ma con dieci divisioni diventa un collo di bottiglia. Il decentralizzato è proprio la causa del caos attuale. La RACI chiarisce chi decide, ma non è un modello organizzativo e non crea definizioni comuni.

Applica a un caso nuovo

Caso ipotetico. Una catena di palestre con 40 sedi perde iscritti. Il CEO vuole 'un'AI che preveda chi se ne va'. Hai i dati di accesso ai tornelli (con il 15% di

tessere senza codice cliente), i pagamenti e un CRM usato poco. Il budget è per tre persone e 60 giorni. Proponi un piano e spiega come valuteresti il modello.

Mostra una soluzione ragionata

Decidi tu

Il CEO vuole l'AI

Sei a metà del piano a 90 giorni. La dashboard di redditività funziona e il CFO la usa. In riunione il CEO dice: 'Una dashboard non è abbastanza ambiziosa. Voglio l'intelligenza artificiale.'

Come rispondi? (carta 4 dell'esercitazione)

Abbandoni la dashboard e avvii subito un modello di AI sul churn

Rischiosa. Butti via l'unico prodotto adottato e parti su un caso con dati deboli (punteggio dati 2/5): rischi di arrivare al giorno 90 senza nulla di usato.

Mantieni la dashboard e proponi un passo predittivo collegato: prevedere i clienti a margine in calo, con pilota e criteri di successo

Scelta solida. Rispondi all'ambizione del CEO senza perdere lo scopo: l'AI si appoggia ai dati già puliti e a un utente che già agisce. Il valore resta misurabile.

Spieghi al CEO che l'AI è una moda e non serve

Rischiosa. Hai forse ragione sul merito ma perdi lo sponsor. Il reparto vive di fiducia del vertice: serve tradurre la richiesta, non respingerla.

Le analytics servono decisioni: la tecnologia (dashboard o AI) si sceglie in base alla decisione e ai dati pronti, non all'effetto annuncio.

Il modello da 95%

Un fornitore ti presenta un modello di churn con 95% di accuracy. Nel tuo database il 4% dei clienti se ne va ogni mese. Il fornitore ha testato il modello su dati mescolati a caso tra 2023 e 2025.

Firmi il contratto?

Sì: 95% è altissimo

Rischiosa. Con il 4% di abbandoni, dire 'nessuno se ne va' dà già 96% di accuracy: il modello potrebbe essere peggio della baseline. E lo split casuale nel tempo può nascondere leakage.

Chiedi recall e precision sugli abbandoni, confronto con la baseline e un test su un periodo futuro mai visto

Scelta solida. Sono i controlli di una valutazione onesta prima dell'uso operativo: baseline, holdout adatto, niente leakage, errori pesati sulla decisione.

Chiedi solo uno sconto sul prezzo

Rischiosa. Negozi il costo di qualcosa di cui non conosci il valore. Prima la prova che il modello serve, poi il prezzo.

Accuracy trap e valutazione onesta: un numero alto non basta, conta come è stato ottenuto e se batte una soluzione banale.

Da vedere

Film · 2011

Moneyball

Storia vera degli Oakland Athletics: un dirigente convince l'organizzazione a decidere con i dati. È la parte 'adozione' della lezione: il problema non è il modello, sono le persone.

Dove: Netflix / noleggio (dipende dal periodo)

Documentario · 2020

Coded Bias

Mostra algoritmi di riconoscimento facciale che sbagliano molto di più su alcuni gruppi: perché bisogna controllare le prestazioni per sottogruppi, come chiede una valutazione onesta.

Dove: Netflix

Documentario · 2017

AlphaGo

Dietro le quinte di un modello addestrato, valutato e messo alla prova contro un campione: utile per capire addestramento e test in un caso reale.

Dove: YouTube (canale Google DeepMind)

Flashcard

Qual è il primo anello di una pipeline di ML e che cosa controlla?

La raccolta dati: mette insieme fonti diverse controllandone qualità e varietà.

Che cosa aggiunge il deployment rispetto a un modello addestrato?

Lo rende parte del lavoro quotidiano, con monitoraggio e manutenzione.

Formula della precision?

TP / (TP + FP): quanti degli allarmi sono veri.

Formula del recall?

TP / (TP + FN): quanti dei casi veri trovo.

Formula dell'F1?

2 × precision × recall / (precision + recall): media armonica, alta solo se lo sono entrambe.

Che cos'è la trappola dell'accuracy?

Con classi sbilanciate un modello banale ha accuracy alta: prevedere 'nessuno disdice' dà 80% ma recall 0%.

Come si riconosce l'overfitting dalle due curve di errore?

L'errore sul training scende, quello sulla validazione risale.

Come si riconosce l'underfitting?

Il modello sbaglia tanto sia sul training sia sulla validazione: è troppo semplice.

Perché il test set si apre una sola volta, alla fine?

Se lo usi per scegliere tra versioni del modello diventa un secondo training e il punteggio finale è ottimista.

Feature e label: qual è la differenza?

Le feature sono gli indizi in ingresso; la label è la risposta giusta già nota nei dati storici.

Quale criterio pesa di più nel punteggio dei casi d'uso?

Il valore, con il 40% (poi fattibilità 25%, dati pronti 20%, adozione 15%).

Nel punteggio dei casi d'uso, che cosa viene prima dei punti?

I vincoli bloccanti (controlli obbligatori, dipendenze critiche): sono cancelli, non punti.

Hub-and-spoke: che cosa sta nel centro e che cosa nei raggi?

Centro: piattaforma, definizioni delle metriche, qualità, coaching. Raggi: analisti nelle aree di business, vicini alle decisioni.

Analytics predittiva e prescrittiva: che differenza c'è?

La predittiva dice che cosa succederà; la prescrittiva dice che cosa conviene fare (ottimizzazione, simulazione, esperimenti).

Qual è l'idea chiave di CRISP-DM oltre alle sue sei fasi?

Non è una linea retta: si torna alle fasi precedenti quando le prove cambiano.

Glossario

Pipeline · catena di lavorazione dei dati

Sequenza di passaggi automatizzati che porta i dati dalla raccolta al modello in produzione: raccolta, pulizia, feature, addestramento, valutazione, deployment.

Feature engineering · costruzione delle variabili

Creare, scegliere e trasformare le variabili che il modello usa. Esempio: da 'data di prenotazione' ricavare 'giorni di anticipo'.

Confusion matrix · matrice di confusione

Tabella 2x2 che conta veri positivi, falsi positivi, falsi negativi e veri negativi di un classificatore: da lì si calcolano tutte le metriche.

Precision · precisione

Tra i casi che il modello segnala come positivi, quanti lo sono davvero: TP / (TP + FP). Bassa precisione = tanti falsi allarmi.

Recall · richiamo / sensibilità

Tra tutti i casi positivi reali, quanti il modello ne trova: TP / (TP + FN). Basso recall = tanti casi persi.

F1 score · punteggio F1

Media armonica di precision e recall: 2·P·R / (P + R). È alta solo se lo sono entrambe.

Overfitting · sovradattamento

Il modello impara a memoria il training, rumore compreso: errore basso sui dati vecchi, alto su quelli nuovi.

Data leakage · fuga di informazioni
Il modello usa, in addestramento, informazioni che al momento reale della previsione non avrebbe. Il punteggio sembra ottimo ma è falso.

Hyperparameter · iperparametro
Impostazione scelta prima dell'addestramento (es. profondità massima di un albero). Si regola con grid search, random search o ottimizzazione bayesiana.

Model drift · deriva del modello
Calo delle prestazioni nel tempo perché il mondo cambia rispetto ai dati di addestramento. Richiede monitoraggio e riaddestramento.

CRISP-DM · processo standard per il data mining
Metodo in sei fasi (business, dati, preparazione, modello, valutazione, deployment) creato a fine anni '90 da un consorzio industriale; si può tornare indietro tra le fasi.

Hub-and-spoke · modello a mozzo e raggi
Organizzazione con un centro (piattaforma, standard, esperti) e analisti distribuiti nelle aree di business, vicini alle decisioni.

RACI · matrice delle responsabilità
Per ogni decisione indica chi è Responsible (fa), Accountable (risponde), Consulted (consultato), Informed (informato).

Label · etichetta / risposta giusta
Il valore che il modello deve imparare a prevedere, già noto nei dati storici. Esempio: per ogni prenotazione passata, 'disdetta sì/no'. Le feature sono gli indizi, la label è la risposta.

Baseline · termine di paragone
Risultato di un metodo semplicissimo (es. prevedere sempre la classe più frequente) che un modello deve battere per valere qualcosa.

Video consigliati

Machine Learning Fundamentals: The Confusion Matrix

StatQuest with Josh Starmer · 7 min · EN

Spiega con disegni semplici la matrice di confusione, base di precision e recall.

Come leggere la matrice di confusione, la precisione e il richiamo

Piero Savastano · 9 min · IT

Lo stesso concetto in italiano, con un esempio pratico in Python.

Overfitting, Underfitting, and Bad Data Are Ruining Your Predictive Models

IBM Technology · 7 min · EN

Overfitting, underfitting e dati sporchi spiegati alla lavagna: completa le slide sulla valutazione.

Introduction to the CRISP-DM Methodology

Cody Baldwin · 5 min · EN

Le sei fasi di CRISP-DM in cinque minuti, con l'idea chiave che si torna indietro.

Fonti

1. Slide Canvas 134187 — Rizzi, BigDataBsnsRizzi2026Lesson6 (46 pagine) — Unica fonte didattica: pipeline (pp. 3–12, immagini), valutazione (pp. 13–16), 'The CEO wants answers' (pp. 17–38), carte di disruption (pp. 39–45).
2. Google for Developers — Accuracy, precision, recall
3. CRISP-DM (storia e fasi)
4. Zillow Group — Form 8-K del 2 novembre 2021 (chiusura Zillow Offers)
5. Zillow Group — Form 10-K FY2021

Note di verifica